**Benemérita Universidad Autónoma de Puebla**
Facultad de Ciencias de la Computación

Reto AgroCebada FIRA 2026
Reporte del modelo generalizable

# ¿Dónde rinde más la cebada de temporal?

## Un modelo municipal con datos públicos para Hidalgo, México, Puebla y Tlaxcala

**Integrantes** José Alán Pomares Valdés
Luis Emmanuel Ramiro Luna
Vicente Josimar López Martinez

**Asesor** Luis Gustavo Olivares Soto

**Contacto** pv202351433@alm.buap.mx

Puebla, Pue., 9 de octubre de 2026

***Resumen*. Estimamos qué rendimiento de cebada de temporal esperar en cada municipio de Hidalgo, México, Puebla y Tlaxcala, y con qué riesgo, usando solo datos públicos. Aprendimos del rendimiento oficial del SIAP de 2003 a 2025. Donde no hay datos del SIAP a menos de 50 km, un modelo basado en la temperatura máxima de julio y agosto se equivoca en promedio 0.44 t/ha, contra 0.57 t/ha de interpolar a los municipios vecinos. El suelo no agrega información y el clima del año no anticipa la cosecha. El resultado es un mapa de 268 municipios con rendimiento esperado, probabilidad de quedar bajo 2 t/ha y una marca de confianza.**

***Palabras clave*. cebada de temporal, rendimiento municipal, SIAP, validación espacial, kriging, riesgo agrícola.**

## I. Introducción

FIRA financia y asegura siembras de cebada de temporal, la que depende solo de la lluvia. Necesita saber qué rendimiento esperar, y con qué riesgo, en lugares donde no hay parcelas medidas.

Las etiquetas del reto no sirven para eso. Se dividen por municipio en dos grupos medidos de forma distinta, que promedian 4.49 y 3.05 t/ha, y ninguna variable ambiental explica la diferencia [1]. Por eso usamos el rendimiento oficial del Servicio de Información Agroalimentaria y Pesquera (SIAP) [2], que mide igual a todos los municipios. El modelo predice el rendimiento promedio de un municipio, no el de una parcela.

**Resultados principales.**

- **La cebada rinde más donde el verano es fresco.** Cada grado más de temperatura máxima en julio y agosto resta cerca de 0.8 t/ha.
- **Ese dato basta para estimar lugares sin datos.** Lejos de municipios con SIAP, el modelo de temperatura se equivoca menos que copiar a los vecinos.
- **El suelo y el clima del año no ayudan.** El suelo no mejora el modelo y el clima mensual del año no anticipa la cosecha.

## II. Datos

**Rendimiento.** Usamos el cierre agrícola municipal del SIAP para cebada grano de temporal en primavera-verano, de 2003 a 2025 [2]. Quitamos las cosechas de menos de 50 ha y los municipios con menos de 5 años de datos. Quedan 1 942 registros de 100 municipios, unos 25 por estado. El rendimiento sube en promedio 0.028 t/ha por año, así que llevamos cada año al nivel de 2025 antes de promediar.

El SIAP muchas veces estima una cifra por distrito y la copia a varios municipios. Así ocurre en el 53 % de los registros. Lo tomamos en cuenta en la validación de la Sección III.

**Ambiente.** Usamos lluvia de CHIRPS [3], temperatura máxima (Tmax) y mínima de CHIRTS-ERA5 [4], elevación y pendiente del Copernicus DEM [5] y la carta de suelos del INEGI [6]. Cada variable se promedia solo sobre la agricultura de temporal del municipio [7], en los 486 municipios del Marco Geoestadístico [8].

La Fig. 1 muestra el patrón central. Los municipios con mejor rendimiento están donde el verano es más fresco, en el oriente de Puebla, Tlaxcala y el centro del Estado de México.

## III. Método

**Modelos.** Comparamos dos formas de estimar un municipio.

- **Kriging de vecinos.** Promedia el rendimiento de los municipios cercanos, dando más peso a los más próximos. Es la base a superar porque no usa ambiente.
- **Modelos ambientales simples.** Regresiones con una o dos variables elegidas por lo que se sabe del cultivo. La principal usa la Tmax de julio y agosto, porque el calor en la floración acorta el llenado del grano. El modelo final le suma el kriging de sus errores, que corrige cerca de los datos y se apaga lejos de ellos.

También probamos modelos con 14 variables de clima, terreno y suelo.

**Validación.** Agrupamos los 100 municipios en 20 zonas y predecimos una zona a la vez sin usar sus datos [9]. Para simular un lugar realmente nuevo quitamos además los municipios a menos de 50 km de la zona (Fig. 2). Repetimos todo 10 veces con zonas distintas.

**Error.** Medimos el error típico en t/ha entre el rendimiento promedio predicho y el observado de cada municipio. Le damos más peso a los municipios con más superficie sembrada, que es donde FIRA opera.

**Regla de decisión.** La fijamos antes de correr los experimentos. Un modelo ambiental sustituye al kriging si gana en al menos 7 de las 10 repeticiones y si su ventaja desaparece al revolver las variables entre municipios.

## IV. Resultados

### A. Comparación de los 13 modelos

Comparamos 13 modelos en cuatro familias, sin ambiente, simples con una o dos variables, simples con kriging de sus errores y con 14 variables. La Fig. 3 los ordena en el escenario que más importa para FIRA, un municipio sin datos del SIAP a menos de 50 km. También los evaluamos con vecinos cerca, dejando fuera distritos completos y sin las cifras que el SIAP copia entre municipios.

- **Sin datos a menos de 50 km, los modelos con Tmax ganan.** El final se equivoca 0.44 t/ha, contra 0.57 del kriging, y gana en las 10 repeticiones. La ventaja se mantiene hasta 80 km (Fig. 4).
- **La ventaja viene del clima.** Al asignar a cada municipio la Tmax de otro, ninguna de 99 pruebas iguala al modelo real.
- **Con vecinos cerca la ventaja es pequeña.** El final tiene 0.29 contra 0.31 del kriging. Si no se pondera por superficie gana el kriging, porque los municipios chicos tienen promedios ruidosos que el clima no explica.
- **Tmax sola y Tmax con lluvia casi empatan.** Con kriging de errores, el promedio de los dos primeros

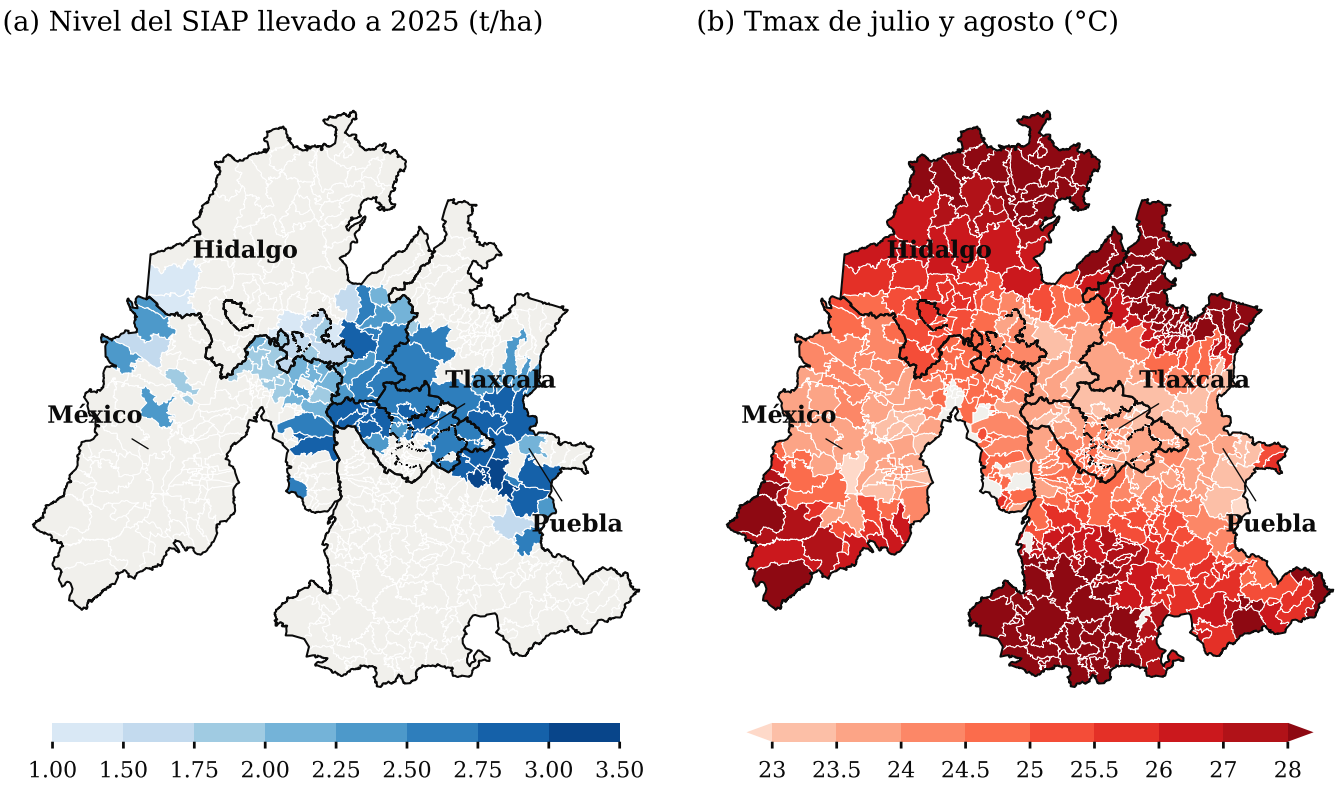



Figura 1. (a) Rendimiento oficial promedio de cada municipio con datos del SIAP, llevado a 2025. (b) Temperatura máxima promedio de julio y agosto en la agricultura de temporal de cada municipio.

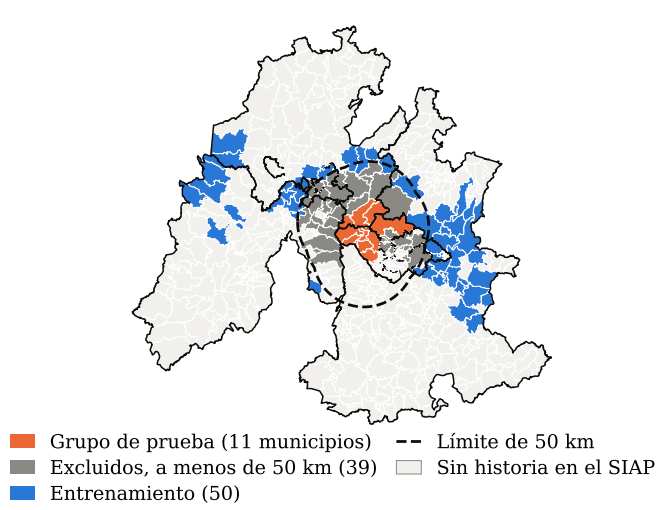



Figura 2. Una partición de la validación. El modelo se entrena sin los municipios grises y predice los naranjas, como si fueran un lugar sin datos del SIAP a menos de 50 km.

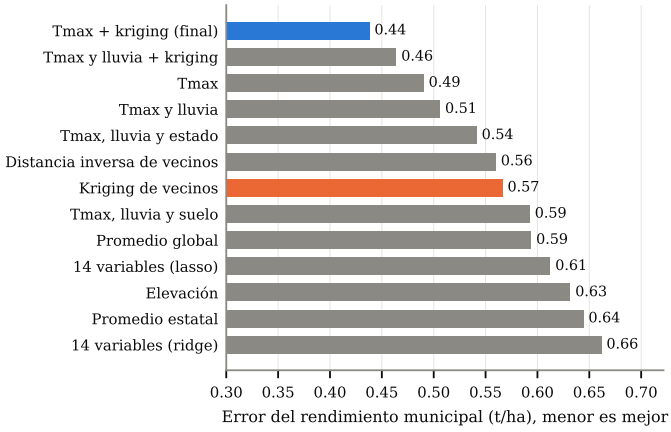



Figura 3. Error de los 13 modelos al predecir municipios sin datos del SIAP a menos de 50 km, ponderado por superficie sembrada y promediado en 10 repeticiones. En naranja el kriging de vecinos, que no usa ambiente, y en azul el modelo final.

escenarios es 0.3655 y 0.3664 t/ha. Con vecinos cerca y por distrito gana la versión con lluvia. Lo firme es que la Tmax es la variable clave, no cuál de las dos versiones es mejor.

- **Elevación sola, suelo, estado o 14 variables no ayudan.** Con 14 variables el modelo queda peor que el promedio global lejos de los datos.

### *B. Qué variables importan*

La Fig. 5 muestra las dos relaciones más claras.

- **Temperatura.** El rendimiento baja 0.79 t/ha por cada grado más de Tmax en julio y agosto ($r = -0.77$).
- **Lluvia.** Más lluvia de mayo a octubre sube el rendimiento ($r = 0.59$), cerca de 0.15 t/ha por cada 100 mm.

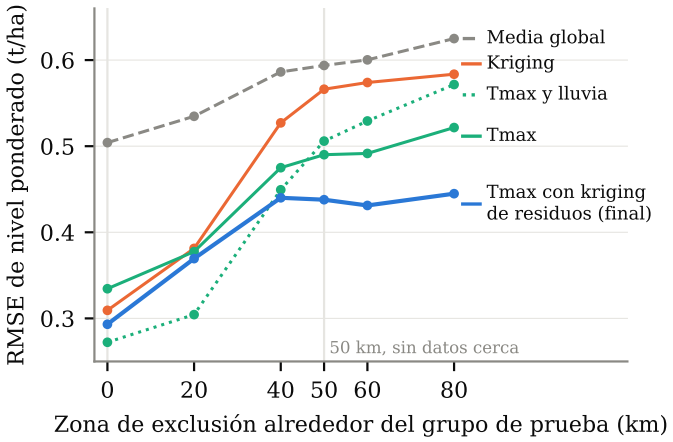



Figura 4. Error del rendimiento municipal según el radio de exclusión, promedio de 10 repeticiones. A la derecha de 50 km el municipio predicho no tiene datos del SIAP cerca.

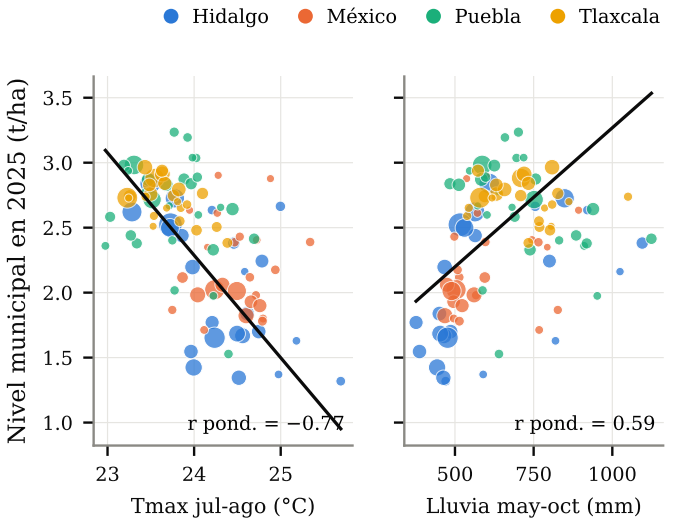



Figura 5. Rendimiento municipal llevado a 2025 contra la Tmax de julio y agosto y la lluvia de mayo a octubre. El tamaño del punto crece con la superficie sembrada.

- **Elevación.** Repite la información de la temperatura, porque los lugares altos son más frescos ($r = -0.80$ entre ambas).
- **Suelo.** No agrega información que podamos detectar.

### C. El clima del año no anticipa la cosecha

Probamos si las desviaciones mensuales de lluvia y temperatura de un año predicen la cosecha de ese año. Al dejar fuera años completos, no mejoran al promedio histórico de cada municipio. Una media mensual no distingue una helada de una noche fresca ni detecta las rachas secas.

### D. Riesgo

Con los errores fuera de muestra construimos, para cada municipio, un intervalo que debería contener 8 de cada 10 años y la probabilidad de quedar bajo 2 t/ha [10].

- **El intervalo cumple.** Contiene el 81.5 % de los años observados, con un ancho medio de 1.9 t/ha.
- **La probabilidad es prudente.** Sobreestima la frecuencia real de años malos, más cuando la probabilidad predicha es alta.

### E. Mapa municipal

Aplicamos el modelo final a los 486 municipios (Fig. 6). Solo damos valor a los 268 cuyo clima y terreno se parecen a los de los municipios con SIAP. Los demás son sobre todo tierras bajas y calientes. Cada valor lleva una marca de confianza.

- **Alta.** El municipio tiene historia en el SIAP. Son 100.
- **Media.** Sin historia pero cerca de municipios con SIAP. Son 91.
- **Baja.** El resto, donde el valor refleja solo el clima. Son 77.

El rendimiento esperado va de 1.3 a 3.2 t/ha. Los mejores municipios con historia están en Puebla, como San Salvador el Seco y San Juan Atenco con 3.16 t/ha. El peor es Huichapan, Hidalgo, con 1.33 t/ha y probabilidad de 0.91 de quedar bajo 2 t/ha.

### F. Comparación con las etiquetas del reto

Aplicamos el modelo, sin ajustarlo a ellas, a las 138 parcelas de entrenamiento del reto, en 9 municipios. Las 59 parcelas de evaluación no tienen rendimiento publicado.

- **No predice las parcelas del reto.** Su error es de 1.35 a 1.46 t/ha, peor que predecir a todas con el promedio del reto (0.85) y que nuestro modelo entrenado con las parcelas del reto (0.46 en validación cruzada).
- **La diferencia se concentra en un grupo.** Las parcelas del grupo de 4.49 t/ha quedan 1.7 t/ha arriba del modelo y las del grupo de 3.05 t/ha solo 0.35 arriba.

Es consistente con que el primer grupo mide algo distinto del promedio municipal oficial, aunque no lo prueba. Con solo 9 municipios esta comparación no evalúa al modelo. Lo evalúa la validación con el SIAP.

## V. Limitaciones

- **El modelo aprende la cifra del SIAP.** Esa cifra a veces se copia entre municipios de un distrito y puede diferir de lo que obtiene un productor.
- **Asociación, no causa.** La temperatura también refleja la altura, la tradición cebadera y el manejo. El modelo ordena lugares, pero no dice cuánto cambiaría el rendimiento si cambiara el clima.
- **La elección de Tmax sola se hizo viendo resultados.** El contendiente fijado de antemano era Tmax con lluvia, que queda casi empatado y es mejor con vecinos cerca. Confirmarlo requiere datos nuevos.
- **Municipios frescos sin cebada.** Un municipio fresco puede salir alto aunque ahí no se siembre cebada o su suelo sea forestal. Por eso lleva confianza baja.

(a) Rendimiento esperado en 2025 (t/ha)

(b) Probabilidad de quedar bajo 2 t/ha en un año cualquiera

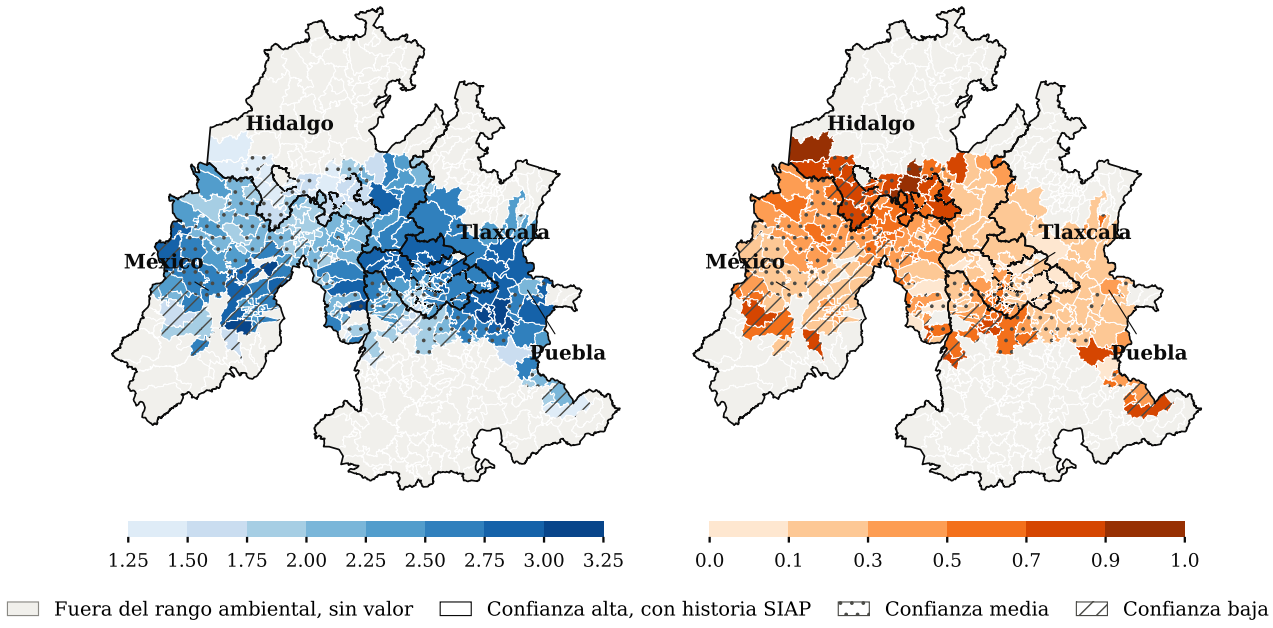



Figura 6. Rendimiento esperado en 2025 y probabilidad de quedar bajo 2 t/ha en un año cualquiera. El rayado marca la confianza media (puntos) y baja (líneas). En gris, municipios sin valor por tener un ambiente distinto al de los municipios con SIAP.

## VI. Conclusiones y uso para FIRA

Con datos públicos se puede estimar el rendimiento esperado de la cebada de temporal en municipios sin datos propios. La temperatura máxima de julio y agosto es la variable clave. Proponemos tres usos.

1) **Priorizar zonas para crédito** con el rendimiento esperado y su intervalo.
2) **Tarifar el seguro** con la probabilidad de quedar bajo 2 t/ha, que es una estimación prudente.
3) **Verificar en campo antes de financiar** en los 77 municipios de confianza baja.

**Zonas con buen rendimiento esperado y sin cebada registrada.** La Tabla I lista municipios sin historia en el SIAP cuyo rendimiento esperado supera la mediana de 2.53 t/ha de los municipios con historia. En ninguno el SIAP registra cebada de temporal con más de 150 ha sembradas en algún año de 2003 a 2025.

- **Oriente de Puebla y Tlaxcala, y norte del Estado de México.** Están junto a zonas cebaderas, con confianza media. Son los candidatos más sólidos para ampliar el crédito.
- **Valle de Toluca y sierra al poniente de la Ciudad de México.** Tienen veranos frescos y algunos de los valores esperados más altos, pero están a más de 25 km de datos y su confianza es baja. Ahí domina el maíz, hay zonas urbanas y bosque, y el modelo no ve las heladas. Requieren parcelas de prueba antes de financiar.

Cuadro I
Municipios sin historia en el SIAP con mayor rendimiento esperado en 2025 (t/ha). El intervalo contiene 8 de cada 10 años.

| Municipio | Estado | Esperado | Intervalo |
|---|---|---|---|
| *Confianza media, junto a zonas cebaderas* | | | |
| Lafragua | Puebla | 3.00 | 1.7 a 4.3 |
| El Carmen Tequexquitla | Tlaxcala | 2.85 | 1.7 a 3.9 |
| El Oro | México | 2.83 | 1.5 a 4.1 |
| Temoaya | México | 2.78 | 1.7 a 3.8 |
| General Felipe Ángeles | Puebla | 2.77 | 1.4 a 4.1 |
| Quecholac | Puebla | 2.75 | 1.4 a 4.1 |
| Tlahuapan | Puebla | 2.70 | 1.7 a 3.7 |
| Ixtenco | Tlaxcala | 2.69 | 1.8 a 3.6 |
| *Confianza baja, lejos de datos* | | | |
| Jilotzingo | México | 3.08 | 1.9 a 3.9 |
| Tenango del Valle | México | 3.02 | 1.8 a 3.9 |
| Calimaya | México | 2.96 | 1.7 a 3.9 |
| Toluca | México | 2.82 | 1.5 a 3.8 |

El rendimiento de un productor depende además de su manejo. Estimarlo requiere datos de manejo y rendimientos medidos con un mismo criterio en todos los municipios.

**Relación con la evaluación del reto.** FIRA evaluará con sus propias parcelas, y en ellas el modelo del reto es mejor, con un error de 0.46 t/ha contra 1.35 a 1.46 del modelo del SIAP. Los dos errores no son comparables. El del reto mide parcelas en 9 municipios y el del SIAP mide promedios municipales en lugares sin datos, donde se equivoca 0.44 t/ha. Las etiquetas del reto mezclan dos criterios de medición que difieren en 1.44 t/ha, y el modelo del reto aprende esa diferencia, que no

existe fuera de esos municipios. El modelo del SIAP aprende de datos medidos con un mismo criterio y por eso generaliza a lugares nuevos, pero por la misma razón no reproduce las etiquetas del reto. Tampoco podemos llevar la Tmax al modelo del reto. En sus 9 municipios va de 23.3 a 23.9 °C, contra 23.0 a 25.7 °C en los municipios con SIAP, y las parcelas de un mismo municipio comparten casi el mismo clima. Esa variación explicaría a lo más 0.5 t/ha, menos que la diferencia entre los dos criterios de medición. Proponemos entregar el modelo del reto para su evaluación y el del SIAP para decidir dónde sembrar.

## Referencias


[1] J. A. Pomares Valdés, L. E. Ramiro Luna y V. J. López Martinez, "¿Qué separa a los dos regímenes de rendimiento? Descarte de causas ambientales y contraste con las cifras oficiales del SIAP," reporte técnico, Reto AgroCebada FIRA 2026, Facultad de Ciencias de la Computación, BUAP, Puebla, 2026.

[2] Servicio de Información Agroalimentaria y Pesquera, "Cierre de la producción agrícola por municipio, cebada grano, temporal, primavera-verano, 2003–2025." [En línea]. Disponible: https://nube.agricultura.gob.mx/cierre_agricola/. Consultado el 9 de octubre de 2026.

[3] C. Funk *et al.*, "The climate hazards infrared precipitation with stations, a new environmental record for monitoring extremes," *Scientific Data*, vol. 2, art. 150066, 2015.

[4] Climate Hazards Center, Universidad de California en Santa Bárbara, "CHIRTS-ERA5, temperatura máxima y mínima mensual." [En línea]. Disponible: https://data.chc.ucsb.edu/experimental/CHIRTS-ERA5/. Consultado el 9 de octubre de 2026.

[5] Agencia Espacial Europea, "Copernicus DEM GLO-90." [En línea]. Disponible: https://copernicus-dem-90m.s3.amazonaws.com/. Consultado el 9 de octubre de 2026.

[6] Instituto Nacional de Estadística y Geografía, "Conjunto de datos vectorial edafológico, escala 1:250 000, Series I y II." [En línea]. Disponible: https://www.inegi.org.mx/temas/edafologia/

[7] Instituto Nacional de Estadística y Geografía, "Conjunto de datos vectoriales de uso del suelo y vegetación, escala 1:250 000, Serie VII, conjunto nacional," 2021. [En línea]. Disponible: https://www.inegi.org.mx/temas/usosuelo/

[8] Instituto Nacional de Estadística y Geografía, "Marco Geoestadístico 2025." [En línea]. Disponible: https://www.inegi.org.mx/app/biblioteca/ficha.html?upc=794551163061

[9] D. R. Roberts *et al.*, "Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure," *Ecography*, vol. 40, no. 8, pp. 913–929, 2017.

[10] A. N. Angelopoulos y S. Bates, "Conformal prediction, a gentle introduction," *Foundations and Trends in Machine Learning*, vol. 16, no. 4, pp. 494–591, 2023.