Benemérita Universidad Autónoma de Puebla
Facultad de Ciencias de la Computación

Reto AgroCebada FIRA 2026
Reporte técnico del modelo

Rendimiento de cebada de temporal con régimen de etiquetas y rezago espacial

Procedimiento, arquitectura y evaluación del modelo

Integrantes José Alán Pomares Valdés
Luis Emmanuel Ramiro Luna
Vicente Josimar López Martinez

Asesor Luis Gustavo Olivares Soto

Contacto pv202351433@alm.buap.mx

Puebla, Pue., 7 de octubre de 2026

***Resumen*. Estimamos el rendimiento de cebada de temporal de 59 parcelas con un proceso gaussiano que usa dos datos de cada parcela, el régimen de su etiqueta y el rendimiento de sus vecinas del mismo régimen. Las etiquetas se dividen por municipio en dos maneras de reportar con medias de 4.49 y 3.05 t/ha, y conocer el régimen explica la mayor parte de lo que se puede explicar. Construimos el modelo paso a paso. Cada idea entró solo si mejoraba la validación cruzada de forma consistente y pasaba una prueba de permutación. Así quedaron fuera las variables satelitales, climáticas y topográficas, que no mejoraron la predicción una vez conocidos el régimen y los vecinos. El modelo obtiene una raíz del error cuadrático medio (RMSE) de 0.458 t/ha en validación cruzada, contra 0.489 de la media por régimen. Como el modelo se eligió entre muchas variantes, estimamos con validación anidada un RMSE esperado de 0.46 a 0.49 t/ha.**

***Palabras clave*. rendimiento de cebada, régimen de etiquetas, rezago espacial, proceso gaussiano, validación cruzada, predicción conformal.**

I. Introducción

El reto AgroCebada de FIRA 2026 pide estimar el rendimiento de cebada de temporal, en toneladas por hectárea (t/ha), de 59 parcelas de Hidalgo, Puebla y Tlaxcala. Estas tres entidades se cuentan entre las cuatro principales productoras de cebada grano del país [1]. Para entrenar tenemos 138 parcelas del mismo ciclo de 2025 con su rendimiento declarado, imágenes de los satélites Sentinel-2 [2] y PlanetScope [3], clima [4], [5] y topografía. El jurado califica primero el error de las 59 predicciones con el RMSE, que se mide en t/ha y castiga más los errores grandes.

La predicción de rendimiento con aprendizaje automático y teledetección es un tema muy estudiado [6], [7]. En este reto las parcelas son pequeñas y su rendimiento es declarado, no medido, y la literatura reporta que ese tipo de dato contiene error considerable [8]. Por eso el reporte se centra en qué información aporta de verdad a la predicción y en qué tan confiable es el error que estimamos.

Este reporte explica cómo construimos el modelo y por qué tomamos cada decisión. La Fig. 1 resume el proceso. Partimos de un hallazgo en las etiquetas (Sección II), fijamos cómo íbamos a evaluar cada idea (Sección III) y agregamos piezas una por una, conservando solo las que mejoraban la validación (Sección IV). Después describimos el modelo final (Sección V), qué tan confiable es su error (Sección VI) y qué aportan los índices satelitales (Sección VII).

II. Datos y el hallazgo de los regímenes

Hay 197 parcelas en nueve municipios, 138 de entrenamiento y 59 de predicción. FIRA hizo la partición al azar y estratificada por zona, así que cada municipio con parcelas por predecir también tiene parcelas de entrenamiento. De las series de tiempo construimos 91 variables por parcela, como el máximo del índice de vegetación NDVI en 2025, la fenología [9], la historia de 2022 a 2024, la heterogeneidad dentro de la parcela, el clima y la topografía. Ninguna usa el rendimiento.

Cuadro I
Parcelas por municipio y régimen.

Municipio	Régimen	Entrenamiento	Predicción
Chignahuapan	A	71	29
Almoloya	A	10	4
Cuautepec de Hinojosa	A	5	4
Tepeapulco	A	1	0
Calpulalpan	B	30	14
Singuilucan	B	16	7
Emiliano Zapata	B	3	0
Apan	B	1	0
Nanacamilpa	B	1	1
Total A, B		87, 51	37, 22

Dos maneras de reportar el rendimiento. Al revisar las etiquetas encontramos dos maneras de reportar el rendimiento, y cada municipio usa una sola (Fig. 2). En cuatro municipios el rendimiento viene con dos decimales y promedia 4.49 t/ha. Lo llamamos régimen A. En los otros cinco todos los valores de entrenamiento tienen un decimal y promedian 3.05 t/ha. De las 51 etiquetas de este grupo, 44 son múltiplos de 0.5 y las otras 7, de Singuilucan, solo de 0.1. Lo llamamos régimen B. Por los decimales no sabemos si el rendimiento se midió de forma distinta o solo se anotó de forma distinta. FIRA nos confirmó que la fuente es mixta, con una comercializadora como fuente mayoritaria y el productor como la otra, que la báscula no ajusta por humedad y que debemos tratar todos los registros como una misma variable objetivo. Tampoco conocemos la fuente de cada parcela. Por eso describimos el régimen como una observación por municipio. La fuente mixta es una posible explicación, pero no podemos confirmarla.

Cómo asignamos el régimen. El régimen es una regla fija por nombre de municipio (Cuadro I). Una vez fijada, no se recalcula en la validación y no usa el rendimiento de la parcela evaluada. No lo asignamos por el formato de cada etiqueta, porque 7 de las 87 parcelas del régimen A tienen un solo decimal y una regla por formato las habría mandado al B. Sí fijamos la regla observando las etiquetas de entrenamiento. En seis parcelas de municipios con una a tres parcelas de entrenamiento (Tepeapulco, Apan, Nanacamilpa y Emiliano Zapata), el régimen se dedujo de su propia etiqueta y de la cercanía a municipios vecinos con el mismo formato. Sin esas seis parcelas el RMSE de la validación pasa de 0.458 a 0.464 t/ha, así que el efecto es pequeño, pero lo reconocemos como un supuesto de diseño. Las 59 parcelas por predecir pertenecen a municipios que ya tienen al menos una parcela de entrenamiento. El caso más delicado es el de la parcela de Nanacamilpa, cuyo régimen se apoya en una sola etiqueta.

Este hallazgo cambia el problema. La diferencia entre las medias de los regímenes, de 1.4 t/ha, es casi tres veces la desviación estándar dentro de cada uno (0.53 t/ha en A y 0.40 en B). Además, el redondeo de las etiquetas del régimen B limita lo que cualquier modelo puede predecir. Si el valor verdadero se redondeó a 0.5 t/ha y se distribuye de forma

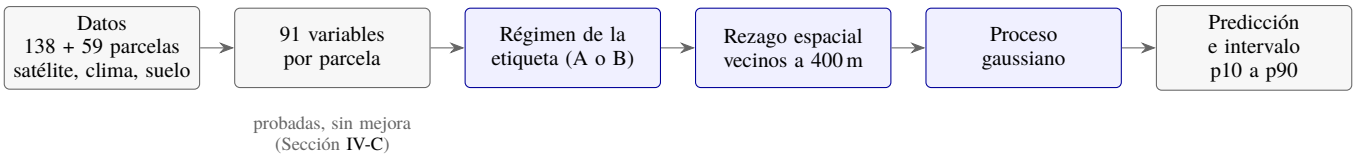


Figura 1. Arquitectura del modelo. En azul, las piezas que usa el modelo final. Las 91 variables satelitales, de clima y de topografía se probaron una por bloque y ninguna mejoró la validación.

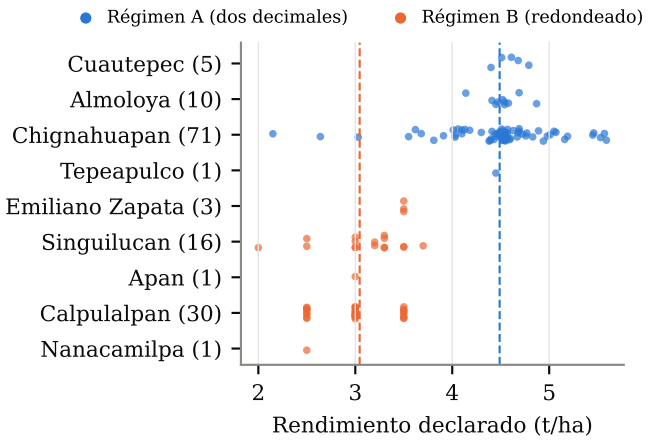


Figura 2. Rendimiento declarado de las 138 parcelas de entrenamiento por municipio, con el número de parcelas entre paréntesis. Las líneas punteadas son la media de cada régimen.

uniforme dentro del intervalo de redondeo, el redondeo agrega una desviación de $0.5/\sqrt{12} = 0.14$ t/ha. Esto es una cota aproximada y no un error mínimo obligatorio, porque 7 de las 51 etiquetas tienen un paso de 0.1. Con la mezcla observada de pasos la cota es 0.134 y, si todas tuvieran paso de 0.1, sería 0.029. Por el tamaño de la diferencia entre regímenes, el régimen es la primera pieza del modelo.

III. Cómo evaluamos cada decisión

Con 138 parcelas cualquier comparación es ruidosa, así que antes de probar ideas fijamos cómo íbamos a decidir.

Error fuera de muestra. Todas las cifras de RMSE se calculan sobre parcelas que el modelo no vio al entrenar. Usamos validación cruzada, que reparte las parcelas en 5 grupos (*folds*), entrena con 4 y predice el quinto, hasta predecir todas. Todo lo que usa el rendimiento, como el rezago espacial, se recalcula dentro de cada fold para que la parcela evaluada nunca influya en su propia predicción.

Dos esquemas. El esquema A sortea los folds al azar, estratificados por municipio, y repite el sorteo 10 veces. Imita la partición oficial y es el que decide. El esquema B deja fuera zonas completas, uniendo las parcelas a menos de 2 km [10], [11], porque la validación al azar tiende a ser optimista cuando hay autocorrelación espacial. Mide qué tanto depende un modelo de tener vecinos en el entrenamiento.

Regla de decisión. Una idea se acepta si baja el RMSE en al menos 7 de las 10 repeticiones del esquema A y si pasa una prueba de permutación [12]. En esa prueba revolvemos al azar las variables nuevas, dentro de cada régimen, y repetimos la validación 50 veces con 3 repeticiones cada una. Si el modelo con las variables revueltas predice igual de bien, la mejora no viene de esas variables y la idea se rechaza. El valor p es la fracción de permutaciones, contando la real, que predice al menos tan bien como el modelo real. Exigimos $p \leq 0.05$. Con 50 permutaciones el p más pequeño posible es $1/51 = 0.0196$, de modo que un valor de 0.02 es el piso de la prueba y no una medición precisa.

Cuántas pruebas hicimos. Registramos 73 evaluaciones. De ellas, 13 fueron informativas, como las bases de comparación. Las otras 60 se sometieron a la comparación emparejada por repetición, 10 ganaron en al menos 7 repeticiones y llegaron a la prueba de permutación, y 7 quedaron aceptadas. No corregimos por comparaciones múltiples, así que los valores p no deben leerse como probabilidades exactas. Con la corrección de Holm solo sobreviven las dos pruebas de que el régimen supera al estado y al municipio, con $p = 0.005$ obtenido con 200 permutaciones. Con el procedimiento de Benjamini y Hochberg [13], que controla la tasa de falsos descubrimientos al 5 %, sobreviven cuatro pruebas, las dos anteriores, el rezago espacial y la elección del proceso gaussiano, todas con $p \leq 0.0196$. Las tres pruebas con $p = 0.039$ no sobreviven. Por esta razón añadimos al final la validación anidada.

Controles del resultado final. Elegir el mejor entre muchos modelos con las mismas particiones infla su resultado [14]. Por eso al final medimos el error esperado con validación anidada [15], comparamos modelos con una prueba t corregida por el traslape entre repeticiones [16] y revisamos que no hubiera fuga de información revolviendo las etiquetas [17]. Estos controles están en la Sección VI.

IV. Construcción del modelo

Agregamos las piezas en orden, de la más sencilla a la más compleja. Cada pieza tuvo que ganarle a la mejor versión aceptada hasta ese momento.

A. *Punto de partida, la media por régimen*

El modelo más simple predice para cada parcela la media de su grupo. La Fig. 3 compara varios grupos. La media por régimen es la mejor en ambos esquemas, con 0.489 t/ha. La media por municipio se le acerca en el esquema A (0.510), pero en el esquema B sube a 0.955 porque, al dejar zonas fuera, muchos municipios se quedan sin parcelas de entrenamiento. El régimen no tiene ese problema, porque se

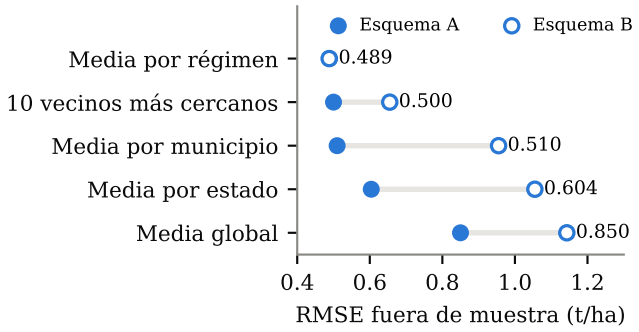


Figura 3. RMSE de modelos sencillos. El número es el esquema A. La media por régimen es la única que no empeora cuando se dejan zonas completas fuera (esquema B).

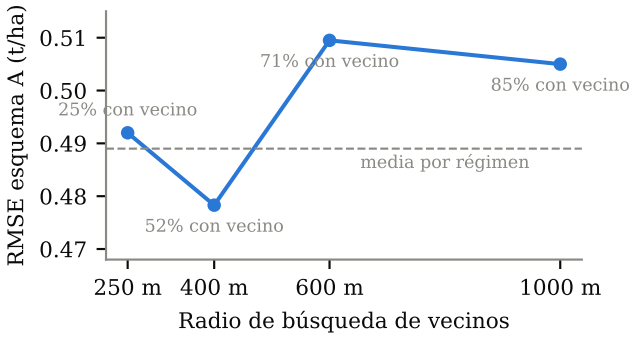


Figura 4. RMSE del modelo con régimen y rezago según el radio de búsqueda de vecinos. El texto indica qué fracción de parcelas tiene al menos un vecino del mismo régimen.

conoce para cualquier parcela. Por eso es la base de todo lo demás.

B. Rezago espacial, lo que dicen los vecinos

Dentro de un régimen el rendimiento todavía varía, y parcelas cercanas tienden a parecerse [18], porque comparten suelo, clima, manejo y a veces productor. Para aprovecharlo calculamos el *rezago espacial*, el promedio del rendimiento de las parcelas de entrenamiento cercanas, ponderado por el inverso de la distancia,

$$\ell_i = \frac{\sum_{j \in \mathcal{N}_i} y_j / d_{ij}}{\sum_{j \in \mathcal{N}_i} 1/d_{ij}}, \tag{1}$$

donde $\mathcal{N}_i$ son hasta 10 vecinos del mismo régimen a menos de un radio r, y_j su rendimiento y d_{ij} la distancia en metros. Si una parcela no tiene vecinos, ℓ_i es la media de su régimen calculada solo con las parcelas de entrenamiento del fold. Al calcularlo para una parcela de entrenamiento la excluimos a ella misma, tanto de los vecinos como de esa media, para que su etiqueta no entre en su propia variable.

El rezago de una parcela de prueba solo usa rendimientos del entrenamiento. Lo ilustramos con un fold de la validación que tiene 110 parcelas de entrenamiento y 28 de prueba. La parcela de prueba AGC_073, del régimen A, tiene tres vecinos de entrenamiento a menos de 400 m. Están a 38, 112 y 195 m y rindieron 4.60, 4.67 y 3.81 t/ha. Su rezago es 4.515, y el rendimiento declarado de la propia AGC_073 (4.30) no interviene. La parcela AGC_002 tiene un único vecino a menos de 400 m, pero ese vecino también está en el fold de prueba, así que no se usa. Sin vecinos, AGC_002 recibe 4.5201, la media del régimen A de las 110 parcelas de entrenamiento del fold y no la de las 138. Una prueba automatizada comprueba esta propiedad. Altera las etiquetas de las parcelas de prueba y verifica que el rezago y las predicciones no cambian. En la validación, 53 % de las parcelas de prueba no tiene vecino a 400 m en el entrenamiento del fold.

Elección del radio. El radio equilibra dos efectos (Fig. 4). Con un radio chico casi ninguna parcela tiene vecinos, solo el 25 % a 250 m, y el rezago no aporta. Con un radio grande todas los tienen, pero el promedio mezcla parcelas que ya no se parecen y el error sube por encima de la media por régimen. A 400 m la mitad de las parcelas tiene vecino y el error es el más bajo.

Otras dos decisiones. Limitamos los vecinos al mismo régimen porque sus etiquetas se miden distinto. Como los dos regímenes están en zonas separadas, a 400 m el resultado es idéntico con o sin esa restricción, y la conservamos como protección. Además, el modelo ve solo el valor del rezago y no el número de vecinos ni la distancia al más cercano. Esas dos columnas extra agregaban ruido, y quitarlas bajó el RMSE de 0.478 a 0.470. Con ese cambio el rezago ganó en 9 de 10 repeticiones, y fue la primera versión del rezago que lo logró.

Prueba de permutación del rezago. Para saber si la posición de los vecinos aporta, revolvimos las coordenadas de las parcelas dentro de cada régimen y dejamos intactos el régimen y el rendimiento. Después recalculamos el rezago y repetimos la validación, con 50 permutaciones y 3 repeticiones cada una. Esta prueba destruye a propósito la estructura espacial. Si el rezago solo captara el nivel del régimen, el modelo con coordenadas revueltas predeciría igual de bien. Ninguna de las 50 permutaciones igualó el error real, lo que da $p = 0.02$, el valor más pequeño posible con 50 sorteos. Con 200 permutaciones obtuvimos $p = 0.01$ al revolver dentro del régimen y $p = 0.005$ al revolver dentro del municipio. Con 50 permutaciones dentro del municipio el resultado sigue siendo $p = 0.02$. La prueba muestra que la posición de los vecinos contiene información sobre el rendimiento además del régimen. No demuestra por sí sola que esta versión del rezago sea mejor que otras, para eso usamos la comparación entre repeticiones.

C. Variables satelitales, de clima y de topografía

Sobre el modelo con régimen y rezago probamos cada bloque de variables por separado (Fig. 5). Ninguno cumplió la regla. El que más se acercó fue la heterogeneidad del NDVI dentro de la parcela, que ganó en 7 de 10 repeticiones por 0.002 t/ha, pero al revolver sus valores el modelo predijo igual

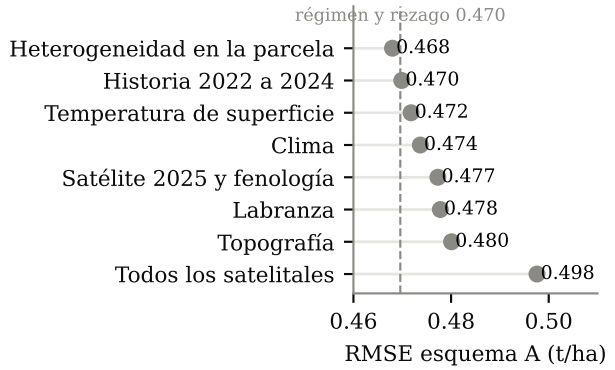


Figura 5. RMSE al agregar cada bloque al modelo con régimen y rezago (línea punteada). Ninguno mejora de forma que pase la regla de decisión.

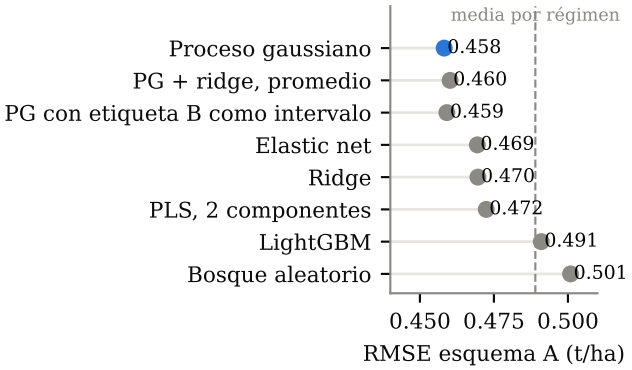


Figura 6. RMSE de cada algoritmo con régimen y rezago. En gris, las alternativas. Las dos filas debajo del proceso gaussiano (PG) son variantes que lo combinan con otras ideas.

($p = 0.63$). Juntar todos los bloques satelitales empeoró el error a 0.498, porque con 138 parcelas el modelo empieza a aprender ruido. El clima viene en celdas de unos 5 km [4], [5], así que solo distingue zonas, y eso ya lo hacen el régimen y los vecinos. También empeoró el esquema B hasta 0.540. Por estas razones el modelo final no usa estas variables.

D. Algoritmo

Con las entradas fijas, régimen y rezago, comparamos algoritmos (Fig. 6). Los modelos de árboles, bosque aleatorio y LightGBM, quedan peor que la media por régimen. Con solo tres entradas y 138 parcelas sus cortes escalonados no tienen dónde apoyarse. Los modelos lineales, ridge, elastic net y PLS, quedan alrededor de 0.470. El proceso gaussiano logra el menor error, 0.458, y gana al ridge en 9 de 10 repeticiones.

Elegimos el proceso gaussiano por tres razones además de su error. Primero, puede ajustar una relación suave y no lineal entre el rezago y el rendimiento, mientras que un modelo lineal supone que cada t/ha de los vecinos pesa igual en todo el rango. Segundo, tiene pocos parámetros, tres en el kernel, que se ajustan con las propias parcelas, lo que busca limitar el sobreajuste con muestras chicas. No lo damos por hecho y mostramos evidencia de estabilidad. El RMSE por repetición va de 0.442 a 0.503, con desviación estándar de 0.018, y el proceso gaussiano gana a la media por régimen en 9 de 10 repeticiones. Con otras cinco semillas de partición el promedio va de 0.452 a 0.468. Calculando el rezago sin la propia parcela, el error en el entrenamiento de cada fold es 0.434 y el error en su fold de prueba es 0.450, una brecha de 0.016 t/ha. Tercero, su término de ruido absorbe parte del ruido de las etiquetas declaradas. Los procesos gaussianos ya se han usado para predecir rendimiento con datos satelitales [19].

Debemos matizar la ventaja del proceso gaussiano. Frente a un modelo lineal con las mismas entradas, la diferencia de RMSE es de -0.012 t/ha (intervalo de confianza del 95 % de -0.039 a $+0.015$, $p = 0.38$), así que no lo supera de forma significativa. Su ventaja clara es sobre los modelos de árboles.

Ideas que no mejoraron al proceso gaussiano. Promediarlo con un ridge (0.460) no ayudó, porque ambos usan la misma información. Tratar la etiqueta del régimen B como un intervalo de ± 0.25 t/ha para reflejar el redondeo tampoco (0.459). Ponderar las parcelas por su área o usar una pérdida robusta de Huber mejoró menos de 0.004 t/ha a un ridge, sin superar al proceso gaussiano.

V. Modelo final

A. Arquitectura

El modelo recibe tres entradas por parcela, el régimen codificado en dos columnas indicadoras (A o B) y el rezago espacial estandarizado. Un proceso gaussiano [20] predice el rendimiento suponiendo que parcelas con entradas parecidas tienen rendimientos parecidos. Qué tan parecidas lo define la covarianza

$$k(\mathbf{x}, \mathbf{x}') = \sigma_f^2 \exp\left(-\frac{\|\mathbf{x} - \mathbf{x}'\|^2}{2\lambda^2}\right) + \sigma_n^2\, \delta_{\mathbf{x}\mathbf{x}'}, \qquad (2)$$

donde λ es la distancia a la que dos parcelas dejan de parecerse, σ_f^2 la variación que explica el modelo y σ_n^2 el ruido que no explica. Los tres se ajustan maximizando la verosimilitud. Dentro de la validación se reajustan en cada fold usando solo las parcelas de entrenamiento de ese fold. En los 50 folds de validación varían entre 0.51 y 1.41 para σ_f^2, entre 0.87 y 2.62 para λ y entre 0.21 y 0.35 para σ_n^2, sin tocar las cotas permitidas. El modelo final, que se entrega para predecir las 59 parcelas, se ajusta con las 138 parcelas y queda con $\sigma_f^2 = 0.77$, $\lambda = 1.57$ y $\sigma_n^2 = 0.26$, en unidades del rendimiento estandarizado. Es decir, el modelo atribuye cerca de una cuarta parte de la variación a ruido. Lo que sí elegimos viendo las 138 parcelas es la estructura del modelo, como el radio de 400 m, los 10 vecinos y el algoritmo. El costo de esa elección lo mide la validación anidada de la Sección VI.

B. Error de predicción

En el esquema A el modelo obtiene un RMSE de 0.458 t/ha, un error absoluto medio de 0.312 y un R^2 de 0.71. Mejora a la media por régimen en los dos regímenes, de 0.535 a 0.494 en el A y de 0.398 a 0.389 en el B. En el esquema B empata

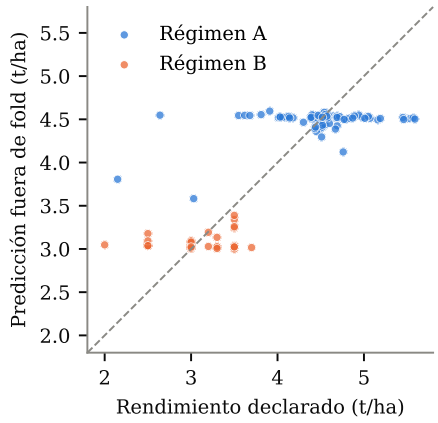


Figura 7. Rendimiento declarado contra predicción fuera de fold, promedio de las 10 repeticiones. La línea punteada es la predicción perfecta.

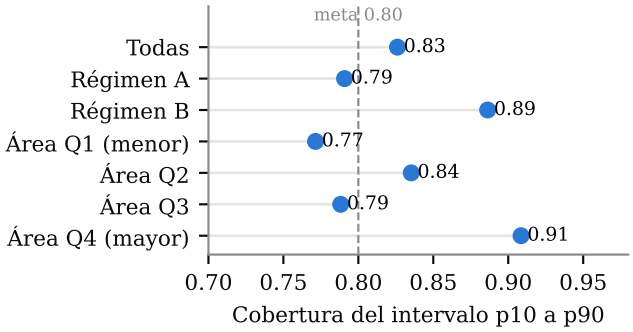


Figura 8. Fracción de parcelas cuyo rendimiento cae dentro de su intervalo p10 a p90, por régimen y por cuartil de área. La meta es 0.80.

con ella (0.489), como se espera, porque sin vecinos cercanos el rezago se convierte en la media del régimen.

La Fig. 7 muestra la limitación principal. Las predicciones forman dos franjas, una por régimen, y dentro de cada una varían poco. Su desviación es cerca de 0.4 veces la de las etiquetas. El modelo acierta el nivel del régimen y corrige con los vecinos, pero las parcelas con rendimientos extremos, como las de 5.5 t/ha en Chignahuapan, quedan cerca de la media. No forzamos más dispersión, porque sin información que la respalde subiría el error.

C. Intervalos de predicción

Para FIRA, que evalúa crédito, importa también cuánto puede fallar cada predicción. Cada parcela recibe un intervalo del percentil 10 al 90 calculado con predicción conformal dividida [21], [22], en su variante de Mondrian, que calibra por separado en cada grupo, aquí cada régimen [21]. El método tiene tres pasos. Primero, guardamos los errores con signo $r = y - \hat{y}$ de las predicciones fuera de fold, es decir, de parcelas que el modelo no vio, en las 10 repeticiones de la validación cruzada. Son 1380 errores, 870 del régimen A y 510 del B. Segundo, para cada régimen calculamos los cuantiles 0.10 y 0.90 de sus errores. En el A valen -0.51 y $+0.57$, y en el B -0.55 y $+0.48$ t/ha. Tercero, el intervalo de una parcela es p10 igual a la predicción más el cuantil 0.10 de su régimen, y p90 igual a la predicción más el cuantil 0.90. Como los cuantiles tienen signo, el intervalo no es simétrico. Los 1380 errores son 138 parcelas repetidas 10 veces, así que la calibración equivale a 87 parcelas en el A y 51 en el B. Con los mismos errores estimamos la probabilidad de que el rendimiento quede por debajo de 2.5 t/ha.

Para medir si el intervalo cumple, usamos validación anidada, en la que la parcela evaluada no participa ni en el ajuste ni en la calibración (Fig. 8). La cobertura total es 0.826, que son 570 aciertos en 690 evaluaciones (138 parcelas por 5 repeticiones), con un ancho medio de 1.13 t/ha. Como cada parcela se evalúa cinco veces, calculamos el intervalo

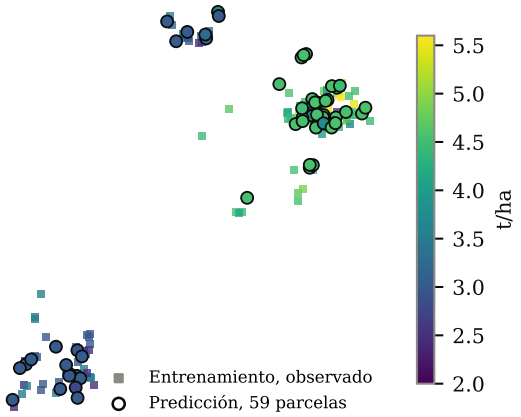


Figura 9. Rendimiento observado en las parcelas de entrenamiento (cuadros) y predicho en las 59 parcelas (círculos con borde), con la misma escala de color. Los grupos en tonos oscuros, al oeste, son del régimen B.

de confianza del 95 % con un bootstrap por parcela y resulta de 0.765 a 0.883, que incluye la meta de 0.80. Por régimen la cobertura es 0.791 en el A (intervalo de 0.708 a 0.869) y 0.886 en el B (de 0.816 a 0.949). En el cuartil de parcelas más chicas es 0.77 (de 0.63 a 0.90). Con 35 parcelas por cuartil, esta diferencia no es concluyente y la tratamos solo como una observación exploratoria.

D. Predicciones de las 59 parcelas

El Cuadro III del apéndice lista las 59 predicciones con sus intervalos. Las 37 parcelas del régimen A tienen una predicción media de 4.49 t/ha (de 3.72 a 4.58) y las 22 del B de 3.06 t/ha (de 2.75 a 3.66), igual que las medias de entrenamiento (Fig. 9). Ninguna sale del rango observado en su régimen. La probabilidad de quedar bajo 2.5 t/ha supera 0.10 en 18 parcelas, todas del régimen B.

VI. Qué tan confiable es el error

Un RMSE de validación cruzada no es todavía el error que tendremos en las 59 parcelas. Revisamos cuatro cosas.

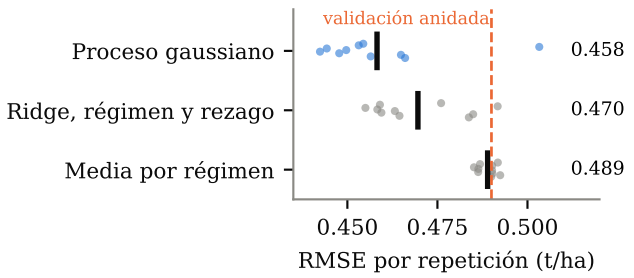


Figura 10. RMSE de cada repetición del esquema A (puntos) y su promedio (barra). La línea naranja es el error estimado con validación anidada.

¿La mejora es real o es azar? La Fig. 10 muestra el RMSE de cada una de las 10 repeticiones. El proceso gaussiano gana a la media por régimen y al ridge en 9 de 10. Pero las repeticiones usan las mismas 138 parcelas, así que no son independientes y contar victorias exagera la evidencia. Con la prueba t corregida de Nadeau y Bengio [16], la diferencia entre el proceso gaussiano y la media por régimen es de -0.029 t/ha en promedio por fold, con un intervalo de confianza del 95 % de -0.079 a $+0.022$ ($p = 0.26$). Aquí la diferencia es el RMSE del proceso gaussiano menos el de la media por régimen, de modo que un valor negativo indica que el proceso gaussiano tiene el menor error. La dirección es consistente, pero el intervalo incluye al cero y con 138 parcelas la mejora no es significativa. La diferencia entre los RMSE promedio de las 10 repeticiones es 0.031, cercana a la anterior porque se calcula sobre todas las parcelas juntas y no fold por fold.

¿Cuánto infla el resultado haber elegido el mejor? Probamos decenas de variantes con las mismas particiones y nos quedamos con la mejor, lo que favorece a la que tuvo suerte en esas particiones [14]. La validación anidada lo corrige [15]. En cada fold externo repetimos la elección entre 12 variantes usando solo las parcelas de entrenamiento de ese fold, y evaluamos la elegida en el fold externo. Por eso mide el error de todo el procedimiento de elegir y ajustar, y no el de un modelo fijo. Los dos números que reportamos responden preguntas distintas, como muestra el Cuadro II. El 0.458 es el error del modelo elegido con validación cruzada repetida. El 0.490 es el error de todo el procedimiento, y coincide con el de la media por régimen porque la elección interna se repartió entre la media por régimen (6 de 15 folds), el proceso gaussiano con rezago a 400 m (6 de 15) y otras variantes (3 de 15). En esas mismas particiones externas, el proceso gaussiano fijo con rezago a 400 m obtiene 0.458 y la media por régimen 0.489. Así, la diferencia de unas 0.03 t/ha es el costo de elegir con pocas parcelas y no un empeoramiento del proceso gaussiano. Cambiando la semilla de las particiones, el proceso gaussiano obtiene entre 0.452 y 0.468.

Por eso el error esperado honesto es de 0.46 a 0.49 t/ha. El extremo inferior supone que se usa el proceso gaussiano fijo y el superior incluye el costo de elegir. Las 59 parcelas tienen algo más de vecinos que las de validación (61 % con un vecino a 400 m o menos, contra 46 %). Esto podría favorecer al extremo bajo, pero no lo demostramos.

Cuadro II
DOS MANERAS DE MEDIR EL ERROR ESPERADO, EN T/HA.

Qué se mide	RMSE
Proceso gaussiano elegido, validación cruzada repetida	0.458
Procedimiento completo de elegir entre 12 variantes, validación anidada	0.490
Proceso gaussiano fijo, particiones externas de la anidada	0.458
Media por régimen, particiones externas de la anidada	0.489

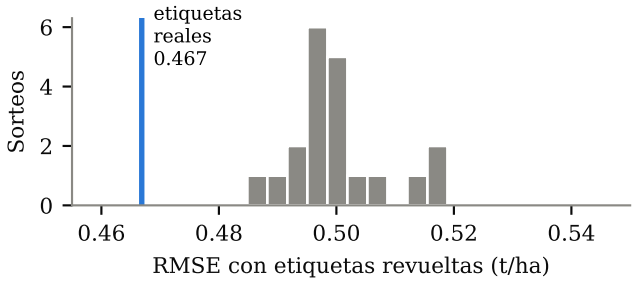


Figura 11. RMSE del modelo en 20 sorteos con los rendimientos revueltos dentro de cada régimen, contra el RMSE con los rendimientos reales.

¿Hay fuga de información? Si la etiqueta se filtrara a las variables, el modelo predeciría bien aunque las etiquetas no tuvieran sentido. Lo probamos con una reimplementación independiente del modelo, revolviendo los rendimientos dentro de cada régimen, lo que conserva el régimen pero rompe la relación con los vecinos (Fig. 11). Con las etiquetas revueltas el modelo no baja de 0.485 en 20 sorteos, y con las reales obtiene 0.467. Revolviendo entre todas las parcelas, el modelo queda en 0.867 en promedio, peor que la media global (0.855). Además, una prueba automatizada verifica que alterar las etiquetas de las parcelas de prueba no cambia sus predicciones. El rezago capta una relación real entre vecinos.

Margen por calificar con 59 parcelas. Aun con el modelo correcto, el RMSE de 59 parcelas varía según cuáles toquen. Sorteamos 5000 grupos de 37 errores del régimen A y 22 del B, como en la partición oficial (Fig. 12). Los errores se toman con reemplazo, dentro de cada régimen, de los errores fuera de fold promediados en las 10 repeticiones. Este bootstrap trata las parcelas como independientes. La dependencia espacial de los errores es débil, con una correlación de 0.14 entre parcelas del mismo régimen a 400 m o menos. Para revisarlo, repetimos el cálculo con un bootstrap por grupos de parcelas cercanas, que da un rango de 0.325 a 0.554 frente a 0.352 a 0.557 del bootstrap por parcela. Usamos este último en todo el reporte. El 90 % de los sorteos cae entre 0.35 y 0.56 t/ha, una estimación aproximada porque los errores salen de las mismas 138 parcelas. Este margen es mayor que la diferencia entre cualquiera de los modelos que comparamos.

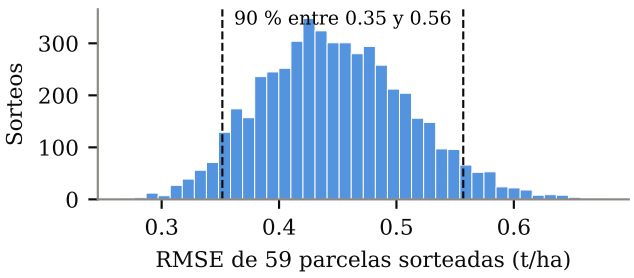


Figura 12. RMSE de 5000 grupos de 59 parcelas sorteados entre los errores fuera de fold del modelo.

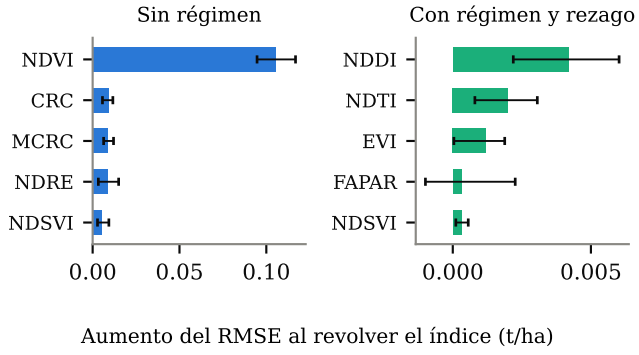


Figura 13. Aumento del RMSE al revolver cada índice, con su intervalo entre repeticiones. Nótese que las escalas horizontales son distintas.

VII. Qué aportan los índices satelitales

El reto pregunta qué índice y qué variable climática pesan más. Para responder usamos un bosque aleatorio de análisis, que aprovecha muchas variables, y medimos cuánto sube su RMSE al revolver los valores de cada índice. Lo hicimos en dos escenarios (Fig. 13).

Sin el régimen, el NDVI es por mucho el más importante. Revolverlo sube el RMSE 0.106 t/ha. Pero el NDVI histórico de cada parcela distingue las zonas y con ellas el régimen, así que en buena parte funciona como un sustituto del régimen. El modelo solo con variables satelitales llega a 0.696 t/ha, muy lejos de 0.489 de la media por régimen. Lo mismo pasa con la lluvia, que sin el régimen sube el RMSE 0.364 t/ha porque sus celdas de 5 km identifican la zona.

Con el régimen y el rezago presentes, el índice de sequía NDDI [23] es el que más aporta en el bosque aleatorio de análisis, pero solo 0.004 t/ha (de 0.002 a 0.006 entre repeticiones), y ninguna variable climática aporta. Este bosque incluye régimen, rezago y variables satelitales y su error es 0.474 t/ha. No es el modelo final, que no usa variables satelitales, así que la importancia del NDDI no se define para el proceso gaussiano final.

Una posible explicación es que el NDDI marque parcelas que sufrieron sequía, un factor que reduce el rendimiento de la cebada [24], [25]. No lo comprobamos. Su efecto es mucho menor que el margen de azar de la Sección VI. Esta es la razón de fondo por la que el modelo final no usa satélite. Con etiquetas declaradas y ruidosas, la información de las imágenes queda por debajo del ruido.

VIII. Conclusiones

El modelo final es deliberadamente simple. Usa el régimen de la etiqueta, que explica la mayor parte del error que se puede reducir, y el rendimiento de los vecinos del mismo régimen a 400 m, combinados con un proceso gaussiano. Cada pieza entró porque mejoró la validación de forma consistente y pasó una prueba de permutación, y cada pieza que se quedó fuera, como las variables satelitales y climáticas o los modelos de árboles, lo hizo porque no mejoró. El modelo obtiene un RMSE de 0.458 t/ha en validación cruzada, y estimamos un RMSE de 0.46 a 0.49 t/ha en las 59 parcelas, con un margen adicional por el tamaño de la muestra de calificación. La cota superior es el error de todo el procedimiento de elegir entre variantes y no el de un modelo fijo.

La lección principal es que en este reto el límite no lo pone el algoritmo sino las etiquetas. Con dos maneras de reportar y rendimientos declarados, la mejora sobre la media por régimen es pequeña y cualquier variable adicional compite contra el ruido. Mejores datos de campo, como el rendimiento medido o la fecha de siembra, ayudarían más que un modelo más complejo.

Apéndice A
Predicciones de las 59 parcelas

El Cuadro III lista, para cada parcela por predecir, el número de identificador (AGC_ más el número), el municipio, el régimen, la predicción en t/ha, los extremos p10 y p90 del intervalo y la probabilidad estimada de que el rendimiento sea menor que 2.5 t/ha.

Referencias

[1] Secretaría de Agricultura y Desarrollo Rural, "Del campo a la copa: el recorrido de la cebada," *gob.mx*, 11 de noviembre de 2025. [En línea]. Disponible: https://www.gob.mx/agricultura/articulos/del-campo-a-la-copa-el-recorrido-de-la-cebada

[2] M. Drusch *et al.*, "Sentinel-2: ESA's Optical High-Resolution Mission for GMES Operational Services," *Remote Sensing of Environment*, vol. 120, pp. 25–36, 2012.

[3] A. E. Frazier y B. L. Hemingway, "A Technical Review of Planet Smallsat Data: Practical Considerations for Processing and Using PlanetScope Imagery," *Remote Sensing*, vol. 13, no. 19, p. 3930, 2021.

[4] C. Funk *et al.*, "The climate hazards infrared precipitation with stations—a new environmental record for monitoring extremes," *Scientific Data*, vol. 2, art. 150066, 2015.

[5] A. Verdin *et al.*, "Development and validation of the CHIRTS-daily quasi-global high-resolution daily temperature data set," *Scientific Data*, vol. 7, no. 1, art. 303, 2020.

[6] T. van Klompenburg, A. Kassahun y C. Catal, "Crop yield prediction using machine learning: A systematic literature review," *Computers and Electronics in Agriculture*, vol. 177, p. 105709, 2020.

[7] M. Weiss, F. Jacob y G. Duveiller, "Remote sensing for agricultural applications: A meta-review," *Remote Sensing of Environment*, vol. 236, p. 111402, 2020.

[8] D. B. Lobell *et al.*, "Eyes in the Sky, Boots on the Ground: Assessing Satellite- and Ground-Based Approaches to Crop Yield Measurement and Analysis," *American Journal of Agricultural Economics*, vol. 102, no. 1, pp. 202–219, 2020.

Cuadro III
PREDICCIÓN, INTERVALO P10 A P90 (T/HA) Y PROBABILIDAD DE RENDIMIENTO MENOR QUE 2.5 T/HA DE LAS 59 PARCELAS.

ID	Municipio	R	Pred.	p10	p90	P	ID	Municipio	R	Pred.	p10	p90	P
003	Singuilucan	B	3.66	3.11	4.14	0.000	107	Almoloya	A	4.54	4.03	5.12	0.001
011	Chignahuapan	A	4.54	4.03	5.11	0.001	113	Singuilucan	B	3.25	2.70	3.73	0.031
016	Chignahuapan	A	4.57	4.06	5.14	0.001	116	Chignahuapan	A	4.54	4.03	5.12	0.001
025	Calpulalpan	B	2.98	2.43	3.46	0.225	118	Singuilucan	B	3.02	2.47	3.50	0.196
027	Calpulalpan	B	3.02	2.47	3.50	0.196	120	Nanacamilpa	B	3.02	2.47	3.50	0.196
028	Chignahuapan	A	4.54	4.03	5.12	0.001	126	Chignahuapan	A	4.57	4.06	5.14	0.001
029	Calpulalpan	B	3.02	2.47	3.50	0.196	128	Almoloya	A	4.56	4.05	5.13	0.001
030	Singuilucan	B	3.02	2.47	3.50	0.196	129	Singuilucan	B	3.02	2.47	3.50	0.196
031	Chignahuapan	A	3.88	3.37	4.45	0.023	130	Cuautepec	A	4.54	4.03	5.11	0.001
036	Chignahuapan	A	4.55	4.04	5.12	0.001	136	Chignahuapan	A	4.57	4.06	5.14	0.001
039	Calpulalpan	B	3.02	2.47	3.50	0.196	142	Chignahuapan	A	4.56	4.04	5.13	0.001
042	Singuilucan	B	3.25	2.70	3.73	0.031	143	Chignahuapan	A	4.58	4.07	5.15	0.001
043	Chignahuapan	A	4.57	4.06	5.14	0.001	147	Calpulalpan	B	3.02	2.47	3.50	0.196
050	Calpulalpan	B	3.02	2.47	3.50	0.196	149	Cuautepec	A	4.54	4.03	5.12	0.001
052	Cuautepec	A	4.56	4.05	5.14	0.001	153	Chignahuapan	A	4.54	4.03	5.11	0.001
061	Calpulalpan	B	3.02	2.47	3.50	0.196	154	Chignahuapan	A	4.58	4.07	5.15	0.001
063	Chignahuapan	A	4.54	4.03	5.11	0.001	156	Singuilucan	B	3.02	2.47	3.50	0.196
065	Almoloya	A	4.54	4.03	5.11	0.001	158	Chignahuapan	A	4.50	3.99	5.07	0.001
071	Calpulalpan	B	3.08	2.53	3.56	0.049	173	Calpulalpan	B	3.02	2.47	3.50	0.196
075	Calpulalpan	B	2.98	2.43	3.46	0.225	174	Cuautepec	A	4.54	4.03	5.11	0.001
076	Chignahuapan	A	4.54	4.03	5.11	0.001	175	Chignahuapan	A	4.58	4.07	5.15	0.001
082	Almoloya	A	4.54	4.03	5.11	0.001	177	Chignahuapan	A	3.72	3.21	4.29	0.024
085	Chignahuapan	A	3.72	3.21	4.29	0.024	182	Chignahuapan	A	4.58	4.07	5.15	0.001
086	Calpulalpan	B	3.02	2.47	3.50	0.196	183	Calpulalpan	B	3.02	2.47	3.50	0.196
087	Calpulalpan	B	2.75	2.20	3.23	0.235	186	Chignahuapan	A	4.54	4.03	5.11	0.001
088	Chignahuapan	A	4.45	3.94	5.02	0.002	188	Chignahuapan	A	4.58	4.07	5.15	0.001
091	Chignahuapan	A	4.55	4.04	5.13	0.001	190	Chignahuapan	A	4.47	3.95	5.04	0.002
093	Calpulalpan	B	2.98	2.43	3.46	0.225	191	Chignahuapan	A	4.56	4.04	5.13	0.001
094	Chignahuapan	A	4.56	4.05	5.13	0.001	192	Chignahuapan	A	4.54	4.03	5.11	0.001
095	Chignahuapan	A	4.58	4.07	5.15	0.001							

[9] J. C. Zadoks, T. T. Chang y C. F. Konzak, "A decimal code for the growth stages of cereals," *Weed Research*, vol. 14, no. 6, pp. 415–421, 1974.

[10] D. R. Roberts *et al.*, "Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure," *Ecography*, vol. 40, no. 8, pp. 913–929, 2017.

[11] P. Ploton *et al.*, "Spatial validation reveals poor predictive performance of large-scale ecological mapping models," *Nature Communications*, vol. 11, no. 1, art. 4540, 2020.

[12] M. Ojala y G. C. Garriga, "Permutation tests for studying classifier performance," *Journal of Machine Learning Research*, vol. 11, pp. 1833–1863, 2010.

[13] Y. Benjamini y Y. Hochberg, "Controlling the False Discovery Rate: A Practical and Powerful Approach to Multiple Testing," *Journal of the Royal Statistical Society Series B: Statistical Methodology*, vol. 57, no. 1, pp. 289–300, 1995.

[14] G. C. Cawley y N. L. C. Talbot, "On over-fitting in model selection and subsequent selection bias in performance evaluation," *Journal of Machine Learning Research*, vol. 11, pp. 2079–2107, 2010.

[15] S. Varma y R. Simon, "Bias in error estimation when using cross-validation for model selection," *BMC Bioinformatics*, vol. 7, art. 91, 2006.

[16] C. Nadeau e Y. Bengio, "Inference for the generalization error," *Machine Learning*, vol. 52, no. 3, pp. 239–281, 2003.

[17] S. Kaufman, S. Rosset, C. Perlich y O. Stitelman, "Leakage in data mining: Formulation, detection, and avoidance," *ACM Transactions on Knowledge Discovery from Data*, vol. 6, no. 4, art. 15, 2012.

[18] W. R. Tobler, "A computer movie simulating urban growth in the Detroit region," *Economic Geography*, vol. 46, pp. 234–240, 1970.

[19] J. You *et al.*, "Deep Gaussian Process for Crop Yield Prediction Based on Remote Sensing Data," *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 31, no. 1, 2017.

[20] C. E. Rasmussen y C. K. I. Williams, *Gaussian Processes for Machine Learning*. Cambridge, MA, EE. UU.: MIT Press, 2006.

[21] V. Vovk, A. Gammerman y G. Shafer, *Algorithmic Learning in a Random World*. Nueva York, NY, EE. UU.: Springer, 2005.

[22] J. Lei *et al.*, "Distribution-Free Predictive Inference for Regression," *Journal of the American Statistical Association*, vol. 113, no. 523, pp. 1094–1111, 2018.

[23] Y. Gu *et al.*, "A five-year analysis of MODIS NDVI and NDWI for grassland drought assessment over the central Great Plains of the United States," *Geophysical Research Letters*, vol. 34, no. 6, art. 2006GL029127, 2007.

[24] N. H. Samarah, "Effects of drought stress on growth and yield of barley," *Agronomy for Sustainable Development*, vol. 25, no. 1, pp. 145–149, 2005.

[25] V. S. Passarella, R. Savin y G. A. Slafer, "Grain weight and malting quality in barley as affected by brief periods of increased spike temperature under field conditions," *Australian Journal of Agricultural Research*, vol. 53, no. 11, pp. 1219–1227, 2002.