Benemérita Universidad Autónoma de Puebla
Facultad de Ciencias de la Computación

Reto AgroCebada FIRA 2026
Reporte técnico del modelo

Rendimiento de cebada de temporal con régimen de etiquetas y rezago espacial

Procedimiento, arquitectura y evaluación del modelo

Integrantes José Alán Pomares Valdés
Luis Emmanuel Ramiro Luna
Vicente Josimar López Martinez

Asesor Luis Gustavo Olivares Soto

Contacto pv202351433@alm.buap.mx

Puebla, Pue., 7 de octubre de 2026

***Resumen*. Estimamos el rendimiento de cebada de temporal de 59 parcelas con un proceso gaussiano que usa dos datos de cada parcela, el régimen de su etiqueta y el rendimiento de sus vecinas del mismo régimen. Las etiquetas se dividen por municipio en dos formatos con medias de 4.49 y 3.05 t/ha, y conocer el formato explica la mayor parte de lo que se puede explicar. Construimos el modelo paso a paso. Cada idea entró solo si mejoraba la validación cruzada de forma consistente y pasaba una prueba de permutación. Así quedaron fuera las variables satelitales, climáticas y topográficas, que no mejoraron la predicción una vez conocidos el régimen y los vecinos. El modelo obtiene un RMSE de 0.458 t/ha en validación cruzada, contra 0.489 de la media por régimen. Como el modelo se eligió entre muchas variantes, estimamos con validación anidada un RMSE esperado de 0.46 a 0.49 t/ha.**

***Palabras clave*. rendimiento de cebada, régimen de etiquetas, rezago espacial, proceso gaussiano, validación cruzada, predicción conformal.**

I. Introducción

El reto AgroCebada de FIRA 2026 pide estimar el rendimiento de cebada de temporal, en toneladas por hectárea (t/ha), de 59 parcelas de Hidalgo, Puebla y Tlaxcala. Para entrenar tenemos 138 parcelas del mismo ciclo de 2025 con su rendimiento declarado, imágenes de Sentinel-2 y de Planet, clima y topografía. El jurado califica primero el error de las 59 predicciones con la raíz del error cuadrático medio (RMSE), que se mide en t/ha y castiga más los errores grandes.

Este reporte explica cómo construimos el modelo y por qué tomamos cada decisión. La Fig. 1 resume el proceso. Partimos de un hallazgo en las etiquetas (Sección II), fijamos cómo íbamos a evaluar cada idea (Sección III) y agregamos piezas una por una, conservando solo las que mejoraban la validación (Sección IV). Después describimos el modelo final (Sección V), qué tan confiable es su error (Sección VI) y qué aportan los índices satelitales (Sección VII).

II. Datos y el hallazgo de los regímenes

Hay 197 parcelas en nueve municipios, 138 de entrenamiento y 59 de predicción. FIRA hizo la partición al azar y estratificada por zona, así que cada municipio con parcelas por predecir también tiene parcelas de entrenamiento. De las series de tiempo construimos 91 variables por parcela, como el máximo del NDVI en 2025, la fenología, la historia de 2022 a 2024, la heterogeneidad dentro de la parcela, el clima y la topografía. Ninguna usa el rendimiento.

Dos formas de reportar el rendimiento. Al revisar las etiquetas vimos que se dividen por municipio en dos formatos (Fig. 2). En cuatro municipios el rendimiento viene con dos decimales y promedia 4.49 t/ha. Lo llamamos régimen A. En los otros cinco todos los valores son múltiplos de 0.1 o de 0.5 y promedian 3.05 t/ha. Lo llamamos régimen B. Asignamos el régimen por el formato de la etiqueta y no por su valor. Creemos que cada régimen corresponde a una forma distinta de levantar el dato, porque FIRA confirmó que el rendimiento lo declara el productor sin validación oficial.

Este hallazgo cambia el problema. La diferencia entre las medias de los regímenes, de 1.4 t/ha, es casi tres veces la desviación estándar dentro de cada uno (0.53 t/ha en A y 0.40 en B). Además, el redondeo del régimen B agrega por sí solo un error de unas 0.14 t/ha que ningún modelo puede predecir. Por eso el régimen es la primera pieza del modelo.

III. Cómo evaluamos cada decisión

Con 138 parcelas cualquier comparación es ruidosa, así que antes de probar ideas fijamos cómo íbamos a decidir.

Error fuera de muestra. Todas las cifras de RMSE se calculan sobre parcelas que el modelo no vio al entrenar. Usamos validación cruzada, que reparte las parcelas en 5 grupos (*folds*), entrena con 4 y predice el quinto, hasta predecir todas. Todo lo que usa el rendimiento, como el rezago espacial, se recalcula dentro de cada fold para que la parcela evaluada nunca influya en su propia predicción.

Dos esquemas. El esquema A sortea los folds al azar, estratificados por municipio, y repite el sorteo 10 veces. Imita la partición oficial y es el que decide. El esquema B deja fuera zonas completas, uniendo las parcelas a menos de 2 km [1]. Mide qué tanto depende un modelo de tener vecinos en el entrenamiento.

Regla de decisión. Una idea se acepta si baja el RMSE en al menos 7 de las 10 repeticiones del esquema A y si pasa una prueba de permutación [2]. En esa prueba revolvemos al azar las variables nuevas, dentro de cada régimen, y repetimos la validación 50 veces. Si el modelo con las variables revueltas predice igual de bien, la mejora no viene de esas variables y la idea se rechaza. Exigimos $p \leq 0.05$.

Controles del resultado final. Elegir el mejor entre muchos modelos con las mismas particiones infla su resultado [3]. Por eso al final medimos el error esperado con validación anidada [4], comparamos modelos con una prueba t corregida por el traslape entre repeticiones [5] y revisamos que no hubiera fuga de información revolviendo las etiquetas [6]. Estos controles están en la Sección VI.

IV. Construcción del modelo

Agregamos las piezas en orden, de la más sencilla a la más compleja. Cada pieza tuvo que ganarle a la mejor versión aceptada hasta ese momento.

A. Punto de partida, la media por régimen

El modelo más simple predice para cada parcela la media de su grupo. La Fig. 3 compara varios grupos. La media por régimen es la mejor en ambos esquemas, con 0.489 t/ha. La media por municipio se le acerca en el esquema A (0.510), pero en el esquema B sube a 0.955 porque, al dejar zonas fuera, muchos municipios se quedan sin parcelas de entrenamiento. El régimen no tiene ese problema, porque se conoce para cualquier parcela. Por eso es la base de todo lo demás.

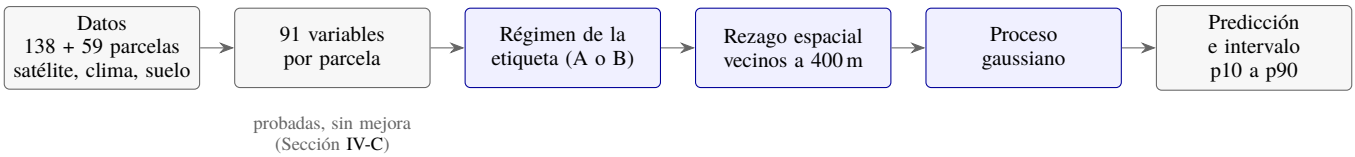


Figura 1. Arquitectura del modelo. En azul, las piezas que usa el modelo final. Las 91 variables satelitales, de clima y de topografía se probaron una por bloque y ninguna mejoró la validación.

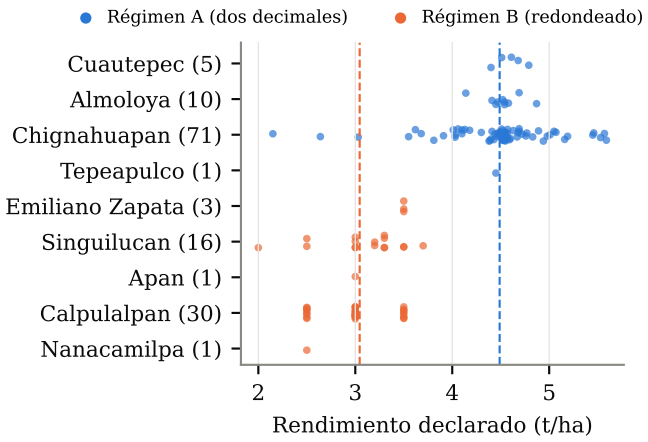


Figura 2. Rendimiento declarado de las 138 parcelas de entrenamiento por municipio, con el número de parcelas entre paréntesis. Las líneas punteadas son la media de cada régimen.

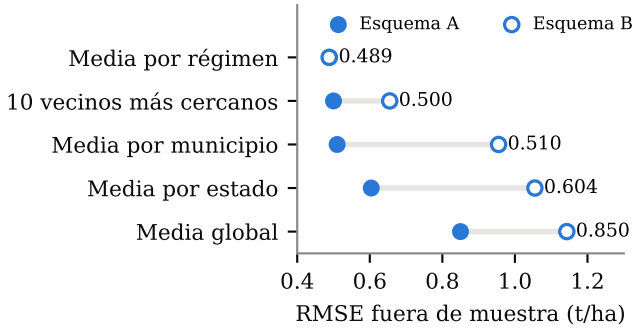


Figura 3. RMSE de modelos sencillos. El número es el esquema A. La media por régimen es la única que no empeora cuando se dejan zonas completas fuera (esquema B).

B. *Rezago espacial, lo que dicen los vecinos*

Dentro de un régimen el rendimiento todavía varía, y parcelas cercanas tienden a parecerse [7], porque comparten suelo, clima, manejo y a veces productor. Para aprovecharlo calculamos el *rezago espacial*, el promedio del rendimiento de las parcelas de entrenamiento cercanas, ponderado por el inverso de la distancia,

$$\ell_i = \frac{\sum_{j \in \mathcal{N}_i} y_j / d_{ij}}{\sum_{j \in \mathcal{N}_i} 1/d_{ij}}, \qquad (1)$$

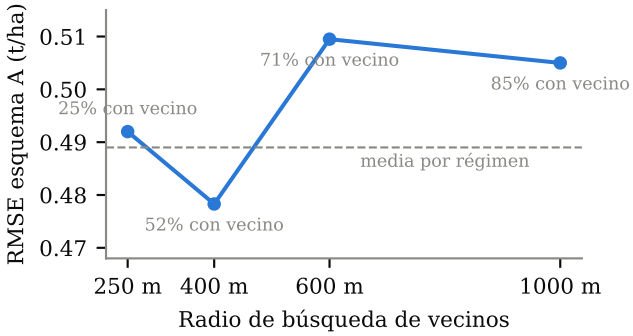


Figura 4. RMSE del modelo con régimen y rezago según el radio de búsqueda de vecinos. El texto indica qué fracción de parcelas tiene al menos un vecino del mismo régimen.

donde $\mathcal{N}_i$ son hasta 10 vecinos del mismo régimen a menos de un radio r, y_j su rendimiento y d_{ij} la distancia en metros. Si una parcela no tiene vecinos, ℓ_i es la media de su régimen. Al calcularlo para una parcela de entrenamiento la excluimos a ella misma, tanto de los vecinos como de esa media, para que su etiqueta no entre en su propia variable.

Elección del radio. El radio equilibra dos efectos (Fig. 4). Con un radio chico casi ninguna parcela tiene vecinos, solo el 25 % a 250 m, y el rezago no aporta. Con un radio grande todas los tienen, pero el promedio mezcla parcelas que ya no se parecen y el error sube por encima de la media por régimen. A 400 m la mitad de las parcelas tiene vecino y el error es el más bajo.

Otras dos decisiones. Limitamos los vecinos al mismo régimen porque sus etiquetas se miden distinto. Como los dos regímenes están en zonas separadas, a 400 m el resultado es idéntico con o sin esa restricción, y la conservamos como protección. Además, el modelo ve solo el valor del rezago y no el número de vecinos ni la distancia al más cercano. Esas dos columnas extra agregaban ruido, y quitarlas bajó el RMSE de 0.478 a 0.470. Con ese cambio el rezago ganó en 9 de 10 repeticiones y pasó la prueba de permutación ($p = 0.02$). Fue la primera mejora aceptada.

C. *Variables satelitales, de clima y de topografía*

Sobre el modelo con régimen y rezago probamos cada bloque de variables por separado (Fig. 5). Ninguno cumplió la regla. El que más se acercó fue la heterogeneidad del NDVI dentro de la parcela, que ganó en 7 de 10 repeticiones por 0.002 t/ha, pero al revolver sus valores el modelo predijo igual

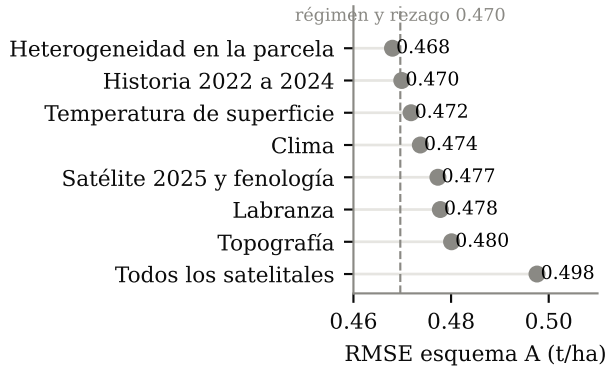


Figura 5. RMSE al agregar cada bloque al modelo con régimen y rezago (línea punteada). Ninguno mejora de forma que pase la regla de decisión.

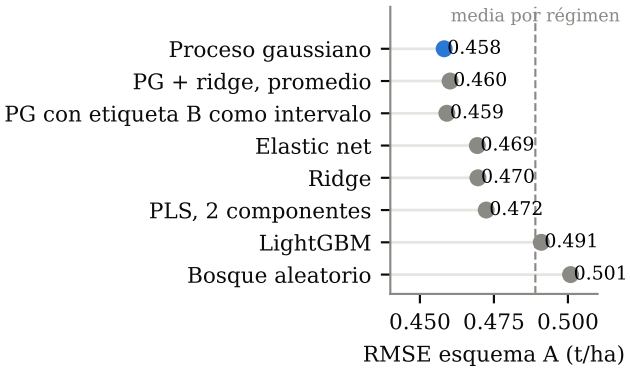


Figura 6. RMSE de cada algoritmo con régimen y rezago. En gris, las alternativas. Las dos filas debajo del proceso gaussiano (PG) son variantes que lo combinan con otras ideas.

($p = 0.63$). Juntar todos los bloques satelitales empeoró el error a 0.498, porque con 138 parcelas el modelo empieza a aprender ruido. El clima viene en celdas de unos 5 km, así que solo distingue zonas, y eso ya lo hacen el régimen y los vecinos. También empeoró el esquema B hasta 0.540. Por estas razones el modelo final no usa estas variables.

D. Algoritmo

Con las entradas fijas, régimen y rezago, comparamos algoritmos (Fig. 6). Los modelos de árboles, bosque aleatorio y LightGBM, quedan peor que la media por régimen. Con solo tres entradas y 138 parcelas sus cortes escalonados no tienen dónde apoyarse. Los modelos lineales, ridge, elastic net y PLS, quedan alrededor de 0.470. El proceso gaussiano logra el menor error, 0.458, y gana al ridge en 9 de 10 repeticiones.

Elegimos el proceso gaussiano por tres razones además de su error. Primero, puede ajustar una relación suave y no lineal entre el rezago y el rendimiento, mientras que un modelo lineal supone que cada t/ha de los vecinos pesa igual en todo el rango. Segundo, tiene pocos parámetros, que se ajustan con las propias parcelas, así que se sobreajusta poco con muestras chicas. Tercero, su término de ruido absorbe parte del ruido de las etiquetas declaradas.

Ideas que no mejoraron al proceso gaussiano. Promediarlo con un ridge (0.460) no ayudó, porque ambos usan la misma información. Tratar la etiqueta del régimen B como un intervalo de ± 0.25 t/ha para reflejar el redondeo tampoco (0.459). Ponderar las parcelas por su área o usar una pérdida robusta de Huber mejoró menos de 0.004 t/ha a un ridge, sin superar al proceso gaussiano.

V. Modelo final

A. Arquitectura

El modelo recibe tres entradas por parcela, el régimen codificado en dos columnas indicadoras (A o B) y el rezago espacial estandarizado. Un proceso gaussiano [8] predice el rendimiento suponiendo que parcelas con entradas parecidas tienen rendimientos parecidos. Qué tan parecidas lo define la covarianza

$$k(\mathbf{x}, \mathbf{x}') = \sigma_f^2 \exp\left(-\frac{\|\mathbf{x} - \mathbf{x}'\|^2}{2\lambda^2}\right) + \sigma_n^2\, \delta_{\mathbf{x}\mathbf{x}'}, \qquad (2)$$

donde λ es la distancia a la que dos parcelas dejan de parecerse, σ_f^2 la variación que explica el modelo y σ_n^2 el ruido que no explica. Los tres se ajustan con las 138 parcelas maximizando la verosimilitud. Quedan $\sigma_f^2 = 0.77$, $\lambda = 1.57$ y $\sigma_n^2 = 0.26$, en unidades del rendimiento estandarizado. Es decir, el modelo atribuye cerca de una cuarta parte de la variación a ruido.

B. Error de predicción

En el esquema A el modelo obtiene un RMSE de 0.458 t/ha, un error absoluto medio de 0.312 y un R^2 de 0.71. Mejora a la media por régimen en los dos regímenes, de 0.535 a 0.494 en el A y de 0.398 a 0.389 en el B. En el esquema B empata con ella (0.489), como se espera, porque sin vecinos cercanos el rezago se convierte en la media del régimen.

La Fig. 7 muestra la limitación principal. Las predicciones forman dos franjas, una por régimen, y dentro de cada una varían poco. Su desviación es cerca de 0.4 veces la de las etiquetas. El modelo acierta el nivel del régimen y corrige con los vecinos, pero las parcelas con rendimientos extremos, como las de 5.5 t/ha en Chignahuapan, quedan cerca de la media. No forzamos más dispersión, porque sin información que la respalde subiría el error.

C. Intervalos de predicción

Para FIRA, que evalúa crédito, importa también cuánto puede fallar cada predicción. Cada parcela recibe un intervalo del percentil 10 al 90 calculado con predicción conformal [9]. Guardamos los errores del modelo en parcelas que no vio, por separado en cada régimen, y sumamos sus percentiles 10 y 90 a la predicción. Separamos por régimen porque los errores del B son menores. Con los mismos errores estimamos la probabilidad de que el rendimiento quede por debajo de 2.5 t/ha.

Para medir si el intervalo cumple, usamos validación anidada, en la que la parcela evaluada no participa ni en

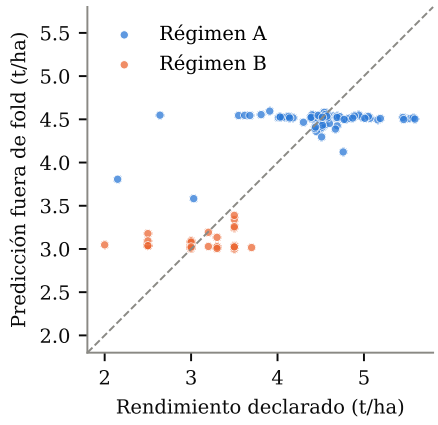


Figura 7. Rendimiento declarado contra predicción fuera de fold, promedio de las 10 repeticiones. La línea punteada es la predicción perfecta.

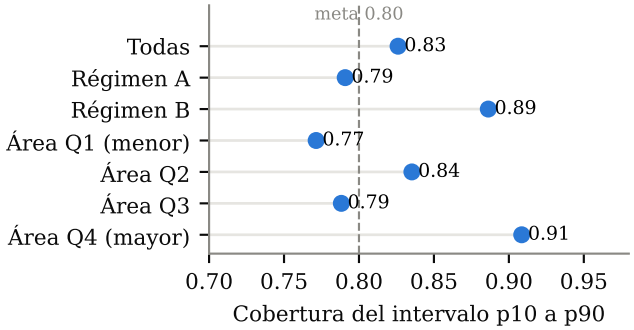


Figura 8. Fracción de parcelas cuyo rendimiento cae dentro de su intervalo p10 a p90, por régimen y por cuartil de área. La meta es 0.80.

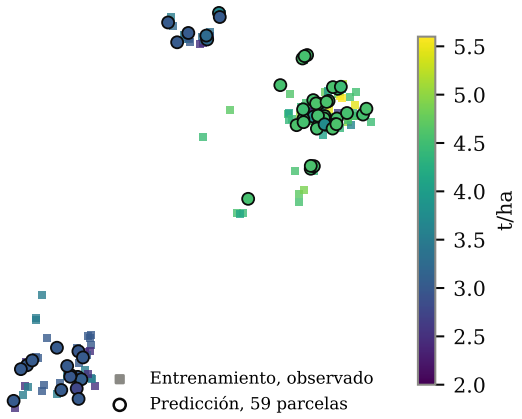


Figura 9. Rendimiento observado en las parcelas de entrenamiento (cuadros) y predicho en las 59 parcelas (círculos con borde), con la misma escala de color. Los grupos en tonos oscuros, al oeste, son del régimen B.

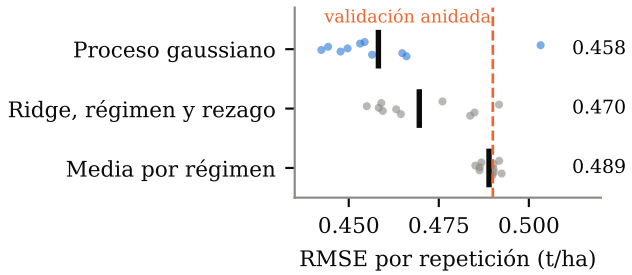


Figura 10. RMSE de cada repetición del esquema A (puntos) y su promedio (barra). La línea naranja es el error estimado con validación anidada.

el ajuste ni en la calibración (Fig. 8). La cobertura total es 0.83, cerca de la meta de 0.80, con un ancho medio de 1.13 t/ha. Las parcelas más chicas quedan algo menos cubiertas (0.77), probablemente porque su rendimiento declarado es más ruidoso.

D. Predicciones de las 59 parcelas

Las 37 parcelas del régimen A tienen una predicción media de 4.49 t/ha (de 3.72 a 4.58) y las 22 del B de 3.06 t/ha (de 2.75 a 3.66), igual que las medias de entrenamiento (Fig. 9). Ninguna sale del rango observado en su régimen. La probabilidad de quedar bajo 2.5 t/ha supera 0.10 en 18 parcelas, todas del régimen B.

VI. Qué tan confiable es el error

Un RMSE de validación cruzada no es todavía el error que tendremos en las 59 parcelas. Revisamos tres cosas.

¿La mejora es real o es azar? La Fig. 10 muestra el RMSE de cada una de las 10 repeticiones. El proceso gaussiano gana a la media por régimen y al ridge en 9 de 10. Pero las repeticiones usan las mismas 138 parcelas, así que no son independientes y contar victorias exagera la evidencia. Con la prueba t corregida de Nadeau y Bengio [5], la ventaja sobre la media por régimen es de 0.029 t/ha, con un intervalo de confianza del 95 % de -0.079 a 0.022 ($p = 0.26$). La dirección es consistente, pero con 138 parcelas la mejora no alcanza a ser significativa.

¿Cuánto infla el resultado haber elegido el mejor? Probamos decenas de variantes con las mismas particiones y nos quedamos con la mejor, lo que favorece a la que tuvo suerte en esas particiones [3]. La validación anidada lo corrige [4]. En cada fold externo repetimos la elección entre 12 variantes usando solo las parcelas de entrenamiento, y evaluamos la elegida en el fold externo. El resultado es 0.490 t/ha, igual que la media por régimen. La elección interna se repartió entre la media por régimen (6 de 15 folds) y el proceso gaussiano con rezago a 400 m (6 de 15). Cambiando la semilla de las particiones, el proceso gaussiano obtiene entre 0.452 y 0.468. Por eso esperamos un RMSE de 0.46 a 0.49 t/ha. Las 59 parcelas tienen algo más de vecinos que las de validación (61 % con un vecino a 400 m o menos, contra 46 %), así que el extremo bajo es plausible.

¿Hay fuga de información? Si la etiqueta se filtrara a las variables, el modelo predeciría bien aunque las etiquetas no

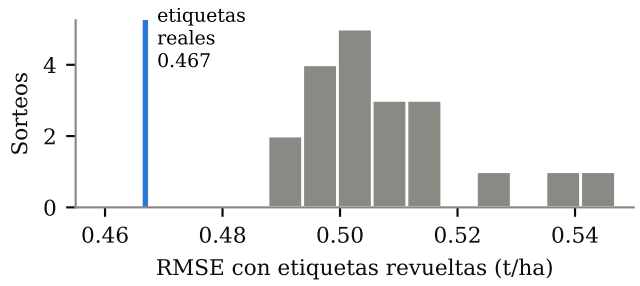


Figura 11. RMSE del modelo en 20 sorteos con los rendimientos revueltos dentro de cada régimen, contra el RMSE con los rendimientos reales.

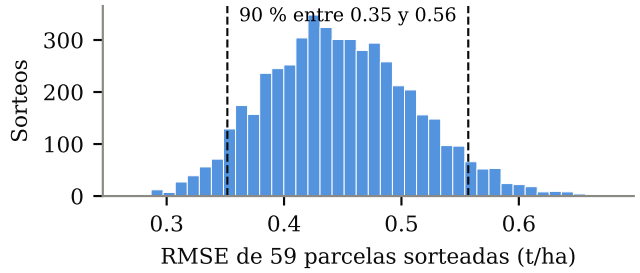


Figura 12. RMSE de 5000 grupos de 59 parcelas sorteados entre los errores fuera de fold del modelo.

tuvieran sentido. Lo probamos revolviendo los rendimientos dentro de cada régimen, lo que conserva el régimen pero rompe la relación con los vecinos (Fig. 11). Con las etiquetas revueltas el modelo nunca baja de 0.488, y con las reales obtiene 0.467 en las mismas condiciones. Revolviendo entre todas las parcelas, el modelo queda en 0.861, peor que la media global (0.855). El rezago capta una relación real entre vecinos.

Margen por calificar con 59 parcelas. Aun con el modelo correcto, el RMSE de 59 parcelas varía según cuáles toquen. Sorteamos 5000 grupos de 37 errores del régimen A y 22 del B, como en la partición oficial (Fig. 12). El 90 % de los sorteos cae entre 0.35 y 0.56 t/ha. Este margen es mayor que la diferencia entre cualquiera de los modelos que comparamos.

VII. Qué aportan los índices satelitales

El reto pregunta qué índice y qué variable climática pesan más. Para responder usamos un bosque aleatorio de análisis, que aprovecha muchas variables, y medimos cuánto sube su RMSE al revolver los valores de cada índice. Lo hicimos en dos escenarios (Fig. 13).

Sin el régimen, el NDVI es por mucho el más importante. Revolverlo sube el RMSE 0.106 t/ha. Pero el NDVI histórico de cada parcela distingue las zonas y con ellas el régimen, así que en buena parte funciona como un sustituto del régimen. El modelo solo con variables satelitales llega a 0.696 t/ha, muy lejos de 0.489 de la media por régimen. Lo mismo pasa con la lluvia, que sin el régimen sube el RMSE 0.364 t/ha porque sus celdas de 5 km identifican la zona.

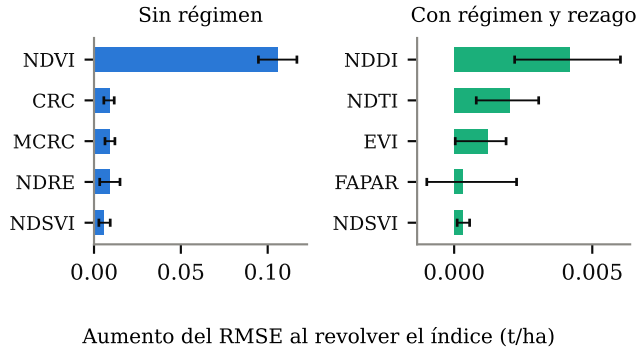


Figura 13. Aumento del RMSE al revolver cada índice, con su intervalo entre repeticiones. Nótese que las escalas horizontales son distintas.

Con el régimen y el rezago presentes, el índice de sequía NDDI es el que más aporta, pero solo 0.004 t/ha, y ninguna variable climática aporta. Es plausible que el NDDI importe, porque marca las parcelas que se secaron o se acamaron antes en un año muy lluvioso. Aun así, su efecto es mucho menor que el margen de azar de la Sección VI. Esta es la razón de fondo por la que el modelo final no usa satélite. Con etiquetas declaradas y ruidosas, la información de las imágenes queda por debajo del ruido.

VIII. Conclusiones

El modelo final es deliberadamente simple. Usa el régimen de la etiqueta, que explica la mayor parte del error que se puede reducir, y el rendimiento de los vecinos del mismo régimen a 400 m, combinados con un proceso gaussiano. Cada pieza entró porque mejoró la validación de forma consistente y pasó una prueba de permutación, y cada pieza que se quedó fuera, como las variables satelitales y climáticas o los modelos de árboles, lo hizo porque no mejoró. El modelo obtiene 0.458 t/ha en validación cruzada, y estimamos un RMSE de 0.46 a 0.49 t/ha en las 59 parcelas, con un margen adicional por el tamaño de la muestra de calificación.

La lección principal es que en este reto el límite no lo pone el algoritmo sino las etiquetas. Con dos formas de reportar y rendimientos declarados, la mejora sobre la media por régimen es pequeña y cualquier variable adicional compite contra el ruido. Mejores datos de campo, como el rendimiento medido o la fecha de siembra, ayudarían más que un modelo más complejo.

Referencias

[1] D. R. Roberts *et al.*, “Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure,” *Ecography*, vol. 40, no. 8, pp. 913–929, 2017.

[2] M. Ojala y G. C. Garriga, “Permutation tests for studying classifier performance,” *Journal of Machine Learning Research*, vol. 11, pp. 1833–1863, 2010.

[3] G. C. Cawley y N. L. C. Talbot, “On over-fitting in model selection and subsequent selection bias in performance evaluation,” *Journal of Machine Learning Research*, vol. 11, pp. 2079–2107, 2010.

[4] S. Varma y R. Simon, “Bias in error estimation when using cross-validation for model selection,” *BMC Bioinformatics*, vol. 7, art. 91, 2006.

[5] C. Nadeau e Y. Bengio, “Inference for the generalization error,” *Machine Learning*, vol. 52, no. 3, pp. 239–281, 2003.
[6] S. Kaufman, S. Rosset, C. Perlich y O. Stitelman, “Leakage in data mining: Formulation, detection, and avoidance,” *ACM Transactions on Knowledge Discovery from Data*, vol. 6, no. 4, art. 15, 2012.
[7] W. R. Tobler, “A computer movie simulating urban growth in the Detroit region,” *Economic Geography*, vol. 46, pp. 234–240, 1970.
[8] C. E. Rasmussen y C. K. I. Williams, *Gaussian Processes for Machine Learning*. Cambridge, MA, EE. UU.: MIT Press, 2006.
[9] V. Vovk, A. Gammerman y G. Shafer, *Algorithmic Learning in a Random World*. Nueva York, NY, EE. UU.: Springer, 2005.