Anexo técnico. Rendimiento de cebada de temporal con régimen de registro y rezago espacial

José Alán Pomares Valdés
Facultad de Ciencias de la Computación
Benemérita Universidad Autónoma de Puebla
Puebla, México
pv202351433@alm.buap.mx

Vicente Josimar López Martínez
Facultad de Ciencias de la Computación
Benemérita Universidad Autónoma de Puebla
Puebla, México

Luis Emmanuel Ramiro Luna
Facultad de Ciencias de la Computación
Benemérita Universidad Autónoma de Puebla
Puebla, México

Luis Gustavo Olivares Soto (asesor)
Facultad de Ciencias de la Computación
Benemérita Universidad Autónoma de Puebla
Puebla, México

***Resumen*—Este anexo del equipo Los Bien Dotados complementa la metodología del reporte técnico con las figuras, ecuaciones y tablas que sustentan cada decisión del modelo. Estimamos el rendimiento de 59 parcelas con un proceso gaussiano que usa el régimen de registro del municipio y el rendimiento de las parcelas vecinas del mismo régimen. Su raíz del error cuadrático medio (RMSE) en validación cruzada es 0.458 t/ha y esperamos de 0.46 a 0.49 t/ha en las 59 parcelas. Las citas remiten a la bibliografía entregada.**

***Palabras clave*—rendimiento de cebada, régimen de registro, rezago espacial, proceso gaussiano, predicción conformal, crédito agrícola.**

I. Dos formas de registrar el rendimiento

Cada municipio registra el rendimiento de una sola forma (Fig. 1). En el régimen A los valores tienen dos decimales y promedian 4.49 t/ha. En el B tienen un decimal y promedian 3.05 t/ha. La diferencia entre medias, 1.4 t/ha, es casi tres veces la desviación estándar dentro de cada régimen. Por eso el régimen es la primera pieza del modelo. No sabemos si el rendimiento se midió distinto o solo se anotó distinto, así que lo tratamos como una observación por municipio.

El régimen supera a cualquier agrupación geográfica. La Fig. 2 compara medias por grupo. La media por municipio se acerca a la del régimen cuando hay parcelas de entrenamiento cerca (esquema A), pero cuando la validación deja fuera zonas completas (esquema B) sube a 0.955 t/ha. El régimen se conoce para toda parcela y no tiene ese problema.

II. Modelo

Rezago espacial. Parcelas cercanas tienden a rendir parecido [16]. El rezago de la parcela i es

$$\ell_i = \frac{\sum_{j \in \mathcal{N}_i} y_j / d_{ij}}{\sum_{j \in \mathcal{N}_i} 1/d_{ij}}, \tag{1}$$

donde $\mathcal{N}_i$ son hasta 10 parcelas de entrenamiento del mismo régimen a 400 m o menos, y_j su rendimiento y d_{ij} la distancia. Sin vecinos, ℓ_i es la media del régimen en el entrenamiento.

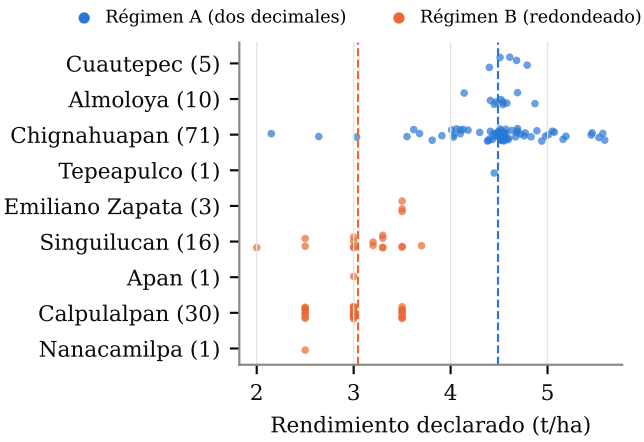


Fig. 1. Rendimiento de las 138 parcelas de entrenamiento por municipio. Cada municipio cae en un solo régimen. Las líneas punteadas son la media de cada régimen.

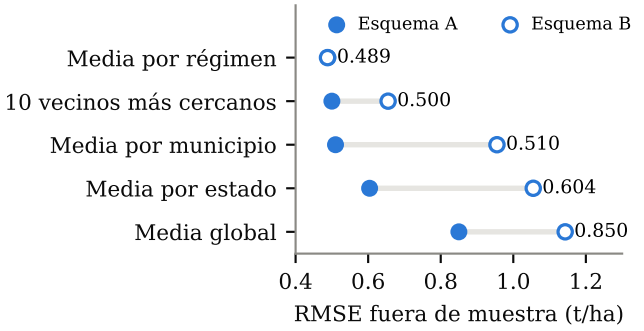


Fig. 2. RMSE de modelos sencillos en los dos esquemas de validación. La media por régimen es la única que no empeora cuando se dejan zonas completas fuera.

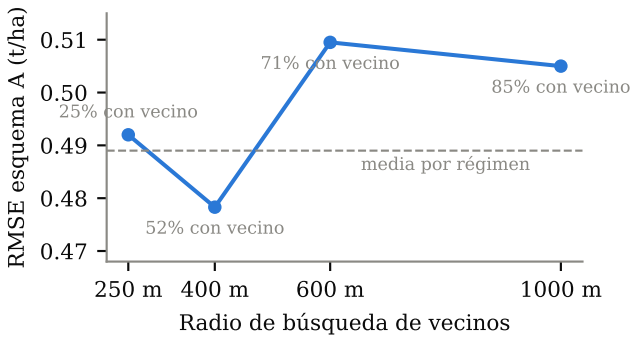


Fig. 3. RMSE según el radio de búsqueda de vecinos, con la fracción de parcelas que tiene al menos un vecino. Con radios chicos casi nadie tiene vecinos y con radios grandes el promedio mezcla parcelas que ya no se parecen.

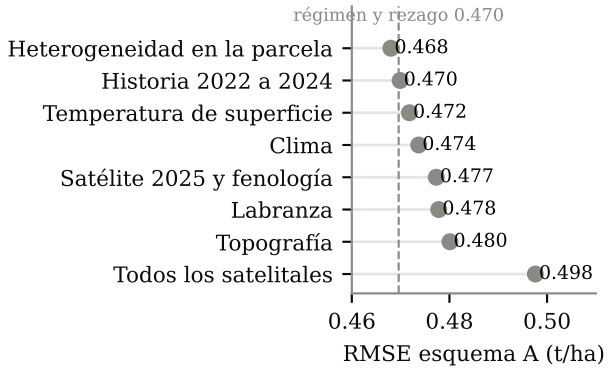


Fig. 4. RMSE al agregar cada bloque de variables al modelo con régimen y rezago (línea punteada). Ninguno mejora de forma que pase la regla de decisión, y juntar todos los satelitales empeora el error.

La parcela evaluada nunca entra en su propio rezago. Elegimos 400 m porque es el radio con menor error (Fig. 3).

Proceso gaussiano. Las entradas son el régimen en dos columnas indicadoras y el rezago estandarizado. La covarianza entre dos parcelas es

$$k(\mathbf{x}, \mathbf{x}') = \sigma_f^2 \exp\left(-\frac{\|\mathbf{x} - \mathbf{x}'\|^2}{2\lambda^2}\right) + \sigma_n^2\, \delta_{\mathbf{x}\mathbf{x}'}, \qquad (2)$$

donde λ es la escala de parecido, σ_f^2 la variación explicada y σ_n^2 el ruido [17]. Los tres se ajustan por máxima verosimilitud dentro de cada grupo de validación. Con las 138 parcelas quedan en 0.77, 1.57 y 0.26, así que el modelo atribuye cerca de una cuarta parte de la variación a ruido.

Intervalo de predicción. Con predicción conformal de Mondrian [21], [22], el intervalo de la parcela i del régimen g es

$$\left[\, \hat{y}_i + q_{0.10}(r_g),\ \hat{y}_i + q_{0.90}(r_g) \,\right], \qquad (3)$$

donde r_g son los 1380 errores fuera de grupo con signo, $r = y - \hat{y}$, de las 10 repeticiones, y q_α su cuantil. Calibramos por régimen porque sus errores se distribuyen distinto.

III. Por qué cada pieza

Una idea entra solo si baja el RMSE en al menos 7 de 10 repeticiones y pasa una prueba de permutación con $p \leq 0.05$ [15]. Ningún bloque satelital, climático o topográfico pasó esa regla (Fig. 4). El clima viene en celdas de unos 5 km y solo distingue zonas, algo que ya hacen el régimen y los vecinos.

Con las entradas fijas comparamos algoritmos (Fig. 5). Los árboles quedan peor que la media por régimen porque con tres entradas y 138 parcelas sus cortes no tienen dónde apoyarse. El proceso gaussiano obtiene el menor error, aunque frente a un modelo lineal con las mismas entradas la diferencia no es significativa ($p = 0.38$).

IV. Confiabilidad del error

La Tabla I separa lo que mide cada cifra. La validación anidada repite la elección entre 12 variantes dentro de cada

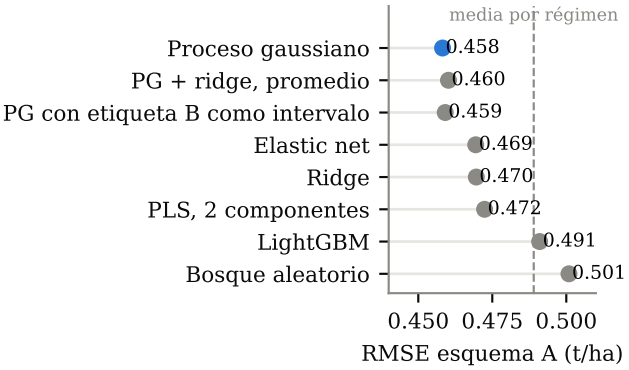


Fig. 5. RMSE de cada algoritmo con régimen y rezago como entradas. La línea punteada es la media por régimen.

Tabla I
Qué mide cada cifra de error (t/ha)

Qué se mide	RMSE
Modelo elegido, validación cruzada repetida	0.458
Procedimiento completo de elegir, validación anidada	0.490
Media por régimen, mismas particiones	0.489
Variación por azar con 59 parcelas (90 % de 5000 sorteos)	0.35 a 0.56

grupo externo [19], así que incluye el costo de haber elegido el mejor modelo [18]. Frente a la media por régimen la diferencia es de -0.029 t/ha, con intervalo de confianza del 95 % de -0.079 a $+0.022$ en la prueba de Nadeau y Bengio [20], así que no es significativa. El intervalo del percentil 10 al 90 cubre 0.826 de las evaluaciones, cerca de la meta de 0.80 (Fig. 7).

No hay fuga de información. Si la etiqueta se filtrara a las variables, el modelo predeciría bien aun con las etiquetas revueltas [23]. Con los rendimientos revueltos dentro de cada régimen el RMSE nunca baja de 0.485, contra 0.467 con los reales (Fig. 6). El rezago capta una relación real entre vecinos.

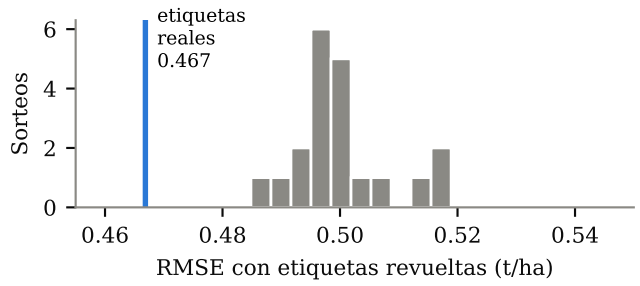


Fig. 6. RMSE en 20 sorteos con los rendimientos revueltos dentro de cada régimen (barras) contra el RMSE con los rendimientos reales (línea azul). Ningún sorteo se acerca al valor real.

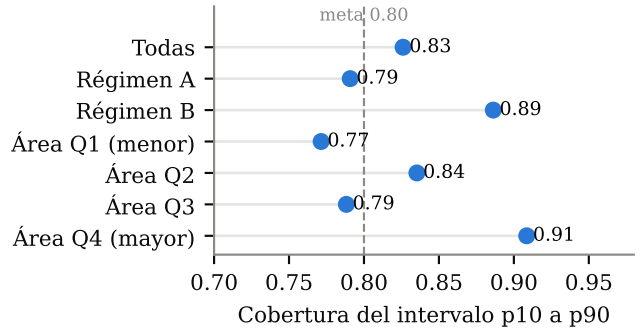


Fig. 7. Cobertura del intervalo p10 a p90 en validación anidada, con su intervalo de confianza del 95 %, en total, por régimen y por cuartil de área. La línea punteada es la meta de 0.80.

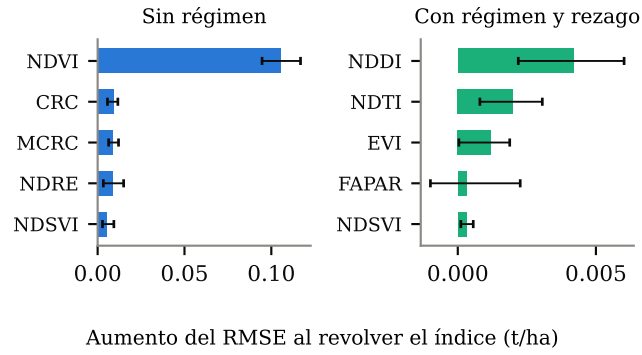


Fig. 8. Aumento del RMSE al revolver cada índice en el bosque de análisis, sin régimen (izquierda) y con régimen y rezago (derecha). Las escalas horizontales son distintas.

V. Preguntas guía

Como el modelo final solo tiene tres entradas, medimos la importancia con un bosque aleatorio de análisis, revolviendo cada índice y viendo cuánto sube su RMSE (Fig. 8). Sin el régimen, el NDVI y la lluvia pesan más, pero identifican la zona. Con régimen y rezago, el índice de sequía NDDI [26] es el mayor, con apenas 0.004 t/ha. La mejor combinación es régimen más rezago.

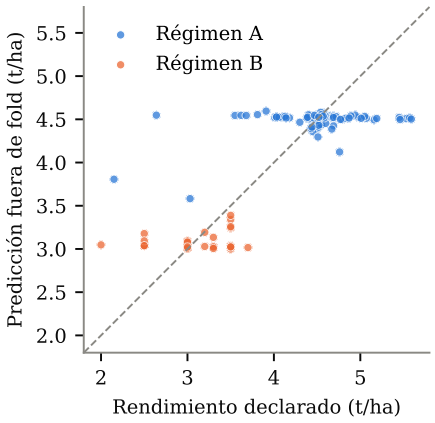


Fig. 9. Rendimiento declarado contra predicción fuera de grupo de las 138 parcelas de entrenamiento. La diagonal es la predicción perfecta.

VI. Capa de crédito

La probabilidad de no cubrir un umbral u, que puede ser el crédito o el costo total por hectárea entre el precio, es

$$P = q + (1 - q)\ \Pr(\hat{y}_i + r_g < u)\,, \tag{4}$$

donde q es la fracción de superficie que el municipio pierde históricamente [24] y la segunda parte usa los mismos errores de (3). Si la cosecha se pierde el ingreso es cero, por eso se suma q. Los costos son los de AgroCostos de FIRA [25].

VII. Predicciones

La Tabla II lista el ID de cada parcela y su rendimiento predicho en t/ha, con su intervalo y la probabilidad de quedar bajo 2.5 t/ha. La Fig. 10 muestra que las predicciones siguen el patrón espacial de los rendimientos observados. Su principal limitación se ve en la Fig. 9. Las predicciones forman una franja por régimen y las parcelas extremas, como las de 5.5 t/ha, quedan cerca de la media de su régimen.

VIII. Aportaciones del equipo

José Alán Pomares Valdés. Limpieza de datos, construcción de variables, hallazgo de los regímenes, diseño de la validación y de la regla de decisión, modelado, intervalos, capa de crédito, preguntas guía y redacción.

Vicente Josimar López Martínez. Aplicación web con mapa, predicción, intervalo y ejecución del modelo en vivo. Levantamiento de necesidades de analistas y productores [por confirmar]. Pruebas de uso [por confirmar]. Despliegue [por confirmar].

Luis Emmanuel Ramiro Luna. Video de presentación. Guion a partir de los resultados [por confirmar]. Grabación y edición [por confirmar]. Revisión de la claridad del mensaje para productores [por confirmar].

Luis Gustavo Olivares Soto, asesor. Revisión crítica de la metodología y de la redacción.

Tabla II

RENDIMIENTO PREDICHO (PRED.), INTERVALO P10 A P90 (T/HA) Y PROBABILIDAD DE RENDIMIENTO MENOR QUE 2.5 T/HA DE LAS 59 PARCELAS. R ES EL RÉGIMEN Y P LA PROBABILIDAD.

ID	Municipio	R	Pred.	p10	p90	P	ID	Municipio	R	Pred.	p10	p90	P
AGC_003	Singuilucan	B	3.66	3.11	4.14	0.000	AGC_107	Almoloya	A	4.54	4.03	5.12	0.001
AGC_011	Chignahuapan	A	4.54	4.03	5.11	0.001	AGC_113	Singuilucan	B	3.25	2.70	3.73	0.031
AGC_016	Chignahuapan	A	4.57	4.06	5.14	0.001	AGC_116	Chignahuapan	A	4.54	4.03	5.12	0.001
AGC_025	Calpulalpan	B	2.98	2.43	3.46	0.225	AGC_118	Singuilucan	B	3.02	2.47	3.50	0.196
AGC_027	Calpulalpan	B	3.02	2.47	3.50	0.196	AGC_120	Nanacamilpa	B	3.02	2.47	3.50	0.196
AGC_028	Chignahuapan	A	4.54	4.03	5.12	0.001	AGC_126	Chignahuapan	A	4.57	4.06	5.14	0.001
AGC_029	Calpulalpan	B	3.02	2.47	3.50	0.196	AGC_128	Almoloya	A	4.56	4.05	5.13	0.001
AGC_030	Singuilucan	B	3.02	2.47	3.50	0.196	AGC_129	Singuilucan	B	3.02	2.47	3.50	0.196
AGC_031	Chignahuapan	A	3.88	3.37	4.45	0.023	AGC_130	Cuautepec	A	4.54	4.03	5.11	0.001
AGC_036	Chignahuapan	A	4.55	4.04	5.12	0.001	AGC_136	Chignahuapan	A	4.57	4.06	5.14	0.001
AGC_039	Calpulalpan	B	3.02	2.47	3.50	0.196	AGC_142	Chignahuapan	A	4.56	4.04	5.13	0.001
AGC_042	Singuilucan	B	3.25	2.70	3.73	0.031	AGC_143	Chignahuapan	A	4.58	4.07	5.15	0.001
AGC_043	Chignahuapan	A	4.57	4.06	5.14	0.001	AGC_147	Calpulalpan	B	3.02	2.47	3.50	0.196
AGC_050	Calpulalpan	B	3.02	2.47	3.50	0.196	AGC_149	Cuautepec	A	4.54	4.03	5.12	0.001
AGC_052	Cuautepec	A	4.56	4.05	5.14	0.001	AGC_153	Chignahuapan	A	4.54	4.03	5.11	0.001
AGC_061	Calpulalpan	B	3.02	2.47	3.50	0.196	AGC_154	Chignahuapan	A	4.58	4.07	5.15	0.001
AGC_063	Chignahuapan	A	4.54	4.03	5.11	0.001	AGC_156	Singuilucan	B	3.02	2.47	3.50	0.196
AGC_065	Almoloya	A	4.54	4.03	5.11	0.001	AGC_158	Chignahuapan	A	4.50	3.99	5.07	0.001
AGC_071	Calpulalpan	B	3.08	2.53	3.56	0.049	AGC_173	Calpulalpan	B	3.02	2.47	3.50	0.196
AGC_075	Calpulalpan	B	2.98	2.43	3.46	0.225	AGC_174	Cuautepec	A	4.54	4.03	5.11	0.001
AGC_076	Chignahuapan	A	4.54	4.03	5.11	0.001	AGC_175	Chignahuapan	A	4.58	4.07	5.15	0.001
AGC_082	Almoloya	A	4.54	4.03	5.11	0.001	AGC_177	Chignahuapan	A	3.72	3.21	4.29	0.024
AGC_085	Chignahuapan	A	3.72	3.21	4.29	0.024	AGC_182	Chignahuapan	A	4.58	4.07	5.15	0.001
AGC_086	Calpulalpan	B	3.02	2.47	3.50	0.196	AGC_183	Calpulalpan	B	3.02	2.47	3.50	0.196
AGC_087	Calpulalpan	B	2.75	2.20	3.23	0.235	AGC_186	Chignahuapan	A	4.54	4.03	5.11	0.001
AGC_088	Chignahuapan	A	4.45	3.94	5.02	0.002	AGC_188	Chignahuapan	A	4.58	4.07	5.15	0.001
AGC_091	Chignahuapan	A	4.55	4.04	5.13	0.001	AGC_190	Chignahuapan	A	4.47	3.95	5.04	0.002
AGC_093	Calpulalpan	B	2.98	2.43	3.46	0.225	AGC_191	Chignahuapan	A	4.56	4.04	5.13	0.001
AGC_094	Chignahuapan	A	4.56	4.05	5.13	0.001	AGC_192	Chignahuapan	A	4.54	4.03	5.11	0.001
AGC_095	Chignahuapan	A	4.58	4.07	5.15	0.001							

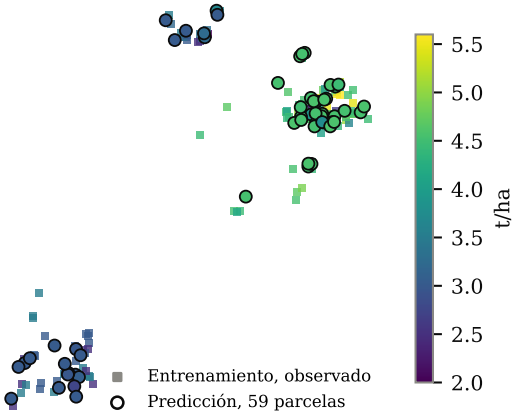


Fig. 10. Rendimiento observado en las parcelas de entrenamiento (cuadros) y predicho en las 59 parcelas (círculos con borde), con la misma escala de color. Los grupos en tonos oscuros, al oeste, son del régimen B.

IX. USO DE INTELIGENCIA ARTIFICIAL

Usamos Claude Code, de Anthropic, como asistente de programación, auditoría y redacción. El equipo verificó cada resultado contra los datos y decidió qué incorporar. La Tabla III resume los prompts principales en una síntesis formal, no en su texto original.

Tabla III

SÍNTESIS DE LOS PROMPTS PRINCIPALES

Fecha	Prompt	Resultado y uso
4 oct	Revisar la documentación del reto como investigación previa e identificar el problema central del dataset.	Diagnóstico del tamaño y del ruido de las etiquetas. Lo contrastamos con los datos.
4 oct	Proponer un plan de validación y experimentación sólido, con conceptos y referencias.	Esquemas de validación y regla de decisión fijados antes de probar ideas.
7 oct	Auditar el código del modelo y documentarlo.	Detectó que el rezago usaba la propia etiqueta. Lo corregimos y el RMSE pasó de 0.4525 a 0.458.
9 oct	Auditar de forma independiente todo el código y sus conclusiones.	Motivó usar datos públicos del SIAP y un modelo municipal.
14 oct	Investigar qué explica los regímenes A y B con lo dicho en la segunda sesión de preguntas.	Hipótesis de fuente mixta, que dejamos como no confirmada.
14 oct	Diseñar la capa de crédito con precio, costos y calibración del p10.	Capa de crédito. Revisamos cada supuesto.
15 oct	Atender las observaciones del asesor, primero las posibles fugas.	Auditoría sin fuga, correcciones de signo y de redacción.