Anexo técnico. Rendimiento de cebada de temporal con régimen de registro y rezago espacial

José Alán Pomares Valdés
Facultad de Ciencias de la Computación
Benemérita Universidad Autónoma de Puebla
Puebla, México
pv202351433@alm.buap.mx

Vicente Josimar López Martínez
Facultad de Ciencias de la Computación
Benemérita Universidad Autónoma de Puebla
Puebla, México

Luis Emmanuel Ramiro Luna
Facultad de Ciencias de la Computación
Benemérita Universidad Autónoma de Puebla
Puebla, México

Luis Gustavo Olivares Soto (asesor)
Facultad de Ciencias de la Computación
Benemérita Universidad Autónoma de Puebla
Puebla, México

***Resumen*—Este anexo reúne las figuras, ecuaciones y tablas que sustentan la metodología. El modelo de parcelas es un proceso gaussiano con el régimen de registro y el rendimiento de las parcelas vecinas, con raíz del error cuadrático medio (RMSE) esperada de 0.46 a 0.49 t/ha. El modelo municipal usa datos públicos de 2003 a 2025 para estimar toda la región. La Tabla I lista el ID y el rendimiento predicho de las 59 parcelas. El detalle completo está en los reportes del equipo [12]–[14] y el código en su repositorio [15].**

***Palabras clave*—rendimiento de cebada, régimen de registro, rezago espacial, proceso gaussiano, kriging, datos públicos, crédito agrícola.**

I. Dos formas de registrar el rendimiento

Cada municipio registra el rendimiento de una sola forma (Fig. 1). En el régimen A los valores tienen dos decimales y promedian 4.49 t/ha. En el B tienen un decimal y promedian 3.05 t/ha. La diferencia entre medias, 1.4 t/ha, es casi tres veces la desviación estándar dentro de cada régimen. Por eso el régimen es la primera pieza del modelo. No sabemos si el rendimiento se midió distinto o solo se anotó distinto, así que lo tratamos como una observación por municipio.

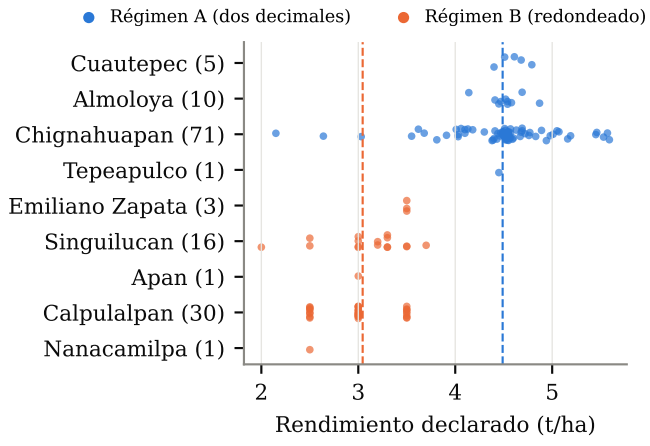


Fig. 1. Rendimiento de las 138 parcelas de entrenamiento por municipio. Cada municipio cae en un solo régimen. Las líneas punteadas son la media de cada régimen.

El régimen supera a cualquier agrupación geográfica. La media por municipio se acerca a la del régimen cuando hay parcelas de entrenamiento cerca (esquema A), pero cuando la validación deja fuera zonas completas (esquema B) sube a 0.955 t/ha. El régimen se conoce para toda parcela y no tiene ese problema.

II. Modelo

Rezago espacial. Parcelas cercanas tienden a rendir parecido [21]. El rezago de la parcela i es

$$\ell_i = \frac{\sum_{j \in \mathcal{N}_i} y_j / d_{ij}}{\sum_{j \in \mathcal{N}_i} 1/d_{ij}}, \tag{1}$$

donde $\mathcal{N}_i$ son hasta 10 parcelas de entrenamiento del mismo régimen a 400 m o menos, y_j su rendimiento y d_{ij} la distancia. Sin vecinos, ℓ_i es la media del régimen en el entrenamiento. La parcela evaluada nunca entra en su propio rezago. Elegimos 400 m porque es el radio con menor error (Fig. 2a).

Proceso gaussiano. Las entradas son el régimen en dos columnas indicadoras y el rezago estandarizado. La covarianza entre dos parcelas es

$$k(\mathbf{x}, \mathbf{x}') = \sigma_f^2 \exp\!\left(-\frac{\|\mathbf{x} - \mathbf{x}'\|^2}{2\lambda^2}\right) + \sigma_n^2\, \delta_{\mathbf{x}\mathbf{x}'}, \tag{2}$$

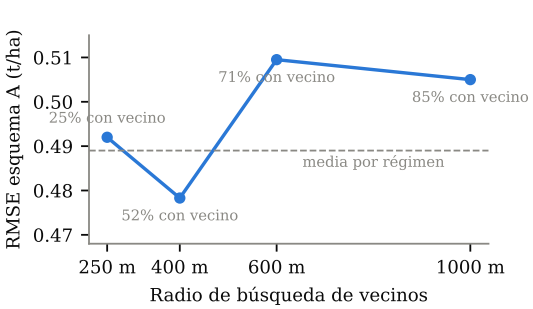
donde λ es la escala de parecido, σ_f^2 la variación explicada y σ_n^2 el ruido [22]. Los tres se ajustan por máxima verosimilitud dentro de cada grupo de validación. Con las 138 parcelas quedan en 0.77, 1.57 y 0.26, así que el modelo atribuye cerca de una cuarta parte de la variación a ruido.

Intervalo de predicción. Con predicción conformal de Mondrian [25], [26], el intervalo de la parcela i del régimen g es

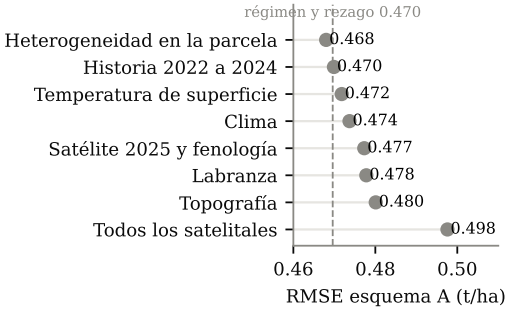
$$\left[\, \hat{y}_i + q_{0.10}(r_g),\ \hat{y}_i + q_{0.90}(r_g) \,\right], \tag{3}$$

Tabla I
ID DE LA PARCELA, RÉGIMEN (R), RENDIMIENTO PREDICHO (PRED.) E INTERVALO P10 A P90, EN T/HA, DE LAS 59 PARCELAS.

ID	R	Pred.	p10	p90	ID	R	Pred.	p10	p90	ID	R	Pred.	p10	p90
AGC_003	B	3.66	3.11	4.14	AGC_076	A	4.54	4.03	5.11	AGC_142	A	4.56	4.04	5.13
AGC_011	A	4.54	4.03	5.11	AGC_082	A	4.54	4.03	5.11	AGC_143	A	4.58	4.07	5.15
AGC_016	A	4.57	4.06	5.14	AGC_085	A	3.72	3.21	4.29	AGC_147	B	3.02	2.47	3.50
AGC_025	B	2.98	2.43	3.46	AGC_086	B	3.02	2.47	3.50	AGC_149	A	4.54	4.03	5.12
AGC_027	B	3.02	2.47	3.50	AGC_087	B	2.75	2.20	3.23	AGC_153	A	4.54	4.03	5.11
AGC_028	A	4.54	4.03	5.12	AGC_088	A	4.45	3.94	5.02	AGC_154	A	4.58	4.07	5.15
AGC_029	B	3.02	2.47	3.50	AGC_091	A	4.55	4.04	5.13	AGC_156	B	3.02	2.47	3.50
AGC_030	B	3.02	2.47	3.50	AGC_093	B	2.98	2.43	3.46	AGC_158	A	4.50	3.99	5.07
AGC_031	A	3.88	3.37	4.45	AGC_094	A	4.56	4.05	5.13	AGC_173	B	3.02	2.47	3.50
AGC_036	A	4.55	4.04	5.12	AGC_095	A	4.58	4.07	5.15	AGC_174	A	4.54	4.03	5.11
AGC_039	B	3.02	2.47	3.50	AGC_107	A	4.54	4.03	5.12	AGC_175	A	4.58	4.07	5.15
AGC_042	B	3.25	2.70	3.73	AGC_113	B	3.25	2.70	3.73	AGC_177	A	3.72	3.21	4.29
AGC_043	A	4.57	4.06	5.14	AGC_116	A	4.54	4.03	5.12	AGC_182	A	4.58	4.07	5.15
AGC_050	B	3.02	2.47	3.50	AGC_118	B	3.02	2.47	3.50	AGC_183	B	3.02	2.47	3.50
AGC_052	A	4.56	4.05	5.14	AGC_120	B	3.02	2.47	3.50	AGC_186	A	4.54	4.03	5.11
AGC_061	B	3.02	2.47	3.50	AGC_126	A	4.57	4.06	5.14	AGC_188	A	4.58	4.07	5.15
AGC_063	A	4.54	4.03	5.11	AGC_128	A	4.56	4.05	5.13	AGC_190	A	4.47	3.95	5.04
AGC_065	A	4.54	4.03	5.11	AGC_129	B	3.02	2.47	3.50	AGC_191	A	4.56	4.04	5.13
AGC_071	B	3.08	2.53	3.56	AGC_130	A	4.54	4.03	5.11	AGC_192	A	4.54	4.03	5.11
AGC_075	B	2.98	2.43	3.46	AGC_136	A	4.57	4.06	5.14					



(a) RMSE según el radio de búsqueda de vecinos, con la fracción de parcelas que tiene al menos un vecino. Con radios chicos casi nadie tiene vecinos y con radios grandes el promedio mezcla parcelas que ya no se parecen.



(b) RMSE al agregar cada bloque de variables al modelo con régimen y rezago (línea punteada). Ninguno mejora de forma que pase la regla de decisión, y juntar todos los satelitales empeora el error.

Fig. 2. Elección del radio del rezago y de las variables.

donde r_g son los 1380 errores fuera de grupo con signo, $r = y - \hat{y}$, de las 10 repeticiones, y q_α su cuantil. Calibramos por régimen porque sus errores se distribuyen distinto.

III. Por qué cada pieza

Una idea entra solo si baja el RMSE en al menos 7 de 10 repeticiones y pasa una prueba de permutación con $p \leq 0.05$ [20]. Ningún bloque satelital, climático o topográfico pasó esa regla (Fig. 2b). El clima viene en celdas de unos 5 km y solo distingue zonas, algo que ya hacen el régimen y los vecinos.

Con las entradas fijas comparamos algoritmos [13]. Los árboles quedan peor que la media por régimen porque con tres entradas y 138 parcelas sus cortes no tienen dónde apoyarse. El proceso gaussiano obtiene el menor error, aunque frente a un modelo lineal con las mismas entradas la diferencia no es significativa ($p = 0.38$).

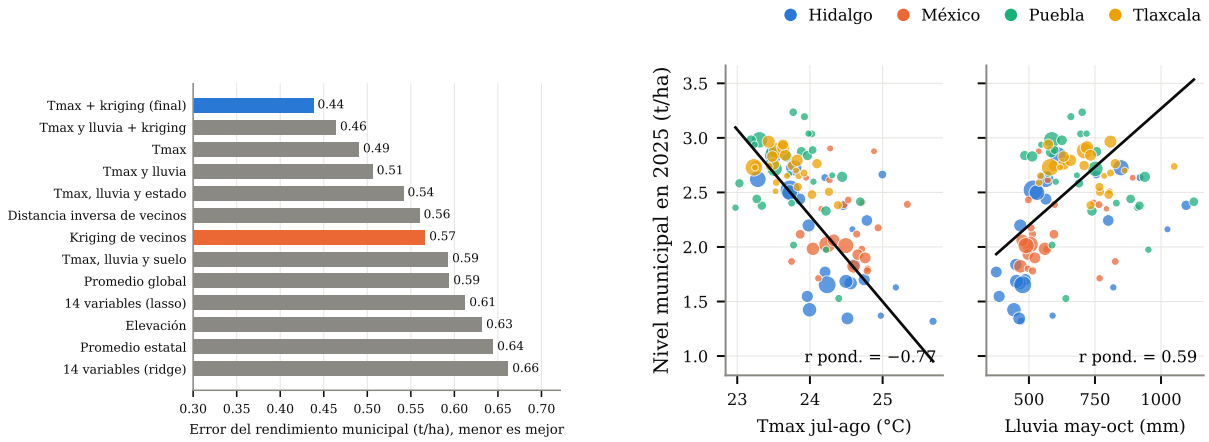
IV. Confiabilidad del error

La Tabla II separa lo que mide cada cifra. La validación anidada repite la elección entre 12 variantes dentro de cada grupo externo [24], así que incluye el costo de haber elegido el mejor modelo [23]. Frente a la media por régimen la diferencia es de -0.029 t/ha, con intervalo de confianza del 95 % de -0.079 a $+0.022$ en la prueba de Nadeau y Bengio [35], así que no es significativa. El intervalo del percentil 10 al 90 cubre 0.826 de las evaluaciones, cerca de la meta de 0.80 [13].

No hay fuga de información. Si la etiqueta se filtrara a las variables, el modelo predeciría bien aun con las etiquetas revueltas [27]. Con los rendimientos revueltos dentro de cada régimen el RMSE nunca baja de 0.485, contra 0.467 con los reales en 20 sorteos. El rezago capta una relación real entre vecinos.

V. Preguntas guía

Como el modelo final solo tiene tres entradas, medimos la importancia con un bosque aleatorio de análisis, revolviendo cada índice y viendo cuánto sube su RMSE [13]. Sin el régimen, el NDVI y la lluvia pesan más, pero identifican la zona. Con régimen y rezago, el índice de sequía NDDI [33]



(a) Error de 13 modelos al predecir municipios sin datos del SIAP a menos de 50 km, ponderado por superficie. En naranja el kriging de vecinos y en azul el modelo final.

(b) Rendimiento municipal llevado a 2025 contra la Tmax de julio y agosto y la lluvia de mayo a octubre. El tamaño del punto crece con la superficie sembrada.

Fig. 3. Modelo municipal con datos públicos.

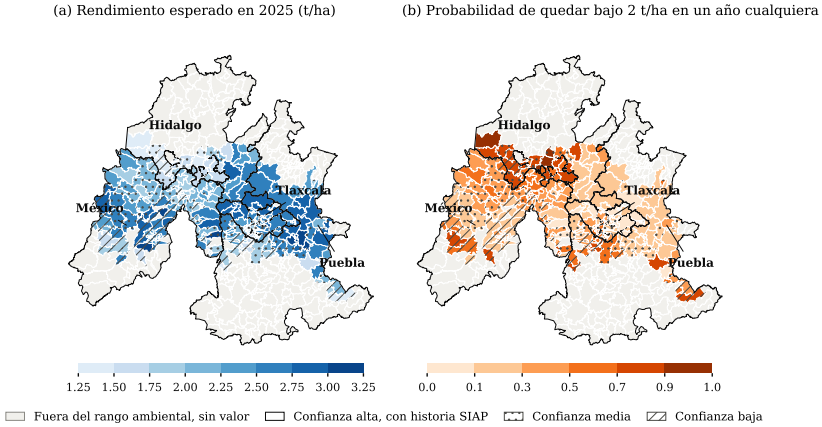


Fig. 4. Modelo municipal. (a) Rendimiento esperado en 2025. (b) Probabilidad de quedar bajo 2 t/ha en un año cualquiera. El rayado marca confianza media (puntos) y baja (líneas). En gris, municipios con un ambiente distinto al de los datos.

Tabla II
QUÉ MIDE CADA CIFRA DE ERROR (T/HA)

Qué se mide	RMSE
Modelo elegido, validación cruzada repetida	0.458
Procedimiento completo de elegir, validación anidada	0.490
Media por régimen, mismas particiones	0.489
Variación por azar con 59 parcelas (90 % de 5000 sorteos)	0.35 a 0.56

es el mayor, con apenas 0.004 t/ha. La mejor combinación es régimen más rezago.

VI. Modelo municipal con datos públicos

El modelo de parcelas solo sirve donde hay parcelas con rendimiento cerca. Para estimar en toda la región usamos el rendimiento municipal del SIAP de 2003 a 2025 en Hidalgo, México, Puebla y Tlaxcala, con 100 municipios con historia [28], y la temperatura máxima (Tmax) de julio y agosto [7]. El rendimiento esperado del municipio m es

$$\hat{\bar{y}}_m = \beta_0 + \beta_1 T_m + \hat{e}(\mathbf{s}_m), \tag{4}$$

donde T_m es su Tmax y $\hat{e}$ un kriging de los errores de la regresión, con covarianza Matérn [30] ajustada en cada partición. Lejos de municipios con SIAP la corrección tiende a cero y queda la predicción por clima.

Funciona en lugares sin datos. Predecimos zonas completas sin usar municipios a menos de 50 km [18]. Ahí el modelo obtiene un RMSE ponderado por superficie de 0.44 t/ha, contra 0.57 del kriging de vecinos, que no usa clima (Fig. 3a). El intervalo de 95 % de la diferencia va de -0.18 a -0.09. Al repetir de forma anidada la elección de la variable la ventaja baja a unos 0.07 t/ha. Con vecinos cerca ambos empatan.

El calor de verano es la variable climática clave. Cada grado más de Tmax se asocia con 0.79 t/ha menos de rendimiento (Fig. 3b), lo que concuerda con el daño del calor

Tabla III
Síntesis de los prompts principales

Fecha	Prompt	Resultado y uso
4 oct	Revisar la documentación del reto e identificar el problema central del dataset.	Diagnóstico del tamaño y del ruido de las etiquetas.
4 oct	Proponer un plan de validación y experimentación.	Regla de decisión fijada antes de probar ideas.
7 oct	Auditar el código del modelo.	Detectó que el rezago usaba la propia etiqueta. Lo corregimos.
9 oct	Auditar de forma independiente el código y las conclusiones.	Motivó el modelo municipal con datos públicos.
14 oct	Investigar qué explica los regímenes A y B.	Hipótesis de fuente mixta, no confirmada.
14 oct	Diseñar la capa de crédito.	Capa de crédito con supuestos revisados.
15 oct	Atender las observaciones del asesor.	Auditoría sin fuga y correcciones.

al llenado del grano [29]. En los 9 municipios del reto la Tmax solo va de 23.3 a 23.9 °C. Por eso el clima no ayudó al modelo de parcelas.

Mapa regional. La Fig. 4 muestra el rendimiento esperado y la probabilidad de quedar bajo 2 t/ha en los 268 municipios cuyo ambiente cae dentro del rango de los datos [36]. La probabilidad aún no está calibrada, así que es una guía preliminar para priorizar zonas.

VII. Capa de crédito

La probabilidad de no cubrir un umbral u, que puede ser el crédito o el costo total por hectárea entre el precio, es

$$P = q + (1 - q)\ \Pr(\hat{y}_i + r_g < u)\,, \tag{5}$$

donde q es la fracción de superficie que el municipio pierde históricamente [31] y la segunda parte usa los mismos errores de (3). Si la cosecha se pierde el ingreso es cero, por eso se suma q. Los costos son los de AgroCostos de FIRA [32].

VIII. Aportaciones del equipo

José Alán Pomares Valdés, datos, variables, validación, modelos, capa de crédito y redacción. **Vicente Josimar López Martínez**, aplicación web, levantamiento de necesidades [por confirmar], pruebas de uso [por confirmar] y despliegue [por confirmar]. **Luis Emmanuel Ramiro Luna**, video, guion [por confirmar] y grabación y edición [por confirmar]. **Luis Gustavo Olivares Soto**, asesor, revisión crítica de la metodología y la redacción.

IX. Uso de inteligencia artificial

Usamos Claude Code, de Anthropic, para programar, auditar y redactar. El equipo verificó cada resultado. La Tabla III sintetiza los prompts principales.

Referencias

[1] FIRA, *Reto AgroCebada 2026. Bases de participación y descripción del conjunto de datos*, 2026.

[2] Secretaría de Agricultura y Desarrollo Rural, "Del campo a la copa: el recorrido de la cebada," *gob.mx*, 11 de noviembre de 2025. [En línea]. Disponible: https://www.gob.mx/agricultura/articulos/del-campo-a-la-copa-el-recorrido-de-la-cebada

[3] FIRA, *Sesiones de preguntas y respuestas del Reto AgroCebada 2026 y correos de seguimiento a los equipos participantes*, septiembre y octubre de 2026 (último correo del 14 de octubre).

[4] M. Drusch *et al.*, "Sentinel-2: ESA's Optical High-Resolution Mission for GMES Operational Services," *Remote Sensing of Environment*, vol. 120, pp. 25–36, 2012.

[5] A. E. Frazier y B. L. Hemingway, "A Technical Review of Planet Smallsat Data: Practical Considerations for Processing and Using PlanetScope Imagery," *Remote Sensing*, vol. 13, no. 19, p. 3930, 2021.

[6] C. Funk *et al.*, "The climate hazards infrared precipitation with stations—a new environmental record for monitoring extremes," *Scientific Data*, vol. 2, art. 150066, 2015.

[7] A. Verdin *et al.*, "Development and validation of the CHIRTS-daily quasi-global high-resolution daily temperature data set," *Scientific Data*, vol. 7, no. 1, art. 303, 2020.

[8] D. B. Lobell *et al.*, "Eyes in the Sky, Boots on the Ground: Assessing Satellite- and Ground-Based Approaches to Crop Yield Measurement and Analysis," *American Journal of Agricultural Economics*, vol. 102, no. 1, pp. 202–219, 2020.

[9] T. van Klompenburg, A. Kassahun y C. Catal, "Crop yield prediction using machine learning: A systematic literature review," *Computers and Electronics in Agriculture*, vol. 177, p. 105709, 2020.

[10] M. Weiss, F. Jacob y G. Duveiller, "Remote sensing for agricultural applications: A meta-review," *Remote Sensing of Environment*, vol. 236, p. 111402, 2020.

[11] J. A. Pomares Valdés, V. J. López Martínez y L. E. Ramiro Luna, "¿Qué separa a los dos regímenes de rendimiento? Descarte de causas ambientales y contraste con las cifras oficiales del SIAP," Benemérita Universidad Autónoma de Puebla, Puebla, México, Rep. técnico, oct. 2026. [En línea]. Disponible: https://github.com/alan-pv/AgroCebada_Hackaton/blob/main/docs/reporte_regimenes/main.pdf

[12] J. A. Pomares Valdés, V. J. López Martínez y L. E. Ramiro Luna, "El Reto AgroCebada 2026 en contexto. Lo que sabemos, lo que suponemos y lo que falta comprobar," Benemérita Universidad Autónoma de Puebla, Puebla, México, Rep. técnico, oct. 2026. [En línea]. Disponible: https://github.com/alan-pv/AgroCebada_Hackaton/blob/main/AgroCebada_contexto.pdf

[13] J. A. Pomares Valdés, V. J. López Martínez y L. E. Ramiro Luna, "Rendimiento de cebada de temporal con régimen de etiquetas y rezago espacial. Procedimiento, arquitectura y evaluación del modelo," Benemérita Universidad Autónoma de Puebla, Puebla, México, Rep. técnico, oct. 2026. [En línea]. Disponible: https://github.com/alan-pv/AgroCebada_Hackaton/blob/main/docs/reporte_modelo/main.pdf

[14] J. A. Pomares Valdés, V. J. López Martínez y L. E. Ramiro Luna, "¿Dónde rinde más la cebada de temporal? Un modelo municipal con datos públicos para Hidalgo, México, Puebla y Tlaxcala," Benemérita Universidad Autónoma de Puebla, Puebla, México, Rep. técnico, oct. 2026. [En línea]. Disponible: https://github.com/alan-pv/AgroCebada_Hackaton/blob/main/docs/reporte_generalizable/modelo_generalizable.pdf

[15] J. A. Pomares Valdés, V. J. López Martínez y L. E. Ramiro Luna, "AgroCebada. Código, datos públicos y reportes del Reto AgroCebada FIRA 2026," GitHub, 2026. [En línea]. Disponible: https://github.com/alan-pv/AgroCebada_Hackaton

[16] FIRA, *Ecuaciones de índices satelitales. Reto AgroCebada FIRA 2026*, 2026.

[17] J. C. Zadoks, T. T. Chang y C. F. Konzak, "A decimal code for the growth stages of cereals," *Weed Research*, vol. 14, no. 6, pp. 415–421, 1974.

[18] D. R. Roberts *et al.*, "Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure," *Ecography*, vol. 40, no. 8, pp. 913–929, 2017.

[19] P. Ploton *et al.*, "Spatial validation reveals poor predictive performance of large-scale ecological mapping models," *Nature Communications*, vol. 11, no. 1, art. 4540, 2020.

[20] M. Ojala y G. C. Garriga, "Permutation tests for studying classifier performance," *Journal of Machine Learning Research*, vol. 11, pp. 1833–1863, 2010.

[21] W. R. Tobler, "A computer movie simulating urban growth in the Detroit region," *Economic Geography*, vol. 46, pp. 234–240, 1970.

[22] C. E. Rasmussen y C. K. I. Williams, *Gaussian Processes for Machine Learning*. Cambridge, MA, EE. UU.: MIT Press, 2006.

[23] G. C. Cawley y N. L. C. Talbot, "On over-fitting in model selection and subsequent selection bias in performance evaluation," *Journal of Machine Learning Research*, vol. 11, pp. 2079–2107, 2010.

[24] S. Varma y R. Simon, “Bias in error estimation when using cross-validation for model selection,” *BMC Bioinformatics*, vol. 7, art. 91, 2006.
[25] V. Vovk, A. Gammerman y G. Shafer, *Algorithmic Learning in a Random World*. Nueva York, NY, EE. UU.: Springer, 2005.
[26] J. Lei *et al.*, “Distribution-Free Predictive Inference for Regression,” *Journal of the American Statistical Association*, vol. 113, no. 523, pp. 1094–1111, 2018.
[27] S. Kaufman, S. Rosset, C. Perlich y O. Stitelman, “Leakage in data mining: Formulation, detection, and avoidance,” *ACM Transactions on Knowledge Discovery from Data*, vol. 6, no. 4, art. 15, 2012.
[28] Servicio de Información Agroalimentaria y Pesquera, “Cierre de la producción agrícola por municipio, cebada grano, temporal, primavera-verano, 2003–2025.” [En línea]. Disponible: https://nube.agricultura.gob.mx/cierre_agricola/. Consultado el 9 de octubre de 2026.
[29] V. S. Passarella, R. Savin y G. A. Slafer, “Grain weight and malting quality in barley as affected by brief periods of increased spike temperature under field conditions,” *Australian Journal of Agricultural Research*, vol. 53, no. 11, pp. 1219–1227, 2002.
[30] M. A. Oliver y R. Webster, “A tutorial guide to geostatistics: Computing and modelling variograms and kriging,” *CATENA*, vol. 113, pp. 56–69, 2014.
[31] SIAP, “Producción agrícola municipal, cierre 2025,” Datos abiertos, 2026. Consultado el 4 de octubre de 2026. Disponible en https://nube.agricultura.gob.mx/datosAbiertos/Agricola.php
[32] Fideicomisos Instituidos en Relación con la Agricultura, “Agrocostos.” [En línea]. Disponible: https://www.fira.gob.mx/Nd/Agrocostos.jsp. Consultado el 15 de octubre de 2026.
[33] Y. Gu *et al.*, “A five-year analysis of MODIS NDVI and NDWI for grassland drought assessment over the central Great Plains of the United States,” *Geophysical Research Letters*, vol. 34, no. 6, art. 2006GL029127, 2007.
[34] N. Jensen y C. Barrett, “Agricultural Index Insurance for Development,” *Applied Economic Perspectives and Policy*, vol. 39, no. 2, pp. 199–219, 2017.
[35] C. Nadeau e Y. Bengio, “Inference for the generalization error,” *Machine Learning*, vol. 52, no. 3, pp. 239–281, 2003.
[36] H. Meyer y E. Pebesma, “Predicting into unknown space? Estimating the area of applicability of spatial prediction models,” *Methods in Ecology and Evolution*, vol. 12, no. 9, pp. 1620–1633, 2021.