Reporte técnico. Rendimiento de cebada de temporal con régimen de registro y rezago espacial

José Alán Pomares Valdés
Facultad de Ciencias de la Computación
Benemérita Universidad Autónoma de Puebla
Puebla, México
pv202351433@alm.buap.mx

Vicente Josimar López Martínez
Facultad de Ciencias de la Computación
Benemérita Universidad Autónoma de Puebla
Puebla, México

Luis Emmanuel Ramiro Luna
Facultad de Ciencias de la Computación
Benemérita Universidad Autónoma de Puebla
Puebla, México

Luis Gustavo Olivares Soto (asesor)
Facultad de Ciencias de la Computación
Benemérita Universidad Autónoma de Puebla
Puebla, México

***Resumen*—Este reporte del equipo Los Bien Dotados reúne el texto de cada sección capturada en la plataforma del Reto AgroCebada FIRA 2026. Estimamos el rendimiento de 59 parcelas de cebada de temporal con un proceso gaussiano que usa el régimen de registro del municipio y el rendimiento de las parcelas vecinas. Esperamos una raíz del error cuadrático medio de 0.46 a 0.49 t/ha. Las figuras, ecuaciones y tablas citadas están en el anexo técnico.**

***Palabras clave*—rendimiento de cebada, régimen de registro, rezago espacial, proceso gaussiano, crédito agrícola.**

I. Introducción

El Reto AgroCebada FIRA 2026 pide estimar el rendimiento de grano de cebada de temporal, en toneladas por hectárea (t/ha), de 59 parcelas de Hidalgo, Puebla y Tlaxcala [1]. Estas entidades se cuentan entre las principales productoras de cebada del país [2]. FIRA busca que la estimación apoye decisiones productivas, de planeación y eventualmente financieras [3].

Contamos con 197 parcelas de nueve municipios, todas del ciclo primavera-verano 2025. En 138 conocemos el rendimiento y las usamos para entrenar. Las otras 59 son las que se califican, principalmente con la raíz del error cuadrático medio (RMSE), el error absoluto medio y el coeficiente de determinación, sin ponderar por superficie [3]. Para todas hay imágenes de los satélites Sentinel-2 [4], Landsat y PlanetScope [5], lluvia [6], temperatura [7] y topografía.

El rendimiento es el peso en báscula de toda la cosecha, sin ajuste por humedad ni impurezas. Lo reportó sobre todo la comercializadora que compró el grano y, en menor medida, el productor [3]. Esto importa porque los rendimientos reportados suelen traer error [8].

Predecir el rendimiento con satélites es un tema muy estudiado [9], [10]. Aquí el problema cambia por dos razones. La primera es que 138 parcelas son pocas, y la diferencia entre dos modelos suele ser menor que el azar de la validación. La segunda es la forma en que se registró el rendimiento.

Al revisar las etiquetas encontramos que cada municipio registra el rendimiento de una sola de dos formas (anexo técnico, Fig. 1). En cuatro municipios los valores tienen dos decimales y promedian 4.49 t/ha. Lo llamamos régimen A. En los otros cinco están redondeados y promedian 3.05 t/ha. Lo llamamos régimen B. La diferencia entre ambos, 1.4 t/ha, es casi tres veces la variación dentro de cada uno, así que conocer el régimen ya explica buena parte del rendimiento. No sabemos si el rendimiento se midió distinto o solo se anotó distinto. FIRA pidió tratar todos los registros como una sola variable, así que usamos el régimen como una característica del municipio y no como dos problemas separados.

Por eso nuestro trabajo no se limita a buscar el algoritmo con menor error. Buscamos responder qué información predice de verdad el rendimiento, qué tan confiable es el error que estimamos y qué significa ese error para un productor o un analista.

El resultado es un modelo sencillo. Usa el régimen del municipio y el rendimiento de las parcelas vecinas, y esperamos que su RMSE en las 59 parcelas sea de 0.46 a 0.49 t/ha. Lo acompañamos con un intervalo por parcela, una traducción del error a pesos y una aplicación web.

II. Justificación

FIRA pidió que la estimación sirva para decisiones productivas, de planeación y eventualmente financieras, y que cada equipo explique qué significa su error en términos productivos [3]. Para cualquiera de esas decisiones un número solo no basta. Hace falta saber cuánto puede fallar.

Las mediciones de campo son escasas y costosas, mientras que las imágenes de satélite y el clima son públicos y cubren cualquier parcela. Vale la pena saber cuánta información del

rendimiento contienen realmente. Con pocas parcelas y un registro heterogéneo, también vale la pena medir el error con cuidado, porque un error subestimado haría parecer seguras decisiones que no lo son.

Este trabajo aporta una estimación por parcela con un error medido de forma conservadora, su traducción a pesos y una aplicación para consultarla. También documenta qué ideas no funcionaron y por qué.

III. Objetivos

Objetivo general. Estimar el rendimiento de cebada de temporal de las 59 parcelas del reto con el menor error posible en parcelas no vistas, y medir con honestidad qué tan confiable es esa estimación.

Objetivos específicos.

1) Caracterizar las etiquetas de rendimiento y medir cómo su forma de registro limita lo que un modelo puede predecir.
2) Construir el modelo con una regla de decisión fijada antes de probar ideas, y conservar solo las piezas que mejoren la validación de forma consistente.
3) Estimar el error esperado incluyendo el costo de elegir entre variantes, y entregar por parcela un intervalo de predicción con cobertura verificada.
4) Responder con evidencia qué índice satelital, qué variable climática y qué combinación de variables pesan más.
5) Traducir el error a pesos por hectárea y a una señal de riesgo de crédito, e indicar en qué momento del ciclo puede usarse la estimación.
6) Publicar una aplicación web que ejecute el modelo y muestre predicciones, intervalos y probabilidades.

IV. Metodología

Seguimos seis pasos. En cada uno explicamos qué decidimos y por qué.

1. Limpieza de los datos. Usamos una observación de satélite solo si su nubosidad era de 20 % o menos. Elegimos ese umbral porque la nubosidad casi siempre vale 0 o 100 %, y cuando vale 100 los índices vienen vacíos. Con él cada parcela conserva entre 19 y 34 imágenes de Sentinel-2 en la temporada de 2025. No inventamos valores para las fechas descartadas. Después marcamos como pico un valor que se aleja mucho de la mediana de sus vecinos en el tiempo y suavizamos cada serie, porque un salto aislado suele ser una nube o una sombra que el filtro no detectó. Dejamos fuera el índice de área foliar de Sentinel-2, porque su fórmula da valores negativos sobre suelo desnudo, algo sin sentido físico [11]. Con lo demás construimos 91 variables por parcela, como el verdor máximo de 2025, las etapas del ciclo [12], la historia de 2022 a 2024, el clima y el terreno.

2. Asignación del régimen. Asignamos el régimen por el nombre del municipio. No lo hicimos por los decimales de cada parcela, porque 7 de las 87 parcelas del régimen A tienen un solo decimal y se habrían clasificado mal. Así el régimen se conoce para las 59 parcelas a predecir. En seis parcelas de municipios muy pequeños el régimen se dedujo de su propia etiqueta. Sin ellas el error cambia de 0.458 a 0.464 t/ha, un efecto pequeño.

3. Forma de evaluar. Fijamos la forma de evaluar antes de probar ideas, para no acomodarla a los resultados. Medimos el error siempre en parcelas que el modelo no vio, con validación cruzada de cinco grupos repetida 10 veces, que imita la partición de FIRA. Como parcelas cercanas se parecen y eso puede volver optimista la validación [13], [14], también evaluamos dejando fuera zonas completas. Una idea se acepta solo si mejora el error en al menos 7 de las 10 repeticiones y pasa una prueba de permutación [15]. Esa prueba revuelve las variables nuevas dentro de cada régimen y repite la validación 50 veces. Si el modelo predice igual de bien con ellas revueltas, la mejora era azar.

4. Construcción del modelo. Agregamos piezas de la más simple a la más compleja, y cada pieza tuvo que ganarle a la mejor versión aceptada hasta ese momento. Empezamos con la media de cada régimen. Después agregamos el rezago espacial, que es el promedio del rendimiento de las parcelas vecinas del mismo régimen, porque parcelas cercanas comparten suelo, clima y manejo [16]. Usamos vecinas a 400 m o menos porque es el radio con menor error (anexo técnico, Fig. 3). Luego probamos bloques de variables satelitales, climáticas y topográficas, y al final comparamos algoritmos. El modelo elegido es un proceso gaussiano [17], cuyos parámetros se ajustan solo con las parcelas de entrenamiento de cada grupo (anexo técnico, ecuaciones 1 y 2).

5. Confiabilidad. Probar muchas variantes y quedarse con la mejor infla el resultado [18]. Para medir ese efecto repetimos toda la elección dentro de cada grupo, lo que se llama validación anidada [19]. Todo lo que usa el rendimiento, como el rezago, se recalcula en cada grupo solo con las parcelas de entrenamiento, para que una parcela nunca influya en su propia predicción. Comparamos modelos con una prueba que corrige que las repeticiones comparten parcelas [20]. Para cada parcela calculamos un intervalo del percentil 10 al 90 con predicción conformal [21], [22], por separado en cada régimen porque sus errores son distintos (anexo técnico, ecuación 3). Una prueba automatizada verifica que cambiar las etiquetas de prueba no cambia las predicciones [23].

6. Traducción a pesos. Valuamos la predicción con el precio medio rural del SIAP de 2023 a 2025 [24] y con los costos de los paquetes de AgroCostos de FIRA [25], actualizados a 2025 con la inflación.

V. Resultados y discusión

El modelo mejora poco a la media por régimen. En validación cruzada el modelo obtiene un RMSE de 0.458 t/ha, un error absoluto medio (MAE) de 0.312 t/ha y un coeficiente de determinación (R^2) de 0.71. Solo con la media de cada régimen el RMSE es 0.489. La mejora va en la dirección correcta, pero su intervalo de confianza del 95 % incluye el cero, así que no es significativa (anexo técnico, Tabla I).

Error esperado en la calificación. Al repetir toda la elección dentro de la validación el RMSE es 0.490. Por eso

esperamos entre 0.46 y 0.49 t/ha en las 59 parcelas. Con solo 59 parcelas el resultado también depende de cuáles toquen, y por azar podría caer entre 0.35 y 0.56.

Qué aportó cada pieza. El régimen es la base. Cuando la validación deja fuera zonas completas, la media por municipio sube a 0.955 t/ha y la del régimen se mantiene en 0.489 (anexo técnico, Fig. 2). El rezago espacial mejoró el error en 9 de 10 repeticiones y pasó la prueba de permutación ($p = 0.02$). Ningún bloque de variables satelitales, climáticas o topográficas pasó la regla (Fig. 4). El clima, por ejemplo, viene en celdas de unos 5 km y solo distingue zonas, algo que ya hacen el régimen y los vecinos. Entre algoritmos, los de árboles quedaron peor que la media por régimen y el proceso gaussiano obtuvo el menor error, aunque no superó de forma significativa a un modelo lineal (Fig. 5).

El modelo no aprende de las etiquetas por error. Con los rendimientos revueltos el RMSE nunca baja de 0.485, contra 0.467 con los reales (Fig. 6). Si hubiera fuga de información, ambos serían parecidos.

Los intervalos cumplen. El intervalo del percentil 10 al 90 contiene el rendimiento real en 83 % de los casos, cerca de la meta de 80 % (Fig. 7). En 18 parcelas, todas del régimen B, la probabilidad de quedar bajo 2.5 t/ha supera 10 %. La tabla con las 59 predicciones está en el anexo técnico.

Preguntas guía. Como el modelo final usa solo tres entradas, medimos la importancia con un bosque aleatorio auxiliar (Fig. 8). Sin el régimen, el índice más importante es el NDVI y la variable climática más importante es la lluvia, pero ambos funcionan como indicadores de zona. Con el régimen y los vecinos, el índice de sequía NDDI [26] es el que más aporta, aunque apenas 0.004 t/ha. La mejor combinación es régimen más rezago espacial.

Qué significa el error para un productor. Con el precio del SIAP, un error de 0.46 t/ha equivale a unos 2,500 pesos por hectárea, entre 2,000 y 3,300 según el municipio. Es de 7 a 12 % del costo de producción y de 13 a 45 % del crédito por hectárea. Sirve para ordenar parcelas por riesgo, pero no para decidir sola sobre una parcela.

Aplicación. En https://agrocebada.alan-pv.com se consulta el mapa de parcelas, la predicción con su intervalo y la probabilidad de quedar bajo un umbral que elige el usuario. La aplicación ejecuta el modelo en vivo.

VI. Uso de la ciencia de datos en la inclusión financiera del sector agro

Del rendimiento de la zona al de la parcela. Los paquetes tecnológicos de AgroCostos, que FIRA sugirió consultar en la segunda sesión de preguntas [3], suponen un rendimiento esperado por zona [25]. Nuestra capa de crédito usa en su lugar la predicción de cada parcela con su incertidumbre. Con ella calcula la probabilidad de no cubrir el crédito o el costo de producción (anexo técnico, ecuación 4). Si la cosecha se pierde el ingreso es cero, así que la probabilidad también incluye la pérdida histórica del municipio. Un semáforo la resume en verde, amarillo o rojo. Con el crédito, 23 parcelas salen en verde, 30 en amarillo y 6 en rojo. Con el costo total casi todas salen en rojo, porque el paquete incluye gastos que el crédito no financia, como la renta de la tierra.

A quién sirve. La comercializadora que compra el grano puede decidir dónde visitar primero. El analista puede ordenar parcelas por riesgo y el productor puede ver cuánto necesita cosechar para pagar.

Qué no hace. La probabilidad describe un año parecido a 2025 y no incluye sequías, heladas ni cambios de precio. Por eso no es una probabilidad de incumplimiento ni sirve para fijar el precio de un seguro [27].

Cuándo se puede usar. El modelo usa el rendimiento de parcelas vecinas de la misma temporada, que solo existe después de su cosecha. Es una estimación de cierre de temporada. Para usarlo antes de cosechar harían falta rendimientos de ciclos anteriores.

VII. Conclusiones

Construimos un modelo sencillo para estimar el rendimiento de 59 parcelas de cebada de temporal. Usa dos datos, el régimen de registro del municipio y el rendimiento de las parcelas vecinas, combinados con un proceso gaussiano. Esperamos un RMSE de 0.46 a 0.49 t/ha en las 59 parcelas.

Cada pieza entró porque mejoró la validación de forma consistente, y cada idea que quedó fuera lo hizo porque no la mejoró. Así quedaron fuera las variables satelitales y climáticas, que no aportaron una vez conocidos el régimen y los vecinos.

Nuestros resultados sugieren que el límite de este reto está más en las etiquetas que en el algoritmo. El modelo mejora poco a la media por régimen, y el redondeo y la fuente mixta del rendimiento pueden agregar un ruido que no pudimos medir. Conocer la fuente de cada registro, la fecha de siembra o tener cortes de cosecha medidos permitiría comprobarlo, y podría ayudar más que un modelo más complejo.

Sobre las preguntas guía, el NDVI y la lluvia pesan solo cuando falta el régimen, porque indican la zona. Con el régimen y los vecinos, el NDDI es el índice que más aporta, pero su efecto es muy pequeño. La mejor combinación es régimen más rezago espacial.

Para un productor, el error equivale a unos 2,500 pesos por hectárea. La estimación sirve para ordenar parcelas y orientar la revisión de un crédito, junto con el juicio del analista.

Como trabajo futuro proponemos validar con el rendimiento real de las 59 parcelas cuando FIRA lo publique, sumar más temporadas para estimar antes de la cosecha y probar la capa de crédito con datos reales.

Referencias

[1] FIRA, *Reto AgroCebada 2026. Bases de participación y descripción del conjunto de datos*, 2026.

[2] Secretaría de Agricultura y Desarrollo Rural, "Del campo a la copa: el recorrido de la cebada," *gob.mx*, 11 de noviembre de 2025. [En línea]. Disponible: https://www.gob.mx/agricultura/articulos/del-campo-a-la-copa-el-recorrido-de-la-cebada

[3] FIRA, *Sesiones de preguntas y respuestas del Reto AgroCebada 2026 y correos de seguimiento a los equipos participantes*, septiembre y octubre de 2026 (último correo del 14 de octubre).

[4] M. Drusch *et al.*, “Sentinel-2: ESA’s Optical High-Resolution Mission for GMES Operational Services,” *Remote Sensing of Environment*, vol. 120, pp. 25–36, 2012.

[5] A. E. Frazier y B. L. Hemingway, “A Technical Review of Planet Smallsat Data: Practical Considerations for Processing and Using PlanetScope Imagery,” *Remote Sensing*, vol. 13, no. 19, p. 3930, 2021.

[6] C. Funk *et al.*, “The climate hazards infrared precipitation with stations—a new environmental record for monitoring extremes,” *Scientific Data*, vol. 2, art. 150066, 2015.

[7] A. Verdin *et al.*, “Development and validation of the CHIRTS-daily quasi-global high-resolution daily temperature data set,” *Scientific Data*, vol. 7, no. 1, art. 303, 2020.

[8] D. B. Lobell *et al.*, “Eyes in the Sky, Boots on the Ground: Assessing Satellite- and Ground-Based Approaches to Crop Yield Measurement and Analysis,” *American Journal of Agricultural Economics*, vol. 102, no. 1, pp. 202–219, 2020.

[9] T. van Klompenburg, A. Kassahun y C. Catal, “Crop yield prediction using machine learning: A systematic literature review,” *Computers and Electronics in Agriculture*, vol. 177, p. 105709, 2020.

[10] M. Weiss, F. Jacob y G. Duveiller, “Remote sensing for agricultural applications: A meta-review,” *Remote Sensing of Environment*, vol. 236, p. 111402, 2020.

[11] FIRA, *Ecuaciones de índices satelitales. Reto AgroCebada FIRA 2026*, 2026.

[12] J. C. Zadoks, T. T. Chang y C. F. Konzak, “A decimal code for the growth stages of cereals,” *Weed Research*, vol. 14, no. 6, pp. 415–421, 1974.

[13] D. R. Roberts *et al.*, “Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure,” *Ecography*, vol. 40, no. 8, pp. 913–929, 2017.

[14] P. Ploton *et al.*, “Spatial validation reveals poor predictive performance of large-scale ecological mapping models,” *Nature Communications*, vol. 11, no. 1, art. 4540, 2020.

[15] M. Ojala y G. C. Garriga, “Permutation tests for studying classifier performance,” *Journal of Machine Learning Research*, vol. 11, pp. 1833–1863, 2010.

[16] W. R. Tobler, “A computer movie simulating urban growth in the Detroit region,” *Economic Geography*, vol. 46, pp. 234–240, 1970.

[17] C. E. Rasmussen y C. K. I. Williams, *Gaussian Processes for Machine Learning*. Cambridge, MA, EE. UU.: MIT Press, 2006.

[18] G. C. Cawley y N. L. C. Talbot, “On over-fitting in model selection and subsequent selection bias in performance evaluation,” *Journal of Machine Learning Research*, vol. 11, pp. 2079–2107, 2010.

[19] S. Varma y R. Simon, “Bias in error estimation when using cross-validation for model selection,” *BMC Bioinformatics*, vol. 7, art. 91, 2006.

[20] C. Nadeau e Y. Bengio, “Inference for the generalization error,” *Machine Learning*, vol. 52, no. 3, pp. 239–281, 2003.

[21] V. Vovk, A. Gammerman y G. Shafer, *Algorithmic Learning in a Random World*. Nueva York, NY, EE. UU.: Springer, 2005.

[22] J. Lei *et al.*, “Distribution-Free Predictive Inference for Regression,” *Journal of the American Statistical Association*, vol. 113, no. 523, pp. 1094–1111, 2018.

[23] S. Kaufman, S. Rosset, C. Perlich y O. Stitelman, “Leakage in data mining: Formulation, detection, and avoidance,” *ACM Transactions on Knowledge Discovery from Data*, vol. 6, no. 4, art. 15, 2012.

[24] SIAP, “Producción agrícola municipal, cierre 2025,” Datos abiertos, 2026. Consultado el 4 de octubre de 2026. Disponible en https://nube.agricultura.gob.mx/datosAbiertos/Agricola.php

[25] Fideicomisos Instituidos en Relación con la Agricultura, “Agrocostos.” [En línea]. Disponible: https://www.fira.gob.mx/Nd/Agrocostos.jsp. Consultado el 15 de octubre de 2026.

[26] Y. Gu *et al.*, “A five-year analysis of MODIS NDVI and NDWI for grassland drought assessment over the central Great Plains of the United States,” *Geophysical Research Letters*, vol. 34, no. 6, art. 2006GL029127, 2007.

[27] N. Jensen y C. Barrett, “Agricultural Index Insurance for Development,” *Applied Economic Perspectives and Policy*, vol. 39, no. 2, pp. 199–219, 2017.