Rendimiento de cebada de temporal con régimen de registro y rezago espacial

Reporte técnico. Reto AgroCebada FIRA 2026

Equipo Los Bien Dotados
José Alán Pomares Valdés, Luis Emmanuel Ramiro Luna y Vicente Josimar López Martínez
Asesor Luis Gustavo Olivares Soto
Facultad de Ciencias de la Computación, Benemérita Universidad Autónoma de Puebla, Puebla, México
pv202351433@alm.buap.mx

I. Introducción

El Reto AgroCebada FIRA 2026 pide estimar el rendimiento de grano de cebada de temporal, en toneladas por hectárea (t/ha), de 59 parcelas de Hidalgo, Puebla y Tlaxcala [1]. Estas tres entidades se cuentan entre las cuatro principales productoras de cebada grano del país [2]. FIRA busca una herramienta que apoye decisiones productivas, de planeación y eventualmente financieras [3].

El conjunto de datos reúne 197 parcelas de nueve municipios, todas del ciclo primavera-verano 2025. De ellas, 138 traen su rendimiento y sirven para entrenar, y 59 no lo traen y son las que se califican. FIRA hizo la partición al azar, estratificada por zona. Para cada parcela hay series de los satélites Sentinel-2 [4], Landsat y PlanetScope [5], lluvia [6], temperatura [7] y topografía. El rendimiento es el peso en báscula de toda la cosecha, sin ajuste por humedad, impurezas ni mermas. Lo reportó principalmente la comercializadora que compró el grano y, en menor proporción, el productor. FIRA no informará la fuente de cada parcela y pide tratar todos los registros como una sola variable objetivo [3].

La predicción de rendimiento con teledetección y aprendizaje automático es un tema muy estudiado [8], [9]. Este reto tiene dos rasgos que cambian el problema. El primero es el tamaño de la muestra. Con 138 parcelas, la diferencia entre dos modelos suele ser menor que la variación que produce cambiar las particiones de validación. El segundo es el registro del rendimiento. La literatura reporta que los rendimientos reportados contienen un error considerable [10], y aquí la fuente es mixta.

Dos formas de registrar el rendimiento. Al revisar las etiquetas de entrenamiento encontramos que cada municipio registra el rendimiento de una sola de dos formas (Fig. 1). En cuatro municipios los valores tienen dos decimales y promedian 4.49 t/ha. Lo llamamos régimen A. En los otros cinco todos los valores tienen un solo decimal, 44 de 51 son múltiplos de 0.5, y promedian 3.05 t/ha. Lo llamamos régimen B. La diferencia entre medias, 1.4 t/ha, es casi tres veces la desviación estándar dentro de cada régimen, que es de 0.53 t/ha en el A y 0.40 en el B. Por los decimales no sabemos si el rendimiento se midió distinto o solo se anotó distinto. La fuente mixta es una explicación posible que no podemos confirmar. Por eso tratamos el régimen como una observación por municipio y no como dos variables objetivo.

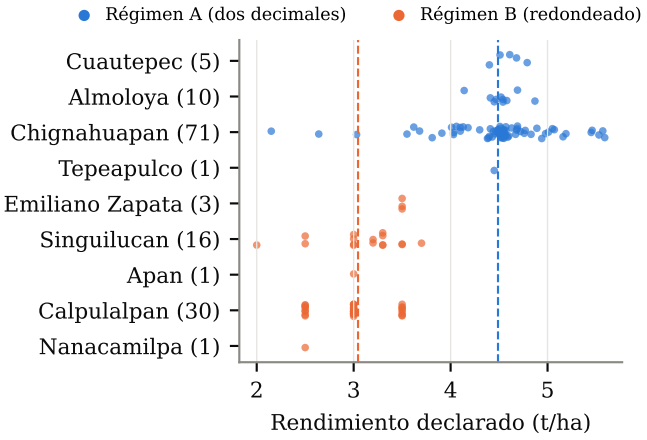


Figura 1. Rendimiento de las 138 parcelas de entrenamiento por municipio, con el número de parcelas entre paréntesis. Las líneas punteadas son la media de cada régimen.

Por estos dos rasgos el trabajo no se limita a buscar el algoritmo con menor error. Responde tres preguntas. Qué información predice el rendimiento de parcelas nuevas, qué tan confiable es el error que estimamos y qué significa ese error para quien toma una decisión. Para responderlas fijamos la forma de evaluar antes de probar ideas y agregamos las piezas del modelo una por una, conservando solo las que mejoraban la validación de forma consistente.

El modelo final es un proceso gaussiano con dos entradas, el régimen del municipio y el rendimiento de las parcelas vecinas del mismo régimen a 400 m o menos. Estimamos que su raíz del error cuadrático medio (RMSE) en las 59 parcelas será de 0.46 a 0.49 t/ha. Además entregamos un intervalo de predicción por parcela, una capa que traduce la predicción a pesos y a riesgo de crédito, y una aplicación web para consultarla.

II. Justificación

Un crédito de avío financia el ciclo de cultivo y se paga con el ingreso de la cosecha. Para valorar si la cosecha cubrirá el crédito, el analista necesita una estimación del rendimiento de la parcela y de cuánto puede fallar. Los paquetes tecnológicos de FIRA suponen un mismo rendimiento esperado para toda una zona, de 3.5 a 5.5 t/ha según el paquete [11], y no distinguen una parcela de otra.

Las mediciones de campo son escasas y costosas. Las imágenes de satélite y los datos de clima son públicos y cubren cualquier parcela. Por eso conviene saber cuánta información del rendimiento contienen realmente esas fuentes. Con 138 parcelas y un registro heterogéneo del rendimiento, también conviene medir con rigor qué tan confiable es el error, porque un error subestimado haría parecer seguras decisiones que no lo son.

Este trabajo aporta una estimación por parcela con un error medido de forma conservadora, su traducción a pesos por hectárea y una aplicación para analistas y productores. También documenta las ideas que no mejoraron la predicción y por qué, para que trabajos futuros no repitan esas pruebas.

III. Objetivos

Objetivo general. Estimar el rendimiento de cebada de temporal, en t/ha, de las 59 parcelas del reto con el menor RMSE posible en parcelas no vistas, y medir con honestidad qué tan confiable es esa estimación.

Objetivos específicos.

1) Caracterizar las etiquetas de rendimiento y medir cómo su forma de registro limita lo que un modelo puede predecir.
2) Construir el modelo con una regla de decisión fijada antes de probar ideas, y conservar solo las piezas que mejoren la validación de forma consistente.
3) Estimar el error esperado incluyendo el costo de elegir entre variantes, y entregar por parcela un intervalo del percentil 10 al 90 con cobertura verificada.
4) Responder con evidencia qué índice satelital, qué variable climática y qué combinación de variables pesan más.
5) Traducir el error a pesos por hectárea y a una señal de riesgo de crédito, e indicar en qué momento del ciclo puede usarse la estimación.
6) Publicar una aplicación web que ejecute el modelo y muestre predicciones, intervalos y probabilidades.

IV. Metodología

Limpieza de las series. Consideramos limpia una observación satelital con nubosidad de 20 % o menos y con valor del índice. Elegimos ese umbral porque la nubosidad casi siempre vale 0 o 100 % (86 % de los registros) y cuando vale 100 los índices vienen vacíos. Así cada parcela conserva de 19 a 34 observaciones de Sentinel-2 entre mayo y octubre de 2025, con mediana de 25. Las observaciones descartadas no se imputan. Excluimos el índice de área foliar (LAI) de Sentinel-2 porque su fórmula da valores negativos sobre suelo desnudo, sin significado físico, en 42 % de los registros [12]. Con las series limpias construimos 91 variables por parcela, como el máximo del NDVI de 2025, la fenología [13], la historia de 2022 a 2024, el clima y la topografía. Ninguna usa el rendimiento.

Régimen. Asignamos el régimen con una regla fija por nombre de municipio. No usamos el formato de cada etiqueta, porque 7 de las 87 parcelas del régimen A tienen un solo decimal y esa regla las habría mandado al B. La regla se conoce para las 59 parcelas, porque todas pertenecen a municipios con parcelas de entrenamiento. En seis parcelas de municipios con una a tres parcelas de entrenamiento el régimen se dedujo de su propia etiqueta y de la cercanía a municipios del mismo formato. Sin ellas el RMSE pasa de 0.458 a 0.464 t/ha, así que el efecto es pequeño.

Esquema de evaluación. Todo error se mide en parcelas que el modelo no vio. Usamos validación cruzada de 5 grupos, estratificada por municipio y repetida 10 veces, porque imita la partición oficial. Es el esquema A. Como la validación al azar puede ser optimista cuando parcelas cercanas se parecen [14], [15], añadimos un esquema B que deja fuera zonas completas, formadas al unir parcelas a menos de 2 km. Todo lo que usa el rendimiento se recalcula dentro de cada grupo con solo las parcelas de entrenamiento.

Regla de decisión. Con 138 parcelas una mejora puede aparecer por azar. Por eso una idea se acepta solo si baja el RMSE en al menos 7 de las 10 repeticiones y si pasa una prueba de permutación con $p \leq 0.05$ [16]. En la prueba revolvemos las variables nuevas dentro de cada régimen y repetimos la validación 50 veces. Si el modelo predice igual con ellas revueltas, la mejora no viene de esas variables.

Rezago espacial. Parcelas cercanas tienden a rendir parecido porque comparten suelo, clima y manejo [17]. El rezago de una parcela es el promedio del rendimiento de hasta 10 parcelas de entrenamiento del mismo régimen a 400 m o menos, ponderado por el inverso de la distancia. Sin vecinos, recibe la media de su régimen en el entrenamiento. Elegimos 400 m porque a 250 m solo el 25 % de las parcelas tiene vecino, mientras que con radios mayores el promedio mezcla parcelas que ya no se parecen y el error sube.

Algoritmo. Comparamos modelos lineales, de árboles y un proceso gaussiano [18] con núcleo de base radial y término de ruido. Sus tres parámetros se ajustan por máxima verosimilitud dentro de cada grupo.

Intervalos. Usamos predicción conformal de Mondrian [19], [20], que calibra cada régimen por separado porque sus errores se distribuyen distinto. A cada predicción le sumamos los cuantiles 0.10 y 0.90 de los errores fuera de grupo de su régimen.

Controles. Probamos 73 variantes sin corregir por comparaciones múltiples, y elegir la mejor entre muchas infla su resultado [21]. Lo corregimos con validación anidada, que repite la elección entre 12 variantes dentro de cada grupo externo [22]. Comparamos modelos con la prueba t corregida de Nadeau y Bengio [23], porque las repeticiones comparten

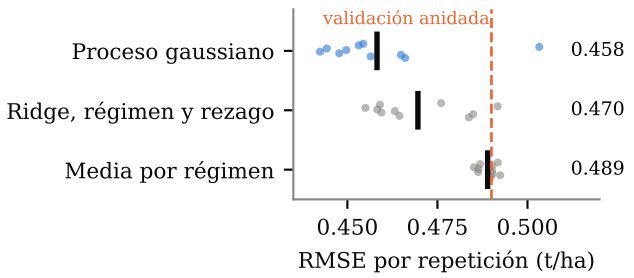


Figura 2. RMSE de cada repetición del esquema A (puntos) y su promedio. Las repeticiones comparten parcelas, por eso la comparación formal usa la prueba corregida de Nadeau y Bengio.

parcelas. Una prueba automatizada verifica que alterar las etiquetas de prueba no cambia las predicciones [24].

Capa económica. Valuamos la predicción con el precio medio rural del SIAP de 2023 a 2025 [25] y con los costos del paquete de FIRA de primavera-verano 2022, el más reciente público, actualizados a 2025 con el índice nacional de precios al consumidor [11].

V. Resultados y discusión

Error del modelo. En el esquema A el modelo obtiene un RMSE de 0.458 t/ha, un error absoluto medio (MAE) de 0.312 t/ha y un coeficiente de determinación (R^2) de 0.71. La media por régimen obtiene 0.489. El modelo la mejora en los dos regímenes, de 0.535 a 0.494 en el A y de 0.398 a 0.389 en el B. Con la prueba de Nadeau y Bengio, el RMSE del modelo menos el de la media por régimen es -0.029 t/ha, con intervalo de confianza del 95 % de -0.079 a $+0.022$ ($p = 0.26$). La dirección favorece al modelo, pero la diferencia no es significativa.

Error esperado en las 59 parcelas. La validación anidada da 0.490. No indica un modelo peor, porque mide todo el procedimiento de elegir. En sus mismas particiones el proceso gaussiano fijo obtiene 0.458 y la media por régimen 0.489. Por eso esperamos un RMSE de 0.46 a 0.49 t/ha. Además, con 59 parcelas el RMSE calificado varía según cuáles toquen. Al sortear 5000 grupos de 37 errores del régimen A y 22 del B, el 90 % cae entre 0.35 y 0.56 t/ha.

Por qué el régimen es la base. La media por municipio se acerca a la del régimen en el esquema A (0.510), pero en el esquema B sube a 0.955, porque al dejar zonas fuera muchos municipios se quedan sin entrenamiento. El régimen no tiene ese problema.

Por qué entra el rezago. El rezago ganó en 9 de 10 repeticiones (Fig. 2). Al revolver las coordenadas dentro de cada régimen, ninguna de 50 permutaciones igualó el error real ($p = 0.02$, el mínimo posible con 50 sorteos). Es decir, la posición de los vecinos aporta información además del régimen. En el esquema B el modelo empata con la media por régimen, porque sin vecinos el rezago se vuelve esa media.

Por qué no usamos satélite ni clima. Ningún bloque de variables pasó la regla. El más cercano, la heterogeneidad del NDVI dentro de la parcela, ganó en 7 de 10 repeticiones por 0.002 t/ha, pero con sus valores revueltos el modelo predijo igual ($p = 0.63$). Juntar todos los bloques satelitales empeoró el RMSE a 0.498. El clima viene en celdas de unos 5 km, así que solo distingue zonas, y eso ya lo hacen el régimen y los vecinos.

Por qué un proceso gaussiano. Los modelos de árboles quedaron peor que la media por régimen, porque con tres entradas y 138 parcelas sus cortes no tienen dónde apoyarse. Los lineales quedaron cerca de 0.470. El proceso gaussiano obtuvo 0.458, con un RMSE por repetición de 0.442 a 0.503. Frente a un modelo lineal con las mismas entradas no es significativamente mejor ($p = 0.38$). Lo elegimos porque ajusta una relación suave entre rezago y rendimiento y su término de ruido absorbe parte del ruido de las etiquetas.

Intervalos y predicciones. El intervalo del percentil 10 al 90 cubre 570 de 690 evaluaciones en validación anidada (0.826, intervalo de confianza de 0.765 a 0.883), con ancho medio de 1.13 t/ha. Las 37 parcelas del régimen A tienen predicción media de 4.49 t/ha y las 22 del B de 3.06. En 18 parcelas, todas del B, la probabilidad de quedar bajo 2.5 t/ha supera 0.10.

Preguntas guía. Como el modelo final solo tiene tres entradas, respondimos con un bosque aleatorio de análisis y medimos cuánto sube su RMSE al revolver cada índice o variable. Sin el régimen, el índice más importante es el NDVI (0.106 t/ha) y la variable climática más importante es la lluvia (0.364 t/ha), pero ambos identifican la zona y sustituyen al régimen. Con régimen y rezago presentes, el índice de sequía NDDI [26] es el mayor, con apenas 0.004 t/ha, y ninguna variable climática aporta. La combinación que mejor funciona es régimen más rezago.

Error en términos productivos. Con el precio medio del SIAP en las 59 parcelas, de 5,353 $/t en el régimen A y 5,693 en el B, un error de 0.46 t/ha equivale a unos 2,500 $/ha, entre 2,000 y 3,300 según el municipio. Es de 7 a 12 % del costo total del paquete y de 13 a 45 % del crédito por hectárea.

Limitaciones. El modelo acerca a la media de su régimen las parcelas extremas, como las de 5.5 t/ha. Las predicciones heredan las unidades de la etiqueta, sin ajuste por humedad. Solo hay una temporada, con mayo y junio más lluviosos que lo normal. No medimos el ruido de etiqueta.

Aplicación. La aplicación web, en https://agrocebada.alan-pv.com, muestra el mapa de parcelas, la predicción con su intervalo y la probabilidad de quedar bajo un umbral que elige el usuario, y ejecuta el modelo en vivo.

VI. Uso de la ciencia de datos en la inclusión financiera del sector agro

De un rendimiento por zona a uno por parcela. La capa de crédito sustituye el rendimiento esperado del paquete tecnológico por la predicción de cada parcela con su incertidumbre. Calcula la probabilidad de no cubrir el crédito o el costo total. La probabilidad combina los errores del modelo con la fracción de superficie que el municipio pierde históricamente, porque si la cosecha se pierde el ingreso es

cero. Un semáforo la resume en verde bajo 10 %, amarillo de 10 a 30 % y rojo desde 30 %. Con el crédito, 23 de las 59 parcelas salen en verde, 30 en amarillo y 6 en rojo. Con el costo total salen 55 en rojo, porque el paquete incluye conceptos no financiados, como la renta.

A quién sirve. La comercializadora que compra el grano puede priorizar visitas de campo. El analista ordena parcelas por riesgo y el productor ve cuánto debe cosechar para pagar.

Alcance. La probabilidad describe la incertidumbre de un año parecido a 2025 y no incluye sequías, heladas ni cambios de precio. Por eso no es una probabilidad de incumplimiento ni sirve para tarificar seguros, que además enfrentan riesgo base [27].

Momento de uso. El modelo usa rendimientos de vecinas de la misma temporada, que existen solo después de su cosecha. Es una estimación de cierre de temporada. Para usarlo antes de cosechar harían falta rendimientos de ciclos anteriores, que el reto no incluye.

Escala municipal. Con el SIAP de 2003 a 2025 ajustamos un modelo municipal [25]. En municipios a más de 50 km de los de entrenamiento, la temperatura máxima de julio y agosto más kriging de residuos obtuvo un RMSE de 0.44 t/ha contra 0.57 del kriging solo. Al repetir de forma anidada la elección de esa variable, la ventaja baja a unos 0.07 t/ha.

VII. Conclusiones

Estimamos el rendimiento de las 59 parcelas con un proceso gaussiano que usa el régimen de registro del municipio y el rendimiento de las parcelas vecinas del mismo régimen a 400 m o menos. En validación cruzada obtiene un RMSE de 0.458 t/ha, un MAE de 0.312 y un R^2 de 0.71. Como lo elegimos entre muchas variantes, esperamos un RMSE de 0.46 a 0.49 t/ha en las 59 parcelas.

Cada pieza del modelo está justificada por la validación. El régimen entró porque reduce el error más que cualquier otra variable y se conoce para toda parcela. El rezago entró porque ganó en 9 de 10 repeticiones y pasó la prueba de permutación. Las variables satelitales, climáticas y topográficas quedaron fuera porque ninguna mejoró la validación una vez conocidos el régimen y los vecinos.

Nuestros resultados sugieren que el límite de este reto está más en las etiquetas que en el algoritmo. La mejora sobre la media por régimen es de 0.029 t/ha y no es significativa. Si el redondeo del régimen B fuera uniforme, aportaría por sí solo unos 0.13 t/ha de error en ese régimen. La fuente mixta y la falta de ajuste por humedad son posibles fuentes de ruido que no pudimos medir. La fuente de cada registro, la fecha de siembra o cortes de cosecha medidos permitirían comprobarlo.

Sobre las preguntas guía, sin el régimen el NDVI y la lluvia son lo que más pesa, pero funcionan como indicadores de zona. Con el régimen y los vecinos, el NDDI es el índice de mayor aporte y aun así es de 0.004 t/ha. La mejor combinación es régimen más rezago.

Para un productor, un error de 0.46 t/ha son unos 2,500 $/ha. La estimación sirve para ordenar parcelas por riesgo y orientar la revisión de un crédito, no para decidir sola sobre una parcela, porque el margen depende también del precio y del costo, que tienen su propia incertidumbre.

Como trabajo futuro proponemos validar con el rendimiento observado de las 59 parcelas cuando FIRA lo libere, incorporar varias temporadas para estimar antes de la cosecha y probar la capa de crédito con información real de créditos.

Referencias

[1] FIRA, *Reto AgroCebada 2026. Bases de participación y descripción del conjunto de datos*, 2026.

[2] Secretaría de Agricultura y Desarrollo Rural, "Del campo a la copa: el recorrido de la cebada," *gob.mx*, 11 de noviembre de 2025. [En línea]. Disponible: https://www.gob.mx/agricultura/articulos/del-campo-a-la-copa-el-recorrido-de-la-cebada

[3] FIRA, *Sesiones de preguntas y respuestas del Reto AgroCebada 2026 y correos de seguimiento a los equipos participantes*, septiembre y octubre de 2026 (último correo del 14 de octubre).

[4] M. Drusch *et al.*, "Sentinel-2: ESA's Optical High-Resolution Mission for GMES Operational Services," *Remote Sensing of Environment*, vol. 120, pp. 25–36, 2012.

[5] A. E. Frazier y B. L. Hemingway, "A Technical Review of Planet Smallsat Data: Practical Considerations for Processing and Using PlanetScope Imagery," *Remote Sensing*, vol. 13, no. 19, p. 3930, 2021.

[6] C. Funk *et al.*, "The climate hazards infrared precipitation with stations—a new environmental record for monitoring extremes," *Scientific Data*, vol. 2, art. 150066, 2015.

[7] A. Verdin *et al.*, "Development and validation of the CHIRTS-daily quasi-global high-resolution daily temperature data set," *Scientific Data*, vol. 7, no. 1, art. 303, 2020.

[8] T. van Klompenburg, A. Kassahun y C. Catal, "Crop yield prediction using machine learning: A systematic literature review," *Computers and Electronics in Agriculture*, vol. 177, p. 105709, 2020.

[9] M. Weiss, F. Jacob y G. Duveiller, "Remote sensing for agricultural applications: A meta-review," *Remote Sensing of Environment*, vol. 236, p. 111402, 2020.

[10] D. B. Lobell *et al.*, "Eyes in the Sky, Boots on the Ground: Assessing Satellite- and Ground-Based Approaches to Crop Yield Measurement and Analysis," *American Journal of Agricultural Economics*, vol. 102, no. 1, pp. 202–219, 2020.

[11] Fideicomisos Instituidos en Relación con la Agricultura, "Agrocostos." [En línea]. Disponible: https://www.fira.gob.mx/Nd/Agrocostos.jsp. Consultado el 15 de octubre de 2026.

[12] FIRA, *Ecuaciones de índices satelitales. Reto AgroCebada FIRA 2026*, 2026.

[13] J. C. Zadoks, T. T. Chang y C. F. Konzak, "A decimal code for the growth stages of cereals," *Weed Research*, vol. 14, no. 6, pp. 415–421, 1974.

[14] D. R. Roberts *et al.*, "Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure," *Ecography*, vol. 40, no. 8, pp. 913–929, 2017.

[15] P. Ploton *et al.*, "Spatial validation reveals poor predictive performance of large-scale ecological mapping models," *Nature Communications*, vol. 11, no. 1, art. 4540, 2020.

[16] M. Ojala y G. C. Garriga, "Permutation tests for studying classifier performance," *Journal of Machine Learning Research*, vol. 11, pp. 1833–1863, 2010.

[17] W. R. Tobler, "A computer movie simulating urban growth in the Detroit region," *Economic Geography*, vol. 46, pp. 234–240, 1970.

[18] C. E. Rasmussen y C. K. I. Williams, *Gaussian Processes for Machine Learning*. Cambridge, MA, EE. UU.: MIT Press, 2006.

[19] V. Vovk, A. Gammerman y G. Shafer, *Algorithmic Learning in a Random World*. Nueva York, NY, EE. UU.: Springer, 2005.

[20] J. Lei *et al.*, "Distribution-Free Predictive Inference for Regression," *Journal of the American Statistical Association*, vol. 113, no. 523, pp. 1094–1111, 2018.

[21] G. C. Cawley y N. L. C. Talbot, "On over-fitting in model selection and subsequent selection bias in performance evaluation," *Journal of Machine Learning Research*, vol. 11, pp. 2079–2107, 2010.

[22] S. Varma y R. Simon, "Bias in error estimation when using cross-validation for model selection," *BMC Bioinformatics*, vol. 7, art. 91, 2006.

[23] C. Nadeau e Y. Bengio, “Inference for the generalization error,” *Machine Learning*, vol. 52, no. 3, pp. 239–281, 2003.

[24] S. Kaufman, S. Rosset, C. Perlich y O. Stitelman, “Leakage in data mining: Formulation, detection, and avoidance,” *ACM Transactions on Knowledge Discovery from Data*, vol. 6, no. 4, art. 15, 2012.

[25] SIAP, “Producción agrícola municipal, cierre 2025,” Datos abiertos, 2026. Consultado el 4 de octubre de 2026. Disponible en https://nube.agricultura.gob.mx/datosAbiertos/Agricola.php

[26] Y. Gu *et al.*, “A five-year analysis of MODIS NDVI and NDWI for grassland drought assessment over the central Great Plains of the United States,” *Geophysical Research Letters*, vol. 34, no. 6, art. 2006GL029127, 2007.

[27] N. Jensen y C. Barrett, “Agricultural Index Insurance for Development,” *Applied Economic Perspectives and Policy*, vol. 39, no. 2, pp. 199–219, 2017.