Cómo se construyó el modelo

Reto AgroCebada FIRA 2026 · Predicción del rendimiento de cebada (t/ha) de 59 parcelas a partir de 138 de entrenamiento

En una frase: un solo modelo (proceso gaussiano) con dos entradas, el **régimen** de registro de la parcela y el **rendimiento de sus vecinas** a menos de 400 m. Error esperado de 0.46 a 0.49 t/ha. Cada predicción trae un rango del 80 %.

Paso 1. Analizar los datos: dos regímenes

Los rendimientos se registraron de dos formas distintas según el **municipio**. La división es por **cómo se registró** el dato, no por su valor:

	Régimen A	Régimen B
Municipios	Chignahuapan, Almoloya, Cuautepec, Tepeapulco	Singuilucan, E. Zapata, Apan, Calpulalpan, Nanacamilpa
Cómo se registró	Con dos decimales (4.37)	Redondeado a media tonelada (3.0, 3.5)
Promedio	≈ 4.5 t/ha	≈ 3.0 t/ha

Solo con usar el promedio de cada régimen, el error baja de **0.85 a 0.49 t/ha**. El régimen se conoce para cualquier parcela porque depende del municipio. **No se hizo un modelo por régimen:** hay un solo modelo y el régimen es una de sus entradas.

Paso 2. Definir cómo medir antes de probar

Métrica: RMSE en t/ha (la oficial del reto), siempre sobre parcelas que el modelo no vio.

Validación: el esquema A aparta parcelas al azar, con 10 repeticiones, e imita la partición de FIRA; es el que decide. El esquema B aparta zonas completas y solo mide cuánto depende el modelo de las vecinas. (No confundir esquema A/B con régimen A/B.)

Regla fijada de antemano: una idea se acepta solo si gana en al menos 7 de 10 repeticiones **y** pasa una prueba de permutación ($p \leq 0.05$). La prueba revuelve al azar las variables nuevas; si el modelo funciona igual con datos revueltos, la mejora fue suerte.

Paso 3. Elegir las variables

Se construyeron **91 variables** en 8 bloques: fenología satelital 2025, pico y siembra, historia 2022–2024, heterogeneidad dentro de la parcela, labranza, temperatura de superficie, clima y topografía. Probar todas las combinaciones (2^{91}) es imposible, así que se hizo una **selección hacia adelante por bloques**: partir del régimen, agregar un bloque a la vez y aplicar la regla.

Paso	Resultado	RMSE	Decisión
Base	Solo régimen	0.489	punto de partida
1	+ rezago espacial (vecinas del mismo régimen a < 400 m)	0.470	✔ 9/10, p = 0.02
2	+ heterogeneidad (el mejor bloque)	0.468	✘ 7/10 pero p = 0.63
2	+ satélite, historia, clima, topografía, labranza…	0.470–0.480	✘ ninguno pasa

Para el rezago se probaron radios de 250 m, 400 m, 600 m y 1 km; solo 400 m mejoró. La selección se repitió con un bosque aleatorio y tampoco aceptó ningún bloque.

Paso 4. Elegir el algoritmo

Cada algoritmo se probó con las 2 entradas y con 72 variables (régimen, rezago y todos los bloques satelitales), porque la utilidad de una variable depende del modelo:

Algoritmo	Con 2 entradas	Con 72 variables
Proceso gaussiano	**0.458 ✔**	0.483
Ridge	0.470	0.498
Elastic net	0.469	0.487
PLS	0.472	0.478
LightGBM	0.491	0.493
Bosque aleatorio	0.501	0.480

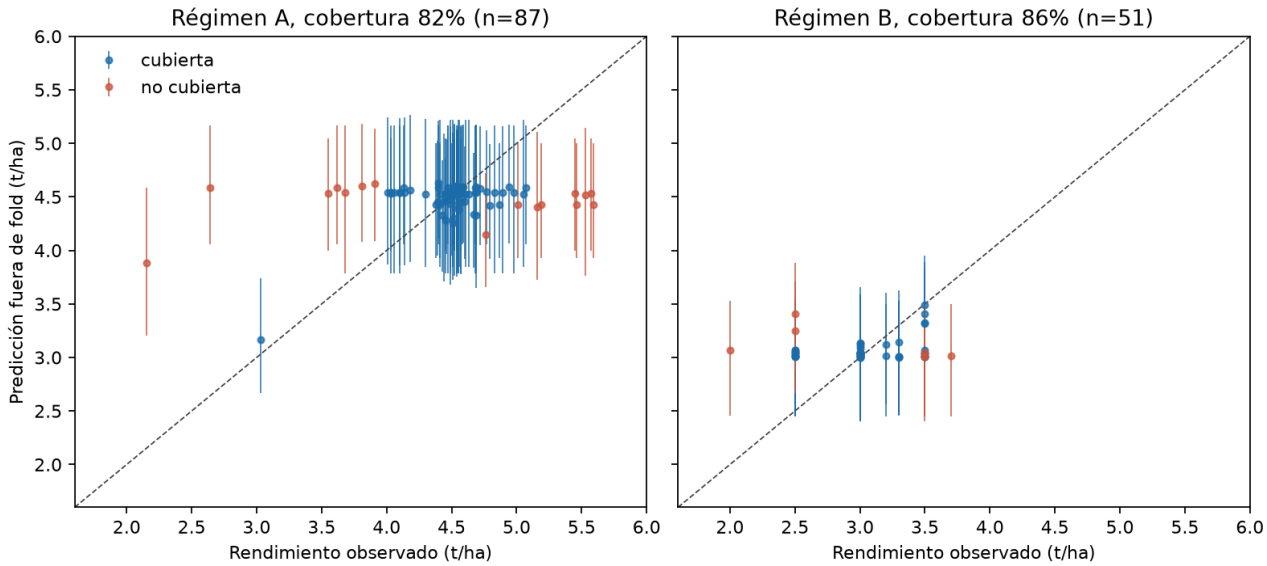
El proceso gaussiano con 2 entradas fue el único que cumplió la regla. **Qué hace:** predice una parcela nueva promediando las parcelas de entrenamiento más parecidas, con más peso cuanto más se parecen, e incluye un término de ruido que asume que las etiquetas no son exactas. No es una normalización: es el tipo de modelo.

Paso 5. Darle un rango a cada predicción (p10 – p90)

Con la validación se guardaron los errores reales del modelo en parcelas que no vio, por régimen. Se cortan el 10 % de errores más bajos y el 10 % más altos, y esos cortes se suman a cada predicción (método **conformal**; no se usó Poisson).

Parcela	Predicción	p10	p90	Prob. < 2.5 t/ha
AGC_025	2.98	2.43	3.46	22.5 %

Se lee: 10 % de probabilidad de quedar bajo 2.43, 10 % de quedar sobre 3.46, y **80 %** de estar entre ambos. Al verificarlo con validación anidada, el rango contuvo el valor real en el **83 %** de los casos (79 % en A, 89 % en B).



Cada punto es una parcela de entrenamiento predicha sin haberla visto; la línea vertical es su rango p10–p90 (azul si contiene el valor real). Las predicciones se quedan cerca del promedio de su régimen: los extremos no se pueden anticipar. (Los porcentajes de la figura vienen de una revisión sin anidar.)

¿Fue fuerza bruta?

No. Las dos entradas salieron del **análisis exploratorio** (forma de registro y partición al azar con vecinas a ~380 m); las pruebas solo las confirmaron. La búsqueda fue guiada y paso a paso (73 evaluaciones, no todas las combinaciones), con una regla fijada antes para no quedarse con algo que ganara por azar.

Aun así, elegir lo mejor de 73 pruebas da algo de optimismo. La **validación anidada**, que repite toda la elección sin ver las parcelas de prueba, estima **0.490** contra 0.458, y la mejora sobre la media por régimen no es significativa ($p = 0.26$). Por eso esperamos un RMSE real de **0.46 a 0.49 t/ha**.

Por qué el satélite y el clima no ayudaron

1. **El régimen ya explica casi todo** lo que se puede explicar. Sin él, el NDVI y la lluvia parecen importantes, pero solo porque delatan la zona. 2. **Las etiquetas tienen ruido**: las declaró el productor sin validación, y el redondeo del régimen B mete ~0.14 t/ha de error impredecible. 3. **Hay pocas parcelas** (138): diferencias de una centésima son azar. Además, el clima viene en celdas de 5 km y datos mensuales, demasiado grueso para distinguir parcelas vecinas.

Resumen: analizamos los datos y encontramos dos regímenes de registro. Fijamos cómo medir y una regla estricta. Probamos los 8 bloques de variables paso a paso: solo el rezago espacial (400 m) pasó. Probamos 6 algoritmos con 2 y con 72 variables: el proceso gaussiano con 2 entradas fue el mejor. Cada predicción lleva un rango p10–p90 del 80 % calculado con los errores reales del modelo.